

ITS INFORMATION AND COMMUNICATIONS TECHNOLOGY Academy

NOME MODULO: IA
UNITÀ DIDATTICA: IA.1
Lezione 2
Stefano Puglia

Biennio 2024-2026



INDICE DEGLI ARGOMENTI

- Area plot
- Histogram
- Box plot
- Scatter plot




Area plot

- Tipo di plot che mostra dati quantitativi cumulativi rispetto al tempo o a categorie
- Use case: dataset “continuo” lungo un periodo di tempo → studio di trend comparativi per mostrare i contributi di più categorie/attori ad un totale
- Esempio: contributi alle vendite di più categorie merceologiche durante un anno
- Solitamente “stacked”, impilati




Area plot

```
years = list(map(str, range(1995, 2025)))  
df.sort_values(['Total'], ascending=False, axis=0, inplace=True)  
df.index = df['Country']  
df_top5 = df.head(5)  
df_top5 = df_top5[years].transpose()  
df_top5.plot(kind="area", figsize=(14, 8))
```




Area plot (Artist)

```
years = list(map(str, range(1995, 2025)))  
ax = df_top5.plot(kind='area', alpha=0.35, figsize=(20, 9))  
ax.set_title('Fatturato: primi 5 paesi per importo totale - cl')  
ax.set_ylabel('milioni di USD')  
ax.set_xlabel('Anni')
```




Area plot (Artist)

```
years = list(map(str, range(1995, 2025)))  
ax = df_top5.plot(kind='area', alpha=0.10, stacked=False, figsize=(20, 9))  
ax.set_title('Fatturato: primi 5 paesi per importo totale - cl')  
ax.set_ylabel('milioni di USD')  
ax.set_xlabel('Anni')
```




Line plot (Artist)

```
years = list(map(str, range(1995, 2025)))  
ax = df_top5.plot(kind='line', figsize=(20, 9))  
ax.set_title('Fatturato: primi 5 paesi per importo totale - cl')  
ax.set_ylabel('milioni di USD')  
ax.set_xlabel('Anni')
```



Area plot (Artist)

```
years = list(map(str, range(1995, 2025)))  
ax = df_top5.plot(kind='area', alpha=0.35, figsize=(20, 9))  
ax.set_title('Fatturato: primi 5 paesi per importo totale - cl')  
ax.set_ylabel('milioni di USD')  
ax.set_xlabel('Anni')
```



Histogram


- Tipo di plot per rappresentare la distribuzione di frequenza di un dataset numerico
- Use case: quantità di un certa variabile associate ad intervalli di valore di quella variabile
- Esempio: 1) quante auto hanno un prezzo tra A e B, B e C, C e D; 2) quantità di persone di un certo gruppo con altezza tra h_1 e h_2 , h_2 e h_3 , h_3 e h_4 ...
- a) Partizionamento asse x in intervalli ("bins"), b) assegnamento di ogni punto del dataset ad un intervallo, c) conteggio del numero dei punti associati ad ogni intervallo



Histogram

```
df['2024'].plot(kind='hist', figsize=(8, 5))  
plt.title('Fatturato da tutti i paesi nel 2024 - cl')  
plt.ylabel('Numero di Paesi')  
plt.xlabel('Fatturato (milioni di USD)')  
plt.show()
```

Es. Intorno ai
40 paesi hanno
contribuito con
un fatturato nel
2024 compreso
tra 0 e meno di
200 mln di
USD




API: `pandas.DataFrame.plot`



Histogram

```
count, bin_edges = np.histogram(df['2024'])
df['2024'].plot(kind='hist', figsize=(8, 5),
                 xticks=bin_edges, color='green')
plt.title('Fatturato da tutti i paesi nel 2024 - cl')
plt.ylabel('Numero di Paesi')
plt.xlabel('Fatturato (milioni di USD)')
plt.show()
```

Es. Poco più di
25 paesi hanno
contribuito con
un fatturato nel
2024 compreso
tra 4.3 e 91.4
mln di USD




API: `pandas.DataFrame.plot`



Histogram

```
fig, ax = plt.subplots(figsize=(8, 5))
bars = ax.hist(df['2024'], color='green', edgecolor='white')
plt.bar_label(bars[2], fontsize=6, color='navy')
plt.xticks(bars[1])
plt.title('Fatturato da tutti i paesi nel 2024 - cl')
plt.ylabel('Numero di Paesi')
plt.xlabel('Fatturato (milioni di USD)')
plt.show()
```




API: matplotlib.axes.Axes

API: matplotlib.container.BarContainer API: matplotlib.pyplot.bar_label

Histogram

Es. La Spagna ha contribuito con un fatturato compreso tra 48,5 e 65,9 mln di USD per 9 anni. L'Italia con un fatturato compreso tra 83,2 e 100,6 mln di USD per 5 anni. La Germania con un fatturato compreso tra 291,4 e 308,8 mln di USD per 2 anni.


Fatturato da tre paesi tra il 1995 ed il 2024 - cl



Histogram


Es. La Spagna ha contribuito con un fatturato compreso tra 48,5 e 65,9 mln di USD per 9 anni. L'Italia con un fatturato compreso tra 83,2 e 100,6 mln di USD per 5 anni. La Germania con un fatturato compreso tra 291,4 e 308,8 mln di USD per 2 anni.

Fatturato da tre paesi tra il 1995 ed il 2024 - **cl**



Histogram

Fatturato da tre paesi tra il 1995 ed il 2024 - ds




Box plot


- Tipo di plot che mostra la distribuzione di un gruppo/campione di dati mediante specifiche grandezze statistiche tipiche
- Misurazione di posizione e dispersione
- Use case: dataset di valori di un grandezza relativi ad un insieme (es. prezzi di un bene) → analisi comparativa di diversi beni rispetto alla grandezza
- Esempio: differenze tra gruppi di uno stesso bene associati a diverse regioni geografiche o a diversi intervalli di tempo



Box plot




Box plot




Mary Eleanor Spear,
50s - 60s



Box plot




Box plot



Box plot


```
df.set_index('Country', inplace=True)
country_name = "Italy"
country = df.loc[country_name, self.years]
country.plot(kind='box', figsize=(10, 6))
title = "Fatturato..."
plt.title(title)
plt.savefig(self.config.output_plot_box)
plt.show()
plt.close()
```



API: `pandas.DataFrame.plot`

Box plot

```
df.set_index('Country', inplace=True)
country_name = "Italy"
country = df.loc[country_name, self.years]
country.plot(kind='box', figsize=(10, 6))
title = "Fatturato..."
plt.title(title)
plt.savefig(self.config.output_plot_box)
plt.show()
plt.close()
```




Box plot

```
df.set_index('Country', inplace=True)
country_name = "Italy"
country = df.loc[country_name, self.years]
country.plot(kind='box', figsize=(10, 6))
title = "Fatturato..."
plt.title(title)
plt.savefig(self.config.output_plot_box)
plt.show()
plt.close()
```

```
Italy
count    30.000000
mean     113.713333
std       44.162730
min       58.200000
25%       75.000000
50%      100.550000
75%      146.150000
max      209.500000
```


$Q3 + 1.5 * IQR = 252.87499999999994$

Upper whisker (baffo superiore): 209.5




Box plot

```
df.set_index('Country', inplace=True)
country_name = "India"
country = df.loc[country_name, self.years]
country.plot(kind='box', figsize=(10, 6))
title = "Fatturato..."
plt.title(title)
plt.savefig(self.config.output_plot_box)
plt.show()
plt.close()
```




Box plot

```
df.set_index('Country', inplace=True)
country_name = "India"
country = df.loc[country_name, self.years]
country.plot(kind='box', figsize=(10, 6))
title = "Fatturato..."
plt.title(title)
plt.savefig(self.config.output_plot_box)
plt.show()
plt.close()
```



Box plot

```
df.set_index('Country', inplace=True)
country_name = "India"
country = df.loc[country_name, self.years]
country.plot(kind='box', figsize=(10, 6))
title = "Fatturato..."
plt.title(title)
plt.savefig(self.config.output_plot_box)
plt.show()
plt.close()
```




```
India
count    30.000000
mean     123.623333
std       135.265600
min        8.500000
25%       23.550000
50%       64.900000
75%      178.600000
max      491.200000
```

$Q3 + 1.5 * IQR = 411.17499999999995$

Upper whisker (baffo superiore): 371.4

Box plot

```
df.set_index('Country', inplace=True)
country_name = "India"
country = df.loc[country_name, self.years]
country.plot(kind='box', figsize=(10, 6))
title = "Fatturato..."
plt.title(title)
plt.savefig(self.config.output_plot_box)
plt.show()
plt.close()
```



```
India
count    30.000000
mean     123.623333
std       135.265600
min        8.500000
25%       23.550000
50%       64.900000
75%      178.600000
max      491.200000
```

$Q3 + 1.5 * IQR = 411.17499999999995$

Upper whisker (baffo superiore): 371.4

	India
1995	8.5
1996	9.8
1997	11.3
1998	13.0
1999	14.9
2000	17.2
2001	19.7
2002	22.7
2003	26.1
2004	30.0
2005	34.5
2006	39.7
2007	45.6
2008	52.5
2009	60.4
2010	69.4
2011	79.8
2012	91.8
2013	105.6
2014	121.4
2015	139.6
2016	160.6
2017	184.6
2018	212.3
2019	244.2
2020	280.8
2021	323.0
2022	371.4
2023	427.1
2024	491.2



Box plot

```
df_top = df.sort_values(['Total'], ascending=False, axis=0).head(15)
df_first_dec = df_top.loc[:, self.first_decade].sum(axis=1)
df_second_dec = df_top.loc[:, self.second_decade].sum(axis=1)
df_third_dec = df_top.loc[:, self.third_decade].sum(axis=1)
new_df = pd.DataFrame({'95-04': df_first_dec,
                       '05-14': df_second_dec,
                       '15-24': df_third_dec})


new_df.plot(kind='box', figsize=(10, 6))
plt.savefig(self.config.output_plot_box)
plt.show()
plt.close()
```



Box plot

```
df_top = df.sort_values(['Total'], ascending=False, axis=0).head(15)
df_first_dec = df_top.loc[:, self.first_decade].sum(axis=1)
df_second_dec = df_top.loc[:, self.second_decade].sum(axis=1)
df_third_dec = df_top.loc[:, self.third_decade].sum(axis=1)
new_df = pd.DataFrame({'95-04': df_first_dec,
                       '05-14': df_second_dec,
                       '15-24': df_third_dec})


new_df.plot(kind='box', figsize=(10, 6))
plt.savefig(self.config.output_plot_box)
plt.show()
plt.close()
```



Box plot

```
df_top = df.sort_values(['Total'], ascending=False, axis=0).head(15)
df_first_dec = df_top.loc[:, self.first_decade].sum(axis=1)
df_second_dec = df_top.loc[:, self.second_decade].sum(axis=1)
df_third_dec = df_top.loc[:, self.third_decade].sum(axis=1)
new_df = pd.DataFrame({'95-04': df_first_dec,
                       '05-14': df_second_dec,
                       '15-24': df_third_dec})

new_df.plot(kind='box', figsize=(10, 6))
plt.savefig(self.config.output_plot_box)
plt.show()
plt.close()
```




Scatter plot

- Tipo di plot che mostra la relazione esistente tra coppie di variabili di gruppo/campione di dati
- Diagramma di dispersione
- Use case: dataset con diversi attributi descrittivi → visualizzazione dell'andamento di un attributo dipendente da uno indipendente (parametro di controllo); analisi della correlazione tra coppie di attributi indipendenti
- Esempi: differenze di andamenti/correlazioni in gruppi diversi (es. associati a diverse regioni geografiche o a diversi intervalli di tempo); interpretazione del risultato di un clustering



Scatter plot


```
df_tot = pd.DataFrame(df[self.years].sum(axis=0))
df_tot.reset_index(inplace = True)
df_tot.columns = ['year', 'total']
plt.figure(figsize=(10, 6))
plt.scatter(df_tot['year'], df_tot['total'], color='darkblue')
...
plt.savefig(self.config.output_plot_box)
plt.show()
plt.close()
```




API: `matplotlib.pyplot.scatter`

Scatter plot

```
N = 50
x = np.random.rand(N)
y = np.random.rand(N)
colors = np.random.rand(N)
area = (30 * np.random.rand(N)) ** 2
plt.scatter(x, y, s=area, c=colors, alpha=0.5)
plt.show()
```



Scatter plot




Scatter plot

Local custom function, check the code


```
df_tot = add_columns(df_tot) # to add "shift" and "employees" columns
plt.figure(figsize=(10, 6))
sns.scatterplot(data=df_tot, x="year", y="total",
                hue="shift", size="employees")

...
plt.savefig(self.config.output_plot_box)
plt.show()
plt.close()
```




API: `seaborn.scatterplot`


Scatter matrix




Avg Basket Size




Unique Products



Avg Price



Frequency



- **Segmento/cluster blu:** ~700 clienti, alta “Frequenza acquisto”, alta “Varietà prodotti” (ABITUALI, CURIOSI, APERTI)*
- **Segmento/cluster arancione:** ~600 clienti, alta “Dimensione carrello”, bassa “Frequenza acquisto”, basso “Prezzo medio”, bassa “Varietà prodotti” (ABITUALI, RISPARMIATORI, RIPETITIVI)°
- **Segmento/cluster verde:** ~1900 clienti, bassa “Frequenza acquisto”, basso “tutto” (OCCASIONALI)^
- **Segmento/cluster rosso:** ~600 customers, bassa “Dimensione carrello”, bassa “Varietà prodotti”, bassa “Frequenza acquisto”, alto “Prezzo medio” (TOP, PREMIUM, LUSO)#



* Es. Invio frequente di comunicazioni, buoni sconto, campioni gratuiti

° Es. Segnalare novità di assortimento prodotti d'interesse, offerte speciali per grosse spese

^ Es. Sconti su prodotti già acquistati, informazione su simili/altre categorie merceologiche

Es. Enfasi su qualità e valore, segnalazione assortimenti di “alta gamma”

RIFERIMENTI BIBLIOGRAFICI

- [click to pandas documentation](#)
- [click to matplotlib documentation](#)

