




Schema Concettuale Naive Bayes

Il classificatore Naive Bayes è un algoritmo di machine learning probabilistico che si basa sul teorema di Bayes. Questo schema illustra il flusso completo: dall'addestramento con i dati fino alla previsione finale, mostrando come il modello impara le probabilità e le utilizza per classificare nuovi esempi.



Il Modello Probabilistico


Probabilità delle Classi

$P(\text{Classe})$ rappresenta quanto è probabile che un esempio appartenga a ciascuna classe, basandosi sulla frequenza nel dataset di training.

Probabilità Condizionate


$P(\text{Feature} \mid \text{Classe})$ indica quanto è probabile osservare una certa caratteristica dato che l'esempio appartiene a una specifica classe.

Il modello addestrato memorizza queste due tipologie di probabilità, che costituiscono la sua "conoscenza" e verranno utilizzate nella fase di previsione per classificare nuovi esempi mai visti prima.



La Fase di Previsione

Quando il modello riceve un nuovo esempio da classificare, applica il teorema di Bayes per calcolare la probabilità che l'esempio appartenga a ciascuna classe disponibile.



La formula completa è: $P(\text{Classe} | \mathbf{x}) \propto P(\text{Classe}) \times P(f_1|\text{Classe}) \times P(f_2|\text{Classe}) \times \dots$ dove $f_1, f_2, \dots$ sono le caratteristiche del nuovo esempio.

Esempio 1: Classificare Frutta

Vediamo un esempio pratico e intuitivo: classificare frutti come **Mele** o **Banane** basandosi su due semplici caratteristiche visive.

Caratteristica: Colore

Può essere **rosso** o **giallo**

Caratteristica: Forma

Può essere **tonda** o **lunga**

Utilizzeremo 4 esempi di training per addestrare il nostro classificatore e capire come distinguere tra questi due tipi di frutta.



Calcolo delle Probabilità: Frutta

Probabilità delle Classi

Nel nostro dataset di 4 esempi:

- $P(\text{Mela}) = 2/4 = 0.5$
- $P(\text{Banana}) = 2/4 = 0.5$

Entrambe le classi sono equiprobabili nel training set.

Probabilità Condizionate

Per le Mele:

- $P(\text{rosso} \mid \text{mela}) = 1/2$
- $P(\text{giallo} \mid \text{mela}) = 1/2$
- $P(\text{tonda} \mid \text{mela}) = 2/2 = 1$
- $P(\text{lunga} \mid \text{mela}) = 0/2 = 0$



Per le Banane

- $P(\text{giallo} \mid \text{banana}) = 2/2 = 1$
- $P(\text{lunga} \mid \text{banana}) = 2/2 = 1$

Le banane nel nostro training sono sempre gialle e lunghe!



Previsione: Frutto Nuovo

Immaginiamo di avere un nuovo frutto da classificare con queste caratteristiche:

colore = giallo, forma = tonda

01

Calcolo per MELA

$$P(\text{mela} \mid x) \propto P(\text{mela}) \times P(\text{giallo} \mid \text{mela}) \\ \times P(\text{tonda} \mid \text{mela})$$

$$= 0.5 \times 0.5 \times 1 = \mathbf{0.25}$$

02

Calcolo per BANANA

$$P(\text{banana} \mid x) \propto P(\text{banana}) \times P(\text{giallo} \mid \text{banana}) \\ \times P(\text{tonda} \mid \text{banana})$$

$$= 0.5 \times 1 \times 0 = \mathbf{0}$$

03

Decisione Finale

$0.25 > 0 \rightarrow$ Il frutto è classificato come **MELA**

Anche se è giallo come le banane, la forma tonda è caratteristica distintiva delle mele nel nostro modello, rendendo impossibile che sia una banana (probabilità zero per forma tonda).

Esempio 2: Classificare Email

Un'applicazione pratica e comune del Naive Bayes è il filtraggio dello spam. Classifichiamo le email come **SPAM** o **NON SPAM** in base alle parole contenute.

1


Dataset di Training

Abbiamo 4 email etichettate con le parole chiave che contengono

2

Caratteristiche

Le parole presenti: "offerta", "gratis", "ciao", "riunione"



Probabilità nel Filtro Spam

Probabilità delle Classi	Parole nello Spam	Parole nel Non Spam
$P(\text{Spam}) = 2/4 = \mathbf{0.5}$	$P(\text{offerta} \mid \text{spam}) = 1/2$	$P(\text{ciao} \mid \text{nospam}) = 1/2$
$P(\text{NonSpam}) = 2/4 = \mathbf{0.5}$	$P(\text{gratis} \mid \text{spam}) = 1/2$	$P(\text{riunione} \mid \text{nospam}) = 1/2$
	$P(\text{ciao} \mid \text{spam}) = 0$	$P(\text{offerta} \mid \text{nospam}) = 0$
	$P(\text{riunione} \mid \text{spam}) = 0$	$P(\text{gratis} \mid \text{nospam}) = 0$

Notiamo come certe parole siano fortemente associate a una classe specifica: "offerta" e "gratis" compaiono solo nello spam, mentre "ciao" e "riunione" solo nelle email legittime.



Classificazione Email: Risultato

Arriva una nuova email contenente la parola **"offerta"**. Calcoliamo le probabilità:

Calcolo SPAM

$$P(\text{spam} \mid \text{offerta}) \propto P(\text{spam}) \times P(\text{offerta} \mid \text{spam})$$

$$= 0.5 \times (1/2) = \mathbf{0.25}$$

Calcolo NON SPAM

$$P(\text{nonsпам} \mid \text{offerta}) \propto P(\text{nonsпам}) \times P(\text{offerta} \mid \text{nonsпам})$$

$$= 0.5 \times 0 = \mathbf{0}$$

✓ Verdetto Finale

L'email è classificata come **SPAM** con alta confidenza

La parola "offerta" non è mai apparsa nelle email legittime del training, rendendo la probabilità zero per la classe Non Spam.



Esempio 3: Classificare Fiori

Esploriamo un esempio più articolato: classificare tre tipi di fiori usando caratteristiche visive semplici ma distintive.



Rosa

Fiore elegante e profumato, simbolo di amore e passione



Girasole

Fiore luminoso che segue il sole con i suoi petali dorati



Margherita

Fiore delicato e semplice, simbolo di purezza

1

Colore

Può essere: **rosso**, **giallo**, o **bianco**


2

Forma del Petalo

Può essere: **tonda** o allungata

Dataset dei Fiori


Ecco i nostri 6 esempi di training con le caratteristiche osservate per ciascun fiore:



Colore	Forma	Classe
Rosso	Tonda	🌹 Rosa
Bianco	Tonda	🌻 Margherita
Giallo	Allungata	🌻 Girasole
Giallo	Tonda	🌻 Margherita
Rosso	Tonda	🌹 Rosa
Giallo	Allungata	🌻 Girasole


Il dataset è perfettamente bilanciato con 2 esempi per ogni classe di fiore.

Probabilità delle Classi: Fiori




Rosa

$P(\text{Rosa}) = 2/6$



Margherita

$P(\text{Margherita}) = 2/6$



Girasole

$P(\text{Girasole}) = 2/6$

Tutte e tre le classi hanno la stessa probabilità iniziale di **0.333**, essendo rappresentate in modo uguale nel dataset di training.



Probabilità Condizionate: Rosa

Analizziamo le caratteristiche specifiche della classe **Rosa** 🌹

Esempi di Rose

Colore	Forma
Rosso	Tonda
Rosso	Tonda

Probabilità Calcolate

Per il Colore:

- $P(\text{rosso} \mid \text{rosa}) = 2/2 = 1$
- $P(\text{giallo} \mid \text{rosa}) = 0/2 = 0$
- $P(\text{bianco} \mid \text{rosa}) = 0/2 = 0$

Per la Forma:

- $P(\text{tonda} \mid \text{rosa}) = 2/2 = 1$
- $P(\text{allungata} \mid \text{rosa}) = 0/2 = 0$

- ☐ Nel nostro training set, le rose sono **sempre** rosse e hanno petali tondi. Questo crea probabilità deterministiche (0 o 1) che rendono la classificazione molto netta.

Probabilità Condizionate: Margherita

Analizziamo le caratteristiche specifiche della classe **Margherita** 🌻

Esempi di Margherite

Colore	Forma
Bianco	Tonda
Giallo	Tonda

Probabilità Calcolate

Per il Colore:

- $P(\text{bianco} \mid \text{margherita}) = 1/2 = \mathbf{0.5}$
- $P(\text{giallo} \mid \text{margherita}) = 1/2 = \mathbf{0.5}$
- $P(\text{rosso} \mid \text{margherita}) = \mathbf{0}$

Per la Forma:

- $P(\text{tonda} \mid \text{margherita}) = 2/2 = \mathbf{1}$
- $P(\text{allungata} \mid \text{margherita}) = \mathbf{0}$

- ❏ Nel nostro training set, le margherite sono sempre tonde, ma possono essere sia bianche che gialle. La probabilità di trovare una margherita con forma allungata è zero.

Probabilità Condizionate: Girasole

Analizziamo le caratteristiche specifiche della classe **Girasole** 

Esempi di Girasoli

Colore	Forma
Giallo	Allungata
Giallo	Allungata

Probabilità Calcolate

Per il Colore:

- $P(\text{giallo} \mid \text{girasole}) = 2/2 = 1$
- $P(\text{rosso} \mid \text{girasole}) = 0$
- $P(\text{bianco} \mid \text{girasole}) = 0$

Per la Forma:

- $P(\text{allungata} \mid \text{girasole}) = 2/2 = 1$
- $P(\text{tonda} \mid \text{girasole}) = 0$

☐ Nel nostro training set, i girasoli sono **sempre** gialli e hanno petali allungati. Questo crea probabilità deterministiche (0 o 1) che rendono la classificazione molto netta.



Previsione: Nuovo Fiore

Immaginiamo di avere un nuovo fiore da classificare con queste caratteristiche: colore = giallo, forma = tonda

01

Calcolo per ROSA

$$\begin{aligned} P(\text{rosa} \mid x) &\propto P(\text{rosa}) \times P(\text{giallo} \mid \text{rosa}) \times \\ &P(\text{tonda} \mid \text{rosa}) \\ &= (2/6) \times 0 \times 1 = \mathbf{0} \end{aligned}$$

02

Calcolo per MARGHERITA

$$\begin{aligned} P(\text{margherita} \mid x) &\propto P(\text{margherita}) \times P(\text{giallo} \mid \\ &\text{margherita}) \times P(\text{tonda} \mid \text{margherita}) \\ &= (2/6) \times 0.5 \times 1 = \mathbf{0.167} \end{aligned}$$

03

Calcolo per GIRASOLE

$$\begin{aligned} P(\text{girasole} \mid x) &\propto P(\text{girasole}) \times P(\text{giallo} \mid \text{girasole}) \times P(\text{tonda} \mid \text{girasole}) \\ &= (2/6) \times 1 \times 0 = \mathbf{0} \end{aligned}$$

Decisione Finale

Il fiore è classificato come **MARGHERITA** 🌻

È l'unica classe con probabilità non nulla! Anche se i girasoli sono sempre gialli, la forma tonda esclude questa possibilità.