

✓ Premessa al Teorema del limite centrale

Prima di illustrare il teorema del limite centrale, daremo una idea intuitiva di un altro fondamentale teorema della probabilità: **la legge dei grandi numeri**.

La Legge dei Grandi Numeri

La **legge dei grandi numeri**, nota anche come **teorema di Bernoulli** descrive il comportamento della media di una sequenza di prove di una variabile casuale che siano:

- **Indipendenti** tra loro;
- caratterizzate dalla **stessa distribuzione di probabilità**

In generale si è soliti usare la terminologia **indipendenti e identicamente distribuite (i.i.d.)**.

La legge dei grandi numeri si concentra sull'analisi è l'evoluzione di tale media al tendere a infinito della numerosità della sequenza stessa.

Il concetto intuitivo è che secondo questa legge, è ragionevolmente sicuro che la media determinata da un numero sufficiente di campioni sia **sufficientemente vicina alla media vera** (ovvero quella calcolabile teoricamente).

Il significato di "ragionevolmente sicuro" dipende dal grado di precisione desiderato che dipende dal numero n delle prove.

Per esempio si osserva che:

- **10 prove:** forniscono una stima grossolana.
- **100 prove:** forniscono una stima molto più precisa.
- **1000 prove:** aumentano ulteriormente l'accuratezza.

In sintesi, il valore di necessario dipende dal livello di casualità che si è disposti ad accettare per il dato analizzato.

Sintesi della legge

Si può affermare che:

1. La media della sequenza è un'**approssimazione della media della distribuzione**, che migliora costantemente al crescere di n .
2. Si può prevedere che tali sequenze mostreranno una media tanto più spesso, e tanto più precisamente, prossima alla media della distribuzione quanto più grande sarà il valore di n .

Della legge dei grandi numeri esistono due versioni: versione debole e forte.

Versione debole e versione forte

La **Legge dei Grandi Numeri** è uno dei pilastri della teoria della probabilità. Formalizza matematicamente un'idea intuitiva molto importante:

Ripetendo molte volte un esperimento casuale, la media dei risultati osservati tende a stabilizzarsi intorno al valore medio teorico.

La LGN esiste in due forme principali:

- **Legge dei Grandi Numeri debole**
- **Legge dei Grandi Numeri forte**

Le due versioni differiscono per il **tipo di convergenza** garantita.

Sia $X_1, X_2, \dots$ una successione di variabili casuali:

- indipendenti
- identicamente distribuite (i.i.d.)
- con media finita $\mathbb{E}[X_i] = \mu$

Definiamo la **media campionaria**: $\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$

L'obiettivo è studiare il comportamento di $\bar{X}_n$ quando n cresce.

Legge dei Grandi Numeri Debole (LGN debole)

Enunciato

Se $X_1, X_2, \dots$ sono i.i.d. e

$$\mathbb{E}[X_i] = \mu, \quad \text{Var}(X_i) < \infty$$

allora:

$$\bar{X}_n \xrightarrow{P} \mu \quad \text{per } n \rightarrow \infty$$

cioè la media campionaria **converge in probabilità** alla media teorica.

Significato della convergenza in probabilità

La convergenza in probabilità significa che:

$$\forall \varepsilon > 0, \quad \mathbb{P}(|\bar{X}_n - \mu| > \varepsilon) \rightarrow 0$$

Interpretazione:

- la probabilità di osservare una deviazione significativa dalla media vera diventa sempre più piccola
- non si esclude che, per qualche (n) , la media sia lontana da (μ)

Interpretazione intuitiva

- Ogni osservazione è rumorosa
- Sommando molte osservazioni:
 - gli errori casuali tendono a compensarsi
- la media empirica diventa sempre più affidabile

Limiti della LGN debole

La LGN debole:

- non garantisce che la convergenza avvenga **per ogni sequenza realizzata**
- non esclude oscillazioni occasionali anche per (n) grandi
- fornisce una convergenza “statistica”, non “puntuale”

Per un risultato più forte serve una nozione di convergenza più robusta.

Legge dei Grandi Numeri Forte (LGN forte)

Enunciato

Se $X_1, X_2, \dots$ sono i.i.d. e

$$\mathbb{E}[X_i] = \mu$$

(all’atto pratico, con opportune ipotesi di integrabilità)

allora:

$$\bar{X}_n \xrightarrow{q.c.} \mu \quad \text{per } n \rightarrow \infty$$

cioè la media campionaria **converge quasi certamente** alla media teorica.

Significato della convergenza quasi certa

La convergenza quasi certa significa che:

$$\mathbb{P}\left(\lim_{n \rightarrow \infty} \bar{X}_n = \mu\right) = 1$$

Interpretazione:

- fissata una sequenza di risultati dell’esperimento,
- **con probabilità 1** la media converge a (μ)
- le oscillazioni persistenti sono eventi di probabilità nulla

Nota BENE:

La LGN forte **implica** la LGN debole, ma non viceversa.

Interpretazione pratica

- **LGN debole** È sufficiente per molte applicazioni statistiche
- **LGN forte** Giustifica l’idea che “ripetendo l’esperimento abbastanza a lungo, la media si stabilizza definitivamente”

In pratica, la LGN forte formalizza l’intuizione sperimentale quotidiana.

Esempio classico: lanci di una moneta

Sia

$$X_i = \begin{cases} 1 & \text{testa} \\ 0 & \text{croce} \end{cases} \quad \text{con } p = P(\text{testa})$$

Allora:

$$\bar{X}_n = \frac{\text{numero di teste}}{n}$$

- LGN debole: la frequenza relativa è **probabilisticamente vicina** a p
- LGN forte: la frequenza relativa **converge quasi certamente** a p

Relazione con la statistica

La Legge dei Grandi Numeri giustifica:

- l'uso della media campionaria come stimatore
- la coerenza degli stimatori
- l'idea di "ripetibilità" degli esperimenti

È il fondamento teorico dell'**inferenza statistica**.

In sintesi:

Entrambe le formulazioni della legge dei grandi numeri descrivono il comportamento asintotico della media campionaria. Però:

- La **LGN debole** garantisce convergenza in probabilità.
- La **LGN forte** garantisce convergenza quasi certa.
- La versione forte è più potente e più informativa

N.B finale:

- La LGN dice **dove** converge la media, non **come** fluttua (a questa domanda risponderà vederemo il teorema del limite centrale)

```
import numpy as np
import matplotlib.pyplot as plt

# Metto seed per rendere l'esperimento riproducibile
np.random.seed(42)

# stabilisco numero totale di lanci
N = 10000


# Lancio del dado (valori 1,2,3,4,5,6)
# uso numpy perché crea vettore di numeri casuali uniformi
# nota: vedi la libreria cosa dice di randint:
# https://numpy.org/devdocs/reference/random/generated/numpy.random.randint.html

lanci = np.random.randint(1, 7, size=N)

# Media campionaria progressiva
medie = np.cumsum(lanci) / np.arange(1, N + 1)

# Valore atteso teorico del dado
media_teorica = 3.5 # (1+2+3+4+5+6)/6

# =====
# Grafico: Legge dei Grandi Numeri
# =====
plt.figure()
plt.plot(np.arange(1, N + 1), medie, label="Media campionaria")
plt.axhline(media_teorica, linestyle="--", label="Media teorica = 3.5")
plt.xlabel("Numero di lanci")
plt.ylabel("Media")
plt.title("Legge dei Grandi Numeri - Lancio di un dado")
plt.legend()
plt.show()
```



Dalla Legge dei Grandi Numeri al Teorema del Limite Centrale

Appurata la legge dei grandi numeri, una possibile domanda successiva potrebbe essere:

Se la media converge a μ , come oscillano i valori di $\bar{X}_n$ attorno a μ ?

Osserviamo che:

$$\bar{X}_n - \mu \rightarrow 0$$

ma non sappiamo **con quale distribuzione**.

Il teorema del limite centrale "risponde" a questa domanda.

Il Teorema del limite centrale

Il teorema del limite centrale (o, in inglese, Central Limit Theorem (CLT)) è uno dei risultati più importanti del calcolo delle probabilità e fondamentali sono le sue applicazioni in statistica

In termini semplicistici esso afferma che la somma di un gran numero di variabili aleatorie tutte con la stessa distribuzione tende ad avere una distribuzione normale.

L'importanza di ciò sta nel fatto che siamo in grado di **ottenere stime** della probabilità che riguardano la **somma di variabili aleatorie indipendenti ed identicamente distribuite (i.i.d.)**, a prescindere da quale sia la distribuzione di ciascuna.

Il **Teorema del Limite Centrale (TLC)** "spiega" perché la **distribuzione normale** compare così spesso in natura, nei dati sperimentali e nelle applicazioni statistiche, anche quando le variabili di partenza **non sono normali**.

Un altro modo di vedere le cose:

La somma (o la media) di molte variabili casuali indipendenti tende a comportarsi come una variabile normale.

Enunciato del Teorema del Limite Centrale

Sia

$$X_1, X_2, \dots, X_n$$

una successione di **variabili casuali indipendenti e identicamente distribuite (i.i.d.)** tali che:

- $\mathbb{E}[X_i] = \mu$
- $\text{Var}(X_i) = \sigma^2 < \infty$

Definiamo la **media campionaria**:

$$\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$$

Ricordando che la **varianza della media campionaria** è

$$\text{Var}(\bar{X}_n) = \frac{\sigma^2}{n}$$

Poiché se le variabili sono indipendenti abbiamo che **Varianza di una somma** è:

$$\text{Var} \left(\sum_{i=1}^n X_i \right) = \sum_{i=1}^n \text{Var}(X_i) = n\sigma^2$$

e che

$$\text{Var} \left(\frac{1}{n} \sum_{i=1}^n X_i \right) = \frac{1}{n^2} \sum_{i=1}^n \text{Var}(X_i) = \frac{1}{n^2} n\sigma^2 = \frac{1}{n} \sigma^2$$

Allora vale:

$$\frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}} \xrightarrow{d} \mathcal{N}(0, 1) \quad \text{per } n \rightarrow \infty$$

cioè la media campionaria, opportunamente standardizzata, **converge in distribuzione a una normale standard**.

Possibile interpretazione intuitiva

- Ogni variabile X_i contribuisce con una piccola parte
- Le fluttuazioni casuali tendono a **compensarsi**
- Il risultato complessivo assume una forma **simmetrica e concentrata**
- La distribuzione limite è la **normale**

La normalità può essere vista come una sorta di **effetto collettivo**, non come proprietà dei singoli dati.

Altro modo di "vedere" CLT: somma invece della media

Consideriamo la somma di n variabili aleatorie i.i.d.:

$$S_n = X_1 + X_2 + \dots + X_n$$

Allora:

- $\mathbb{E}[S_n] = n\mu$
- $\text{Var}(S_n) = n\sigma^2$

La versione standardizzata è:

$$\frac{S_n - n\mu}{\sigma\sqrt{n}} \xrightarrow{d} \mathcal{N}(0, 1)$$

Cosa **non** richiede il TLC

Il TLC **non richiede** che le X_i :

- siano normali
- siano simmetriche
- abbiano una distribuzione particolare

È sufficiente che:

- siano indipendenti
- abbiano **media finita**
- abbiano **varianza finita**

Cosa succede se le ipotesi non valgono

- **Varianza infinita** il TLC classico non vale (non le abbiamo viste questa tipologia di distribuzioni ma esistono)
- **Dipendenza forte** la convergenza può fallire
- **Campioni piccoli** l'approssimazione normale può essere scadente

Velocità di convergenza

In pratica:

- per distribuzioni simmetriche $\rightarrow$ bastano anche ($n \approx 20$)
- per distribuzioni asimmetriche $\rightarrow$ servono ($n \geq 30$) o più
- per code pesanti $\rightarrow$ convergenza lenta

Regola pratica:

($n \geq 30$) è spesso sufficiente, ma dipende dalla distribuzione di partenza.

Esempi classici

Variabili Bernoulliane

$$X_i \sim \text{Bernoulli}(p)$$

La media campionaria converge a:

$$\mathcal{N}\left(p, \frac{p(1-p)}{n}\right)$$


Questo giustifica l'approssimazione normale della binomiale.

Variabili Uniformi

$$X_i \sim \text{Uniforme}(0, 1)$$

La media tende a una normale, anche se la distribuzione iniziale è piatta.

Video divulgativo che spiega con il pallinometro idea intuitiva del teorema del limite centrale.



```
# Simulazione esperimento pallinometro

import numpy as np
import matplotlib.pyplot as plt
import scipy.stats as st
import random

print("Ciao")

def simulate_galton_board(rows, columns, balls):
    positions = [0]*columns #np.zeros(columns, dtype=int)

    for _ in range(balls):
        position = columns//2 # parto dalla posizione a metà
        for row in range(rows):
            #print(position)
            direction = random.choice([-1, 1])
            #print(direction, position)
            position += direction
            #print(position)
            positions[position] += 1
            #print(positions)

    return positions

num_rows = 16
num_columns = 33
num_balls = 10000
final_positions = simulate_galton_board(num_rows, num_columns, num_balls)
#print(final_positions)
print(len(final_positions))
#print(sum(final_positions))

plt.bar(range(num_columns), final_positions)
#plt.xlabel('Column Number')
#plt.ylabel('Number of Balls')
#plt.title('Pallinometro (Galton Board) e Teorema del limite centrale')
plt.grid(True)
```

```
print(final_positions)
results= [x for x in final_positions if x != 0]
print(results)
```



```
plt.figure(2)
plt.bar(range(len(results)),results)
```

Ciao

33

```
[0, 0, 2, 0, 21, 0, 95, 0, 253, 0, 648, 0, 1246, 0, 1728, 0, 1976, 0, 1741, 0, 1178, 0, 686, 0, 304, 0, 99, 0, 20, 0, 3, 0,
[2, 21, 95, 253, 648, 1246, 1728, 1976, 1741, 1178, 686, 304, 99, 20, 3]
```

<BarContainer object of 15 artists>



```
# nota: conservazione parità dei passi
# cosa succede se ho un numero pari o dispari di righe?
import random
passi = [random.choice([-1, 1]) for _ in range(16)]
print(passi)
print(sum(passi))
```

```
passi = [random.choice([-1, 1]) for _ in range(15)]
print(passi)
print(sum(passi))
```

```
passi = [random.choice([-1, 1]) for _ in range(17)]
print(passi)
print(sum(passi))
```

```
[1, -1, -1, -1, -1, -1, 1, -1, -1, 1, -1, 1, 1, -1, -1]
-6
[-1, -1, 1, 1, 1, 1, -1, -1, -1, -1, -1, 1, -1, 1, 1]
-1
[-1, -1, 1, 1, -1, -1, 1, -1, 1, 1, 1, -1, -1, 1, -1, 1, 1]
1
```

✓ Altra idea: simulazione con i dadi

Si veda: <https://journals.aboutscience.eu/index.php/gcnd/article/download/922/839/1665>

Esecizio in classe: scrivi in classe il codice che ripete l'esperimento del lancio di 1,2,3,...n dadi e somma i risultati fra loro.

Che cosa osservi?

```
# esempio codice Chiara

import numpy as np
import matplotlib.pyplot as plt

numero_lanci = 10000


risultati_dati1 = np.random.randint(1,7,size=numero_lanci)
risultati_dati2 = np.random.randint(1,7,size=numero_lanci)
risultati_dati3 = np.random.randint(1,7,size=numero_lanci)

somma_risultati = risultati_dati1 + risultati_dati2 + risultati_dati3

# 2. Contiamo le frequenze di ogni faccia
# unique restituisce i valori unici (1,2,3,4,5,6) e quante volte appaiono, con return_counts=True ci dice appunto quante volte
facce,frequenze = np.unique(somma_risultati, return_counts=True)

plt.figure()
plt.bar(facce,frequenze)
plt.xlabel('Risultati della somma del lancio dei dadi (caso 3 dadi)')
plt.ylabel('Quante volte sono usciti')
plt.show()

## DOMANDA FINALE: come si potrebbe generalizzare il risultato?
```



```
# lancio un dado

import random

numero_simulazioni= 100

list_dado= [random.randint(1,6) for x in range(numero_simulazioni)]

print(list_dado)

list_dado1= [random.randint(1,6) for x in range(numero_simulazioni)]
list_dado2= [random.randint(1,6) for x in range(numero_simulazioni)]

somma_dadi=list_dado1+list_dado2

print(somma_dadi)
```

```
[1, 2, 2, 4, 6, 4, 5, 3, 6, 5, 2, 3, 5, 2, 6, 1, 4, 2, 2, 5, 2, 4, 3, 5, 6, 5, 2, 3, 2, 1, 5, 6, 6, 1, 2, 3, 5, 4, 5, 3, 2,
[5, 1, 6, 3, 2, 5, 5, 3, 3, 1, 1, 4, 3, 3, 1, 2, 5, 5, 1, 1, 6, 6, 6, 3, 2, 3, 5, 6, 6, 6, 2, 4, 2, 5, 1, 6, 5, 2, 5, 6, 5,
```

```
import numpy as np
import matplotlib.pyplot as plt
from scipy.stats import norm
import scipy.stats as st

# 1. Parametri della simulazione
n_campioni = 30 # Quanti numeri sommiamo ogni volta (n)
n_simulazioni = 1000 # Quante volte ripetiamo l'esperimento

# 2. Generazione dei dati
# Creiamo una matrice (n_simulazioni x n_campioni) di numeri casuali tra 0 e 1
dati_uniformi = np.random.uniform(0, 1, (n_simulazioni, n_campioni))
#print(f"Dati simulati: {dati_uniformi} con {n_simulazioni}")
print(f"Dimensioni variabile è {len(dati_uniformi)}")

# Calcoliamo la media per ogni riga (cioè la media di n numeri uniformi)
medie = np.mean(dati_uniformi, axis=1)
# N.B per esame: vedi significato axis=1 e axis=0


# 3. Visualizzazione
plt.figure(figsize=(10, 6))

# Istogramma delle medie calcolate
count, bins, ignored = plt.hist(medie, bins=50, density=True,
                                color='skyblue', edgecolor='white', alpha=0.7,
                                label='Distribuzione delle medie')

# 4. Sovrapponiamo la curva Normale teorica per confronto
mu_teorica = 0.5
sigma_teorica = np.sqrt(1 / (12 * n_campioni)) # Deviazione standard teorica
x = np.linspace(0, 1, 100) # genero un vettore da 0 a 1 lungo 100
plt.plot(x, st.norm.pdf(x, mu_teorica, sigma_teorica),
         color='red', lw=3, label='Normale Teorica (Campana)')

# Dettagli del grafico
plt.title(f'TLC: Media di {n_campioni} variabili Uniformi ({n_simulazioni} simulazioni)')
plt.xlabel('Valore della media')
plt.ylabel('Densità di probabilità')
plt.legend()
plt.grid(axis='y', alpha=0.3)
plt.show()
```

Dimensioni variabile è 1000



il Teorema del Limite Centrale (TLC) usando una variabile binomiale.

L'idea è questa:

- parto da una Binomiale $\text{Bin}(n, p)$
- considero **molte repliche**
- standardizzo la variabile
- mostro che la distribuzione tende a una **Normale standard**

1. Richiamo teorico (in breve)

Se

$$X \sim \text{Bin}(n, p)$$

allora:

- media: $\mu = np$
- varianza: $\sigma^2 = np(1 - p)$

Il TLC dice che la variabile standardizzata

$$Z = \frac{X - np}{\sqrt{np(1-p)}}$$

converge in distribuzione a una Normale standard $\mathcal{N}(0, 1)$ per $n \rightarrow \infty$.

```
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns

# alternativa
import scipy.stats as st

# Parametri della distribuzione binomiale
n_prove = 100 # Numero di prove per ogni campione (es. 100 lanci di una moneta)
p_successo = 0.3 # Probabilità di successo (es. 30% di successo)
n_campioni = 10000 # Numero di campioni da estrarre

# 1. Generare i campioni
# Ogni elemento nel risultato sarà il numero di successi in n_prove, per ciascuno dei n_campioni
risultati_campioni = np.random.binomial(n=n_prove, p=p_successo, size=n_campioni)

# Opppure: Generazione dei campioni
risultati_campioni = st.binom.rvs(n=n_prove, p=p_successo, size=n_campioni)

# 2. Calcolare la media di ogni campione (anche se qui stiamo facendo una simulazione diretta
# delle distribuzioni, la logica del TLC è su un altro livello di campionamento, vediamo qui l'istogramma
# della distribuzione binomiale stessa, che sarà approssimativamente normale)
# Per vedere il TLC: si campiona *da* questa distribuzione tante volte
# oppure si campionano N volte *da* una binomiale, e si fa l'istogramma delle medie.
# Esempio:
medie_campioni = []
n_campioni_per_TLC = 10000 # Quante volte calcoliamo la media
dimensione_campione_TLC = 30 # Grandezza di ogni singolo "micro-campione"

for _ in range(n_campioni_per_TLC):
    # Estraiamo un campione di dimensione 'dimensione_campione_TLC' dalla nostra binomiale
    campione = np.random.binomial(n=n_prove, p=p_successo, size=dimensione_campione_TLC)
    medie_campioni.append(np.mean(campione))


# 3. Visualizzare
plt.figure(figsize=(12, 5))

# Istogramma della distribuzione binomiale (per n=100, p=0.3)
plt.subplot(1, 2, 1)
sns.histplot(risultati_campioni, bins=20, kde=True, color='skyblue')
plt.title(f'Distribuzione Binomiale (n={n_prove}, p={p_successo})')
plt.xlabel('Numero di Successi')
plt.ylabel('Frequenza')

# Istogramma delle medie (per il TLC
```

Text(0, 0.5, 'Frequenza')

Distribuzione Binomiale (n=100, p=0.3)



Inizia a programmare o [genera](#) codice con l'IA.

▼ Esempio a partire dai dati

Le mance del dataset 'tips'. In questo esercizio di esempio partiamo dai dati.

Esempio tratto da qui: <https://github.com/lorisliusso/Python-Statistics/blob/master/Central%20Limit%20Theorem.ipynb>

```
# --- Data Manipulation ---
import numpy as np
import pandas as pd

# --- Data Visualization ---
import seaborn as sns
import matplotlib.pyplot as plt

# --- Maths ---
import math
import scipy.stats as stats

tips_df = sns.load_dataset('tips')
tips_df
```


	total_bill	tip	sex	smoker	day	time	size	
0	16.99	1.01	Female	No	Sun	Dinner	2	
1	10.34	1.66	Male	No	Sun	Dinner	3	
2	21.01	3.50	Male	No	Sun	Dinner	3	
3	23.68	3.31	Male	No	Sun	Dinner	2	
4	24.59	3.61	Female	No	Sun	Dinner	4	
...	...	...	...	...	...	...	...	
239	29.03	5.92	Male	No	Sat	Dinner	3	
240	27.18	2.00	Female	Yes	Sat	Dinner	2	
241	22.67	2.00	Male	Yes	Sat	Dinner	2	
242	17.82	1.75	Male	No	Sat	Dinner	2	
243	18.78	3.00	Female	No	Thur	Dinner	2	

244 rows × 7 columns

Passaggi successivi: [Genera codice con tips_df](#) [New interactive sheet](#)


```
sns.histplot(tips_df['tip'], kde=True, bins = 20)
# kde= Kernel Density estimation
# kde non è strattamente necessaria
```

<Axes: xlabel='tip', ylabel='Count'>



```
# metodo alternativo
tips_df['tip'].hist()
print(type(tips_df['tip']))
```

<class 'pandas.core.series.Series'>



```
mu = tips_df['tip'].mean() #media delle tips

print('Mean:', mu)

sd = tips_df['tip'].std() #deviazione standard delle tips

print('Standard Deviation:', sd)

#skewness = 'right' #asimmetria a destra in questo caso

#print('Skewness:', skewness) #asimmetria a destra in questo caso
```

```
Mean: 2.99827868852459
Standard Deviation: 1.3836381890011826
```

```
tips_df.tip.describe() #statistics summary
#tips_df['tip'].describe()
```

```

      tip
count  244.000000
mean    2.998279
std     1.383638
min     1.000000
25%     2.000000
50%     2.900000
75%     3.562500
max     10.000000

```

dtype: float64

```


n = 30 # CLT applies mostly with n>=30
N = 100

means = [tips_df.tip.sample(n, replace=True).mean() for i in range(N)]

sns.histplot(means, bins=20, kde=True)

```

<Axes: ylabel='Count'>



```

from scipy.stats import skew

index_df = ['mean', 'stdev', 'skewness']

theory = [mu, sd/np.sqrt(n), 0]

real_life = [np.mean(means), np.std(means), skew(means)]

comparison_df = pd.DataFrame(list(zip(theory, real_life)),
                              columns = ["CLT Theory", "Real Tips"],
                              index = index_df)

round(comparison_df, 2)

```

	CLT Theory	Real Tips
mean	3.00	3.07
stdev	0.25	0.23
skewness	0.00	0.24

✓ Approssimazione della binomiale grazie al CLT

Nel seguente codice python mostriamo un esempio di approssimazione nel continuo di una distribuzione binomiale con una gaussiana.

Esempio problema di partenza:

Calcolare la probabilità di ottenere fra 36 a 45 successi lanciando 100 volte una monete.

$$P(36 \leq x \leq 45)$$

E' necessario usare l'approssimazione al continuo. Avendo $\leq$ dovrò considerare l'intervallo che va da $36 - 0.5$ a $45 + 0.5$. E' il modo "nel continuo" per simulare una distribuzione binomiale discreta che non ha, per esempio, fra 35 e 36 nessun evento intermedio. Viene fatta quella che viene chiamata la correzione di continuità.

```
import math
import scipy.stats as stats
p = 0.5
n = 100
lo = 36
hi = 45
# true probability via the binomial distribution
binomial = stats.binom(n, p)
bin = binomial.pmf(range(lo, hi+1))
true = bin.sum()
# approximation via the Central Limit Theorem
m = p * n # mean
s = math.sqrt(p * (1 - p) * n) # standard error
z0 = (lo - 0.5 - m) / s # correzione di continuità
z1 = (hi + 0.5 - m) / s
appr = stats.norm.cdf(z1) - stats.norm.cdf(z0)
# printout
print(f"probability of heads = {p}")
print(f"number of tosses = {n}")
print(f"probability of heads between {lo} and {hi}:")
print(f"true = {true}, approximate via CLT = {appr}")

probability of heads = 0.5
number of tosses = 100
probability of heads between 36 and 45:
true = 0.1823419878018629, approximate via CLT = 0.18219431204637543
```

✓ Approssimazione nel continuo della distribuzione binomiale

Ricordiamo che la distribuzione **binomiale** è una distribuzione **discreta** che descrive il numero di successi in una sequenza di prove di Bernoulli indipendenti:

$$X \sim \text{Bin}(n, p)$$

dove:

- n è il numero di prove
- p è la probabilità di successo
- $X \in 0, 1, \dots, n$

In molti contesti applicativi (statistica inferenziale, fisica, finanza, scienze naturali) si lavora però con **variabili continue**.

Nasce quindi l'esigenza di **approssimare la binomiale con distribuzioni continue**, quando n è grande.

2. Motivazione dell'approssimazione

Quando n cresce:

- il numero di valori possibili di X aumenta
- la distanza tra due valori consecutivi diventa trascurabile rispetto alla scala del problema
- la distribuzione assume una forma sempre più "liscia"

In questi casi:

- il carattere discreto diventa secondario
- una distribuzione continua fornisce una buona approssimazione

Questa idea è alla base del **Teorema del Limite Centrale (TLC)**.

Ripassiamo le caratteristiche fondamentali: Media e varianza della binomiale

Per una variabile binomiale:

$$\begin{aligned}\mathbb{E}[X] &= np \\ \text{Var}(X) &= np(1 - p)\end{aligned}$$

Questi due parametri saranno centrali nelle approssimazioni continue.

Vediamo come approssimare: TLC e correzione di continuità

Per n grande, la distribuzione binomiale può essere approssimata da una **normale**:

$$X \sim \text{Bin}(n, p) \approx \mathcal{N}(np, np(1-p))$$

Questa approssimazione deriva direttamente dal **Teorema del Limite Centrale**, poiché la binomiale è la somma di n variabili di Bernoulli indipendenti.

Una regola empirica molto usata è:

$$np \geq 5 \quad \text{e} \quad n(1-p) \geq 5$$

Queste condizioni garantiscono condizioni di utilizzo di questa approssimazione.

Correzione di continuità

Poiché la binomiale è una distribuzione discreta mentre la normale è una distribuzione continua, è necessario tenere conto del fatto che per avere una approssimazione migliore si introduce la cosiddetta **correzione di continuità**.

Esempio

Se si deve calcolare:

$$P(X = k)$$

si usa:

$$P(k - 0.5 \leq Y \leq k + 0.5) \quad \text{con} \quad Y \sim \mathcal{N}(np, np(1-p))$$

La correzione di continuità è fondamentale per ottenere risultati accurati.

Legame con il Teorema del Limite Centrale

La binomiale può essere scritta come:

$$X = \sum_{i=1}^n B_i$$

dove B_i sono Bernoulli indipendenti. Il TLC afferma che la variabile standardizzata:

$$Z = \frac{X - np}{\sqrt{np(1-p)}}$$

converge in distribuzione a una normale standard:

$$Z \Rightarrow \mathcal{N}(0, 1)$$

Questa è la giustificazione teorica rigorosa dell'approssimazione continua.

Limiti dell'approssimazione

L'approssimazione normale **non è sempre appropriata**:

- n piccolo
- p molto vicino a 0 o 1
- distribuzione fortemente asimmetrica

In questi casi:

- usare la binomiale esatta
- oppure la Poisson

```
# Memo codice per grafico a stelo della Binomiale
# al variare di p puoi vedere come "cambia" il grafico.
# con p=0.5 hai un grafico simmetrico
# con p=0.2 uno molto asimmetrico

import numpy as np
import matplotlib.pyplot as plt
from scipy.stats import binom


# Parametri della binomiale
n = 10
p = 0.2

# Valori possibili della variabile casuale
x = np.arange(0, n + 1)

# Probabilità P(X = k)
pmf = binom.pmf(x, n, p)
```

```
# stem plot
plt.stem(x, pmf, basefmt=" ") #basefmt=" " toglie riga rossa
plt.xlabel("k")
plt.ylabel("P(X = k)")
plt.title("Distribuzione binomiale (n=10, p=0.2)")
plt.grid(True)

plt.show()
```



```
# altro esempio
# mostro istogrammi che fanno vedere che la distribuzione
# binomiale è non simmetrica
# con p=0.2, 0.3 e 0.5

import numpy as np
import matplotlib.pyplot as plt
from scipy.stats import binom

# Parametri
n = 10
p = 0.2
N = 10000 # numero di simulazioni

# Campionamento dalla binomiale
samples = binom.rvs(n, p, size=N)

# Istogramma
plt.hist(samples, bins=np.arange(-0.5, n + 1.5, 1), density=True)
plt.xlabel("k")
plt.ylabel("Frequenza relativa")
plt.title("Istogramma della Binomiale (n=10, p=0.2)")
plt.grid(True)

n = 10
p = 0.3
N = 10000 # numero di simulazioni


# Campionamento dalla binomiale
samples = binom.rvs(n, p, size=N)

# Istogramma
plt.hist(samples, bins=np.arange(-0.5, n + 1.5, 1), density=True)
plt.xlabel("k")
plt.ylabel("Frequenza relativa")
plt.title("Istogramma della Binomiale (n=10, p=0.2)")
plt.grid(True)

n = 10
p = 0.5
N = 10000 # numero di simulazioni

# Campionamento dalla binomiale
samples = binom.rvs(n, p, size=N)
```

```
# Istogramma
plt.hist(samples, bins=np.arange(-0.5, n + 1.5, 1), density=True)
plt.xlabel("k")
plt.ylabel("Frequenza relativa")
plt.title("Istogramma della Binomiale (n=10, p=0.2)")
plt.grid(True)
plt.show()
```



✓ Dispense teoriche o pdf con esercizi svolti

Teoria su probabilità e statistica con esempi di esercizi svolti

<https://www.mat.uniroma2.it/~pacchiar/biotec/dispense.pdf>

Alcuni esercizi per esercitarsi (i più semplici) si possono prendere da queste raccolte sul web.

Se ne riportano alcune a titolo di esempio non esaustivo.

Prima di fare alcuni esercizi il consiglio è di risolvere quelli fatti a lezione!

<https://www.mimmocorrado.it/mat/pro/probabilita.pdf>

https://www.liceogalileiancona.edu.it/wp-content/uploads/2015/11/Esercizi_probabilita_con_teorica.pdf

<https://www.mathesisnazionale.it/mathesisbkip/archivio-argomenti/Centomo.pdf>

<https://docenti-deps.unisi.it/wp-content/uploads/sites/35/2020/05/Esercizi-sulla-distribuzione-normale.pdf>