

✓ Stima dei parametri di una distribuzione dai dati

In statistica, molto frequentemente il **modello probabilistico** che descrive un fenomeno dipende da uno o più **parametri ignoti**.

Lo scopo della **stima dei parametri** è, quindi, quello di usare i dati osservati per ricavare valori plausibili di questi parametri.

Con l'espressione **fitting dei dati** si intende l'adattamento ai dati di un modello ipotizzato valido.

Alcuni esempi di stima:

- media e varianza di una popolazione
- probabilità di successo p in una Bernoulli/binomiale
- parametro λ di una Poisson
- media μ e varianza σ^2 di una normale

Campione statistico

Inquadriamo il problema in modo più formale. Sia:

$$X_1, X_2, \dots, X_n$$

un **campione casuale** di variabili aleatorie i.i.d. (indipendenti e identicamente distribuite), estratte da una popolazione con distribuzione che dipende da un parametro θ .

L'obiettivo è stimare:

$$\theta \quad \text{a partire dai dati osservati } x_1, \dots, x_n$$

Stimatori e stime

Stimatore

Uno **stimatore** è una funzione delle variabili casuali del campione:

$$\hat{\theta} = g(X_1, \dots, X_n)$$

Uno stimatore a sua volta una **variabile casuale**.

Stima

La **stima** è il valore numerico ottenuto sostituendo i dati osservati:

$$\hat{\theta}(x_1, \dots, x_n)$$

Metodi principali di stima

Qui di seguito trattiamo i principali metodi di stima dei parametri.

- Metodo dei momenti
- Massima verosimiglianza (MLE)
- Metodo Bayesiano
- Minimi quadrati

Metodo dei momenti

L'idea di fondo del metodo dei momenti è quella di ipotizzare che i **momenti teorici** della distribuzione devono coincidere con i **momenti empirici** dei dati.

Ripassiamo insieme, prima, cosa sono i momenti di una distribuzione:

I momenti di una distribuzione

I **momenti di una distribuzione** sono quantità numeriche che descrivono in modo sintetico la **forma** di una distribuzione di probabilità o di un insieme di dati.

Il **primo momento** è la **media** e rappresenta il **valore centrale** attorno a cui si concentrano i dati. Indica la posizione della distribuzione sull'asse dei valori.

Il **secondo momento centrale** è la **varianza** e misura la **dispersione** dei dati attorno alla media. Una varianza grande indica dati molto sparsi, una varianza piccola indica dati concentrati.

(Cenni) Il **terzo momento centrale**, opportunamente normalizzato, è l'**asimmetria** (**skewness**). Il terzo momento centrale di una distribuzione di probabilità misura la sua asimmetria (skewness), indicando quanto la distribuzione sia sbilanciata verso destra

(positiva) o sinistra (negativa) rispetto alla media, con un valore di zero che indica perfetta simmetria. Viene standardizzato dividendolo per la deviazione standard al cubo per renderlo indipendente dalle unità di misura, diventando un indice numerico che classifica l'asimmetria

(Cenni) Il **quarto momento centrale, normalizzato, è la curtosi**. La curtosi è una misura statistica che descrive l'altezza e la forma delle "code" di una distribuzione di dati, indicando quanto i valori si concentrano attorno alla media rispetto a una distribuzione normale (a campana). Un valore positivo (leptocurtica) indica una distribuzione più appuntita con code più pesanti, mentre un valore negativo (platicurtica/platocurtica) suggerisce una curva più piatta e code più leggere. Una curtosi pari a zero (mesocurtica) indica una distribuzione simile a quella normale

Il **metodo dei momenti** si basa, quindi, sull'idea di uguagliare:

- **momenti teorici**
- **momenti campionari**

Facciamo degli esempi

Se:

$$\mathbb{E}[X] = \theta$$

allora:

$$\hat{\theta} = \bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$$

È un metodo:

- semplice
- intuitivo
- non sempre ottimale (non entreremo nel dettaglio di spiegare cosa si intende per ottimale nel caso di uno stimatore. Lasciamo idea intuitiva)

Inizia a programmare o [genera](#) codice con l'IA.

Massima verosimiglianza (Maximum Likelihood Estimation, MLE)

È probabilmente il metodo più importante in statistica.

Scegliere il valore del parametro che rende **più probabili i dati osservati**.

Verosimiglianza

Se la densità (o massa) è $f(x | \theta)$, la funzione di verosimiglianza dai $x_1, x_2, \dots, x_n$ i.i.d. è:

$$L(\theta) = \prod_{i=1}^n f(x_i | \theta)$$

Lo stimatore di massima verosimiglianza è:

$$\hat{\theta}_{MLE} = \arg \max_{\theta} L(\theta)$$

Nota: Spesso anche per motivi computazionali si massimizza il **logaritmo della verosimiglianza**.

Esempio: Bernoulli

Se:

$$X_i \sim \text{Bernoulli}(p)$$

lo stimatore MLE di p è:

$$\hat{p} = \bar{X}$$

Esempio: Normale

Se:

$$X_i \sim \mathcal{N}(\mu, \sigma^2)$$

gli stimatori MLE sono:

$$\hat{\mu} = \bar{X}$$

$$\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$$

Comprendiamo meglio la Verosimiglianza

In questa sezione cerchiamo di spiegare l'idea di Verosimiglianza e la sua differenza rispetto alla probabilità di una distribuzione.

In statistica (ma in realtà in tutte le scienze essendo la statistica una sorta di grammatica della scienza) spesso accade che:

- abbiamo **dati osservati** acquisiti per esempio da un esperimento
- si ipotizza (sulla base per esempio di una teoria) che i dati seguano un **modello probabilistico**
- ogni modello esprimibile in forma "chiusa" ovvero analitica dipende da **parametri ignoti**

A questo punto la "domanda delle domande" è: come capiamo quali sono i "migliori parametri" che "descrivono" i dati assumendo quel modello probabilistico?:

Detto in altri termini:

Quanto è "credibile" un certo valore dei parametri, dato ciò che abbiamo osservato?

La risposta è data dalla **verosimiglianza**.

Probabilità vs Verosimiglianza

Una distribuzione di probabilità che dipende da un parametro può essere vista in due modi differenti:

- come una funzione del risultato, dato un valore fissato del parametro;
- come una funzione del parametro, dato un risultato fissato. In tal caso la funzione è chiamata "funzione di verosimiglianza" del parametro, e indica quanto verosimilmente il valore del parametro è corretto rispetto al risultato osservato.

Questa distinzione è fondamentale.

Nella **Probabilità**

- il parametro è **fisso**
- i dati sono **variabili casuali**

$$P(X = x \mid \theta)$$

Nella **Verosimiglianza**

- i dati sono **fissati**
- il parametro è **variabile**

$$L(\theta \mid x)$$

Nota bene:

Sono la **Stessa formula matematica** ma hanno una **interpretazione diversa!**

Definizione formale

Siano:

- $x_1, x_2, \dots, x_n$ dati osservati indipendenti e identicamente distribuiti
- $f(x \mid \theta)$ densità o funzione di massa

La **funzione di verosimiglianza** è:

$$L(\theta \mid x_1, \dots, x_n) = \prod_{i=1}^n f(x_i \mid \theta)$$

Assumiamo:

- osservazioni **indipendenti**
- stesso modello per ogni dato

Interpretazione intuitiva

La verosimiglianza misura:

quanto bene un valore di θ spiega i dati osservati

- valore alto $\rightarrow$ parametro plausibile
- valore basso $\rightarrow$ parametro poco compatibile

Ricordiamo che : **non è una probabilità** In altri termini non ha le caratteristiche di una probabilità ovvero:

- non integra a 1
- può essere maggiore di 1

Collegamento della funzione di Verosimiglianza con il teorema di Bayes

A livello interpretativo, l'uso della funzione di verosimiglianza trova giustificazione nel **teorema di Bayes**, secondo il quale, per due eventi qualsiasi A e B ,

$$P(B | A) = \frac{P(A | B)P(B)}{P(A)}.$$

In questa espressione, sia $P(A | B)$ sia

$$\frac{P(A | B)}{P(A)}$$

possono essere interpretate come **funzioni di verosimiglianza**.

L'uso delle funzioni di verosimiglianza per l'inferenza statistica costituisce un tratto distintivo dell'**inferenza classica (frequentista)**. Questa impostazione rappresenta una differenza fondamentale rispetto all'**inferenza bayesiana**, nella quale lo statistico conduce l'inferenza direttamente tramite la probabilità a posteriori

$$P(B | A).$$

Un esempio per capire: lancio di una moneta e Bernoulli

Inseriamo qui un esempio per spiegare meglio idea di verosimiglianza. Immaginiamo di lanciare una moneta e di ottenere la seguente sequenza (1 testa, 0 croce):

Osserviamo:

$$x = (1, 1, 0, 1, 0)$$

con:

$$X_i \sim \text{Bernoulli}(p)$$

La verosimiglianza è:

$$L(p) = p^{\sum x_i} (1 - p)^{n - \sum x_i}$$

Se:

- $p = 0.2 \rightarrow$ verosimiglianza bassa
- $p = 0.6 \rightarrow$ verosimiglianza alta

Si dimostra che il valore che massimizza la verosimiglianza è:

$$\hat{p} = \text{media campionaria}$$

prova

Esempio: stimatore di massima verosimiglianza (MLE) per i parametri di una gaussiana

(Nota: Questa dimostrazione non verrà richiesta ma sono comunque svolti i passaggi per completezza e correttezza espositiva).

Supponiamo di osservare dati indipendenti e identicamente distribuiti:

$$x_1, x_2, \dots, x_n; \sim \mathcal{N}(\mu, \sigma^2)$$

Parametri ignoti:

- **media** μ
- **varianza** σ^2

La densità di probabilità è:

$$f(x | \mu, \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x - \mu)^2}{2\sigma^2}\right)$$

Calcolo Funzione di verosimiglianza

Assumendo di avere $x_1, x_2, \dots, x_n$ acquisizioni sperimentali i.i.d., la **verosimiglianza** è la probabilità congiunta dei dati osservati:

$$\mathcal{L}(\mu, \sigma^2) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x_i - \mu)^2}{2\sigma^2}\right)$$

Calcoliamo la Log-verosimiglianza (è più semplice massimizzare il logaritmo):

$$\ell(\mu, \sigma^2) = \log \mathcal{L}$$

$$\ell(\mu, \sigma^2) = -\frac{n}{2} \log(2\pi) - \frac{n}{2} \log(\sigma^2) - \frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2$$

(non sono fondamentali i passaggi matematici.. stiamo solo applicando le proprietà del logaritmi)

Stima della media μ

Per trovare la massima verosimiglianza non dobbiamo fare altro che derivare rispetto a μ :

$$\frac{\partial \ell}{\partial \mu} = \frac{1}{\sigma^2} \sum_{i=1}^n (x_i - \mu)$$

Poniamo la derivata uguale a zero:

$$\begin{aligned} \sum_{i=1}^n (x_i - \mu) &= 0 \\ \Rightarrow \hat{\mu} &= \frac{1}{n} \sum_{i=1}^n x_i \end{aligned}$$

Risultato Lo stimatore MLE della media è la **media campionaria**.

Stima della varianza σ^2

Con analoghi calcoli matematici (ma derivando rispetto a σ^2) otteniamo che:

$$\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \hat{\mu})^2$$

Inizia a programmare o [genera](#) codice con l'IA.

✓ Cenni alla Log-verosimiglianza

Per comodità nelle applicazioni reali si usa la **log-verosimiglianza**:

$$\ell(\theta) = \log L(\theta)$$

La log-verosimiglianza sfruttando la proprietà dei logaritmi afferma che il logaritmo di un prodotto è pari alla somma dei logaritmi:

- trasforma prodotti in somme
- più semplice da derivare
- crea meno problemi quando vengono realizzate stime: è più stabile numericamente

Esempio Bernoulli:

$$\ell(p) = \sum x_i \log p + (n - \sum x_i) \log(1 - p)$$

Massimizzare L equivale a massimizzare ℓ

Verosimiglianza e stima dei parametri

Ricapitolando: la **verosimiglianza non stima direttamente**, ma:

- fornisce una funzione dei parametri
- il massimo di questa funzione dà lo **stimatore MLE**

$$\hat{\theta} = \arg \max_{\theta} L(\theta)$$

Questo porta alla **Massima Verosimiglianza (MLE)**.

Esempio: Normale

Ricordiamo quello che in precedenza abbiamo dimostrato nel caso della distribuzione normale.

$$X_i \sim \mathcal{N}(\mu, \sigma^2)$$

La verosimiglianza è:

$$L(\mu, \sigma^2) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x_i - \mu)^2}{2\sigma^2}\right)$$

Da cui:

- $\hat{\mu}$ = media campionaria

$$\bullet \hat{\sigma}^2 = \frac{1}{n} \sum (x_i - \hat{\mu})^2$$

Inizia a programmare o [genera](#) codice con l'IA.

Fai doppio clic (o premi Invio) per modificare

✓ (CENNI) Confronto tra modelli

(Questo paragrafo è messo per completezza espositiva e a lezione sono stati affrontati solo dei cenni)

La verosimiglianza permette di:

- confrontare parametri
- confrontare modelli (con cautela)

Come facciamo però a capire quale dei possibili modelli è meglio? Esistono dei criteri che qui accenneremo solamente:

- Likelihood Ratio Test
- AIC, BIC

Likelihood Ratio Test (LRT)

Il **Likelihood Ratio Test** serve a **confrontare due modelli statistici annidati**:

- un modello **semplice** (ridotto)
- un modello **più complesso** (completo)

Si basa sul confronto delle **verosimiglianze massime**:

$$\Lambda = -2 \log \left(\frac{L_{\text{ridotto}}}{L_{\text{completo}}} \right)$$

Se il modello complesso spiega i dati **significativamente meglio**, il test risulta significativo.

AIC e BIC

AIC e **BIC** sono criteri per **confrontare modelli anche non annidati**, bilanciando:

- bontà di adattamento
- complessità del modello

AIC: Akaike Information Criterion

$$\text{AIC} = -2 \log L + 2k$$

BIC: Bayesian Information Criterion

$$\text{BIC} = -2 \log L + k \log n$$

dove:

- L : verosimiglianza massima
- k : numero di parametri
- n : numero di osservazioni

In entrambi i casi: **Più piccolo è meglio**

La differenza fra questi due criteri è che:

- AIC penalizza meno la complessità
- BIC penalizza di più modelli grandi (favorisce modelli semplici)

Limiti della verosimiglianza

L'utilizzo della verosimiglianza ha delle limitazioni. In particolare ne riportiamo due:

- non tiene conto di informazioni a priori che si possono avere su un fenomeno
- è sensibile agli outlier (ovvero ai dati "estremi")
- dipende dal modello scelto

Un esempio di approccio alternativo che vedremo è quello: **Bayesiano** (prior + likelihood)

In estrema sintesi:

Tagliando un po' con l'accetta, è possibile affermare che:

La verosimiglianza non dice quanto è probabile un evento, ma **quanto è plausibile un parametro dati gli eventi osservati**.

Inizia a programmare o [genera](#) codice con l'IA.

Metodo Bayesiano

L'approccio Bayesiano è molto diffuso e cerca di estrarre informazioni utilizzando le informazioni "a priori" disponibili sul campione.

Nel metodo bayesiano:

- il parametro è trattato come variabile aleatoria
- si specifica una **distribuzione a priori**
- si aggiorna con i dati tramite il teorema di Bayes

$$\pi(\theta | x) \propto L(\theta)\pi(\theta)$$

Cerchiamo di capire meglio il metodo bayesiano

Il **metodo bayesiano** è un approccio all'inferenza statistica che interpreta la **probabilità come grado di credenza**.

Non stimiamo solo parametri, ma **aggiorniamo ciò che crediamo** su un parametro alla luce dei dati osservati.

Il metodo bayesiano è una sorta di **processo di aggiornamento razionale delle credenze** alla luce dei dati.

Il teorema di Bayes

Il metodo bayesiano si basa sul **teorema di Bayes**:

$$P(\theta | D) = \frac{P(D | \theta)P(\theta)}{P(D)}$$

dove:

- θ = parametro ignoto
- D = dati osservati

I tre ingredienti fondamentali

L'A priori ovvero in inglese: Prior $P(\theta)$

Rappresenta la **conoscenza a priori** sul parametro, prima di osservare i dati.

Esempi:

- conoscenze teoriche
- studi precedenti
- ipotesi di esperti
- assenza di informazioni $\rightarrow$ prior "non informativa"

Likelihood $P(D | \theta)$

Misura quanto i dati osservati sono **compatibili** con un certo valore del parametro.

È la stessa funzione usata nell'inferenza frequentista.

Posterior $P(\theta | D)$

È il risultato finale:

la **distribuzione aggiornata** del parametro dopo aver osservato i dati.

La posterior combina:

- ciò che credevamo prima (prior o informazione "a priori")
- ciò che dicono i dati (likelihood)

Interpretazione intuitiva

Il metodo bayesiano risponde a domande del tipo:

"Quanto è plausibile che il parametro abbia valore θ , dati i dati osservati?"

Questa è una **differenza cruciale** rispetto al metodo frequentista.

Esempio classico: la moneta

Immaginiamo di avere una moneta. Se assumiamo di non sapere nulla il nostro a priori possiamo dire che sia distribuito in modo uniforme. Una volta, però che lanciamo la moneta un po' di volte, possiamo utilizzare l'informazione ottenuta con questi lanci per "aggiornare" la nostra conoscenza sul fenomeno.

- $\theta = p$ = probabilità di testa
- Dati: 7 teste su 10 lanci

Come dicevamo, non sapendo nulla della distribuzione potremmo assumere un a priori uniforme e aggiornare i dati in base alle evidenze ottenute (7 teste su 10 lanci).

Il fatto che otteniamo un numero di gran lunga maggiore di teste su n lanci potrebbe far nascere il dubbio che la moneta sia truccata (verrebbe a chiunque questo dubbio) e sarebbe necessario, quindi, è necessario "aggiornare" la conoscenza.

Stime bayesiane

Dalla posterior possiamo ricavare:

Media a posteriori

$$\mathbb{E}[p \mid D]$$

MAP (Maximum A Posteriori)

$$\hat{p}_{\text{MAP}} = \arg \max_{\theta} P(\theta \mid D)$$

I MAP rappresenta l'analogo bayesiano della MLE.

Intervalli credibili

Nel metodo bayesiano si usano **intervalli di credibilità**.

Un intervallo credibile al 95% contiene il parametro con probabilità 95%.

Diverso dagli intervalli di confidenza frequentisti.

Ruolo della prior

La prior:

- conta **molto** con pochi dati
- conta **poco** con molti dati

Con molti dati, la posterior è dominata dalla likelihood.

Bayes vs Frequentista (confronto)

Frequentista	Bayesiano
Parametri fissi	Parametri casuali
Probabilità dei dati	Probabilità dei parametri
Likelihood centrale	Prior + Likelihood
CI	Intervalli credibili

Quando usare il metodo bayesiano

- Dati pochi
- Conoscenza pregressa importante
- Inferenza interpretativa
- Decisioni sotto incertezza

Limiti e criticità

- scelta della prior può essere soggettiva
- calcolo spesso complesso (MCMC)
- maggiore costo computazionale

✓ Approccio frequentista vs Approccio Bayesiano: esempio degli intervalli di confidenza e degli intervalli di credibilità

L'idea chiave (in una frase)

- **Intervallo di confidenza (frequentista):** parla della **procedura**, non del parametro
- **Intervallo di credibilità (bayesiano):** parla **direttamente della probabilità del parametro**

Intervalli di confidenza (frequentisti)

Definizione

Un **intervallo di confidenza al 95%** significa:

Se ripetessimo l'esperimento infinite volte e costruiamo ogni volta l'intervallo, **il 95% di quegli intervalli conterrebbe il vero valore del parametro.**

Il parametro è fisso, l'intervallo è casuale.

NON significa:

"C'è il 95% di probabilità che il parametro sia in questo intervallo"

Nel frequentismo:

- il parametro **non è una variabile casuale**
- quindi **non ha una distribuzione di probabilità**

Esempio intuitivo

Immagina una macchina che:

- estrae un campione
- costruisce un intervallo al 95%

Su 100 campioni:

- ~95 intervalli contengono il vero valore
- ~5 no

Una volta osservato **un singolo intervallo**, non puoi dire "95% di probabilità".

Intervalli di credibilità (bayesiani)

Definizione

Un **intervallo di credibilità al 95%** significa:

Dato il modello e i dati osservati, c'è il 95% di probabilità che il parametro stia in questo intervallo.

Qui il **parametro è una variabile casuale**.

Perché è possibile dirlo?

Perché in Bayes:

$$p(\theta \mid \text{dati})$$

è una **distribuzione di probabilità sul parametro**.

L'intervallo di credibilità è semplicemente:

$$P(\theta \in [a, b] \mid \text{dati}) = 0.95$$

Tipi di intervalli bayesiani

- **Credible interval centrale**
- **HPD (Highest Posterior Density)** → l'intervallo più corto con il 95% di probabilità

Schema per ricordare:

Aspetto	Confidenza (frequentista)	Credibilità (bayesiana)
Parametro	Fisso, ignoto	Variabile casuale
Intervallo	Casuale	Fisso (dato il dataset)
Interpretazione	Procedurale	Probabilistica
"95%" significa	95% degli intervalli	95% di probabilità
Usa prior?	No	Sì

Stesso intervallo, interpretazione diversa

In alcuni casi (es. Normale, prior piatta) intervallo di confidenza 95% e intervallo di credibilità 95% **numericamente coincidono**. Però il significato e l'interpretazione data è **completamente diverso**

Esempio concreto (Bernoulli)

Supponiamo:

- 60 successi su 100
- stimiamo p

Frequentista

E' corretto dire:

L'intervallo di confidenza al 95% è [0.50, 0.69]

Mentre dal punto di vista frequentista non puoi dire "p è lì con probabilità 95%"

Bayesiano (prior Beta(1,1))

Si dimostra utilizzando approccio bayesiano che (non è importante come in questa fase) che la probabilità a posteriori è data da:

$p \mid \text{dati} \sim \text{Beta}(61, 41)$

C'è il 95% di probabilità che $p \in [0.51, 0.69]$

- interpretazione diretta
- parla del parametro

"Metafora" per capire il senso di fondo:

Per l'approccio * **Frequentista**: il bersaglio è fisso, spari tante frecce (intervalli)

Per l'approccio * **Bayesiano**: il bersaglio è una nuvola di probabilità

```
### SOLO CENNI

# esempio python per dare idea
# fuori programma perché non dimostriamo nulla
# sulle variabili congiunte per fare questo calcolo

import numpy as np
import matplotlib.pyplot as plt
from scipy.stats import beta

# Impostiamo i parametri della Prior (Uniforme)
alpha_prior = 1 # servono per modellizzare variabile uniforme
beta_prior = 1 # si usa funzione Beta (non abbiamo visto questo argomento)

# Dati osservati (es. pazienti che rispondono al lancio di una moneta)
# 1 = Successo, 0 = Fallimento
dati = [1, 1, 0, 1, 0, 0, 0, 1, 1, 1]


# Setup del grafico
x = np.linspace(0, 1, 500)
plt.figure(figsize=(10, 6))

# 1. Disegniamo la Prior (Beta(1,1))
y_prior = beta.pdf(x, alpha_prior, beta_prior) # distribuzione uniforme
plt.plot(x, y_prior, label=f'Prior: Beta({alpha_prior},{beta_prior}) - Uniforme',
         linestyle='--', color='gray')
```

```
# 2. Aggiornamento con i dati
successi = sum(dati)
fallimenti = len(dati) - successi
alpha_post = alpha_prior + successi
beta_post = beta_prior + fallimenti

# 3. Disegniamo la Posterior
y_posterior = beta.pdf(x, alpha_post, beta_post)
plt.plot(x, y_posterior, label=f'Posterior: Beta({alpha_post},{beta_post})',
         color='blue', linewidth=3)

plt.fill_between(x, y_posterior, alpha=0.2, color='blue')
plt.title(f"Aggiornamento Bayesiano: da Prior Uniforme a Posterior\n(Dati: {successi} Successi, {fallimenti} Fallimenti)",
          fontsize=12)
plt.xlabel("Probabilità p", fontsize=12)
plt.ylabel("Densità di Probabilità", fontsize=12)
plt.legend()
plt.grid(alpha=0.3)
plt.show()
```



Metodo dei Minimi Quadrati

Sebbene principalmente usato in regressione, il metodo dei minimi quadrati può essere visto come metodo di stima generale.

Principio

Minimizziamo la **somma dei quadrati degli errori**:

$$\hat{\theta} = \arg \min_{\theta} \sum_{i=1}^n [y_i - f(x_i, \theta)]^2$$

Relazione con MLE

Se gli errori sono normali e indipendenti con varianza costante:

$$y_i = f(x_i, \theta) + \epsilon_i, \quad \epsilon_i \sim N(0, \sigma^2)$$

Allora **minimi quadrati = massima verosimiglianza**.

```
# questo codice è inserito solo per chiarezza espositiva
# sarà eventualmente affrontato successivamente

import numpy as np
import matplotlib.pyplot as plt
from scipy import stats

# Imposta seed per riproducibilità
np.random.seed(42)
```

```

# Genera dati con relazione lineare + rumore
n_punti = 20
x = np.linspace(0, 10, n_punti)
vero_intercetta = 2
vero_slope = 1.5
rumore = np.random.normal(0, 1.5, n_punti)
y = vero_intercetta + vero_slope * x + rumore

# Calcola la retta dei minimi quadrati
slope, intercetta, r_value, p_value, std_err = stats.linregress(x, y)
y_predetta = slope * x + intercetta

# Calcola i residui
residui = y - y_predetta

# Calcola SSE (Sum of Squared Errors)
sse = np.sum(residui**2)

# Crea figura con 4 subplot
#fig = plt.figure(figsize=(16, 12))
fig = plt.figure(1, figsize=(16, 12))

# ===== GRAFICO 1: Visualizzazione Base =====
ax1 = plt.subplot(1, 1, 1)

# Plotta i punti dati
ax1.scatter(x, y, color='blue', s=100, alpha=0.6, edgecolors='black',
            linewidth=1.5, label='Dati Osservati', zorder=3)

# Plotta la retta dei minimi quadrati
x_linea = np.linspace(0, 10, 100)
y_linea = slope * x_linea + intercetta
ax1.plot(x_linea, y_linea, 'r-', linewidth=3, label='Retta dei Minimi Quadrati', zorder=2)

# Plotta la retta vera (se diversa)
y_vera = vero_slope * x_linea + vero_intercetta
ax1.plot(x_linea, y_vera, 'g--', linewidth=2, alpha=0.7,
        label='Retta Vera', zorder=1)

ax1.set_xlabel('x', fontsize=12, fontweight='bold')
ax1.set_ylabel('y', fontsize=12, fontweight='bold')
ax1.set_title('Metodo dei Minimi Quadrati - Regressione Lineare',
            fontsize=14, fontweight='bold')
ax1.legend(fontsize=10, loc='upper left')
ax1.grid(True, alpha=0.3)

# Aggiungi equazione della retta
eq_text = f'$\hat{y} = \{intercetta:.2f\} + \{slope:.2f\}x$\\n$R^2 = \{r\_value**2:.3f\}$'
ax1.text(0.05, 0.95, eq_text, transform=ax1.transAxes,
        fontsize=11, verticalalignment='top',
        bbox=dict(boxstyle='round', facecolor='wheat', alpha=0.8))

# ===== GRAFICO 2: Visualizzazione dei Residui =====
fig = plt.figure(2, figsize=(16, 12))
ax2 = plt.subplot(1, 1, 1)

# Plotta i punti e la retta
ax2.scatter(x, y, color='blue', s=100, alpha=0.6, edgecolors='black',
            linewidth=1.5, label='Dati Osservati', zorder=3)
ax2.plot(x_linea, y_linea, 'r-', linewidth=3, label='Retta Stimata', zorder=2)

# Disegna i residui come linee verticali
for i in range(len(x)):
    ax2.plot([x[i], x[i]], [y[i], y_predetta[i]], 'k--',
            linewidth=1.5, alpha=0.5, zorder=1)
    # Evidenzia i residui con segmenti colorati
    if residui[i] > 0:
        ax2.plot([x[i], x[i]], [y_predetta[i], y[i]], 'orange',
            linewidth=3, alpha=0.7, zorder=1)
    else:
        ax2.plot([x[i], x[i]], [y[i], y_predetta[i]], 'purple',
            linewidth=3, alpha=0.7, zorder=1)

ax2.set_xlabel('x', fontsize=12, fontweight='bold')
ax2.set_ylabel('y', fontsize=12, fontweight='bold')
ax2.set_title('Visualizzazione dei Residui $e_i = y_i - \hat{y}_i$',
            fontsize=14, fontweight='bold')
ax2.legend(fontsize=10, loc='upper left')
ax2.grid(True, alpha=0.3)

# Aggiungi info sui residui
residui_text = f'$SSE = \sum e_i^2 = \{sse:.2f\}$\\n$RMSE = \{np.sqrt(sse/n\_punti):.2f\}$'
ax2.text(0.05, 0.95, residui_text, transform=ax2.transAxes,

```

```

        fontsize=11, verticalalignment='top',
        bbox=dict(boxstyle='round', facecolor='lightblue', alpha=0.8))

# ===== GRAFICO 3: Confronto tra Diverse Rette =====
figure=plt.figure(3,figsize=(16, 12))
ax4 = plt.subplot(1, 1, 1)

# Plotta i punti
ax4.scatter(x, y, color='blue', s=100, alpha=0.6, edgecolors='black',
            linewidth=1.5, label='Dati Osservati', zorder=5)

# Genera alcune rette alternative con parametri diversi
alternative_slopes = [slope - 0.5, slope, slope + 0.5]
alternative_intercetti = [intercetta - 1, intercetta, intercetta + 1]

colori = ['orange', 'red', 'purple']
labels = ['Retta Sub-ottimale 1', 'Retta Ottimale (Minimi Quadrati)', 'Retta Sub-ottimale 2']
sse_valori = []

for idx, (s, i) in enumerate(zip(alternative_slopes, alternative_intercetti)):
    y_alt = s * x_linea + i

    # Calcola SSE per questa retta
    y_pred_alt = s * x + i
    residui_alt = y - y_pred_alt
    sse_alt = np.sum(residui_alt**2)
    sse_valori.append(sse_alt)

    linestyle = '-' if idx == 1 else '--'
    linewidth = 3 if idx == 1 else 2
    alpha = 0.9 if idx == 1 else 0.6

    ax4.plot(x_linea, y_alt, color=colori[idx], linestyle=linestyle,
             linewidth=linewidth, alpha=alpha,
             label=f'{labels[idx]}\nSSE = {sse_alt:.2f}', zorder=4-idx)

ax4.set_xlabel('x', fontsize=12, fontweight='bold')
ax4.set_ylabel('y', fontsize=12, fontweight='bold')
ax4.set_title('Confronto tra Diverse Rette e loro SSE',
              fontsize=14, fontweight='bold')
ax4.legend(fontsize=9, loc='upper left')
ax4.grid(True, alpha=0.3)

# Aggiungi testo esplicativo
confronto_text = ('La retta dei minimi quadrati\n'
                  f'minimizza SSE = {sse:.2f}')
ax4.text(0.5, 0.05, confronto_text, transform=ax4.transAxes,
         fontsize=10, verticalalignment='bottom', horizontalalignment='center',
         bbox=dict(boxstyle='round', facecolor='lightgreen', alpha=0.8))

# Titolo generale
fig.suptitle('Metodo dei Minimi Quadrati (Ordinary Least Squares - OLS)',
             fontsize=16, fontweight='bold', y=0.995)

plt.tight_layout()
plt.show()

# ===== STAMPA RISULTATI =====
print("=" * 70)
print("RISULTATI DEL METODO DEI MINIMI QUADRATI")
print("=" * 70)
print(f"\nParametri Veri:")
print(f" Intercetta: {vero_intercetta:.3f}")
print(f" Slope: {vero_slope:.3f}")
print(f"\nParametri Stimati (Minimi Quadrati):")
print(f" Intercetta: {intercetta:.3f}")
print(f" Slope: {slope:.3f}")
print(f"\nErrore di Stima:")
print(f" Errore Intercetta: {abs(intercetta - vero_intercetta):.3f}")
print(f" Errore Slope: {abs(slope - vero_slope):.3f}")
print(f"\nQualità del Fit:")
print(f" R²: {r_value**2:.4f}")
print(f" SSE (Somma Quadrati Errori): {sse:.3f}")
print(f" MSE (Errore Quadratico Medio): {sse/n_punti:.3f}")
print(f" RMSE (Radice MSE): {np.sqrt(sse/n_punti):.3f}")
print(f" Errore Standard: {std_err:.4f}")

print("\n" + "=" * 70)
print("FORMULA DEI MINIMI QUADRATI")
print("=" * 70)


```

```
print( "\ndata una serie di punti (x1,y1), ..., (xn,yn), cerchiamo la retta )
print("ŷ = β0 + β1x che minimizza:")
print("\n SSE = Σ(yi - ŷi)2 = Σ(yi - β0 - β1xi)2")
print("\nLe soluzioni in forma chiusa sono:")
print("\n β1 = Σ[(xi - x̄)(yi - ȳ)] / Σ[(xi - x̄)2]" )
print("\n β0 = ȳ - β1x̄")
print("\ndove x̄ e ȳ sono le medie campionarie di x e y.")

# Calcolo manuale per verificare
x_mean = np.mean(x)
y_mean = np.mean(y)
numeratore = np.sum((x - x_mean) * (y - y_mean))
denominatore = np.sum((x - x_mean)**2)
slope_manuale = numeratore / denominatore
intercetta_manuale = y_mean - slope_manuale * x_mean

print("\n" + "=" * 70)
print("VERIFICA CALCOLO MANUALE")
print("=" * 70)
print(f"\nUsando le formule dirette:")
print(f" x̄ = {x_mean:.3f}")
print(f" ȳ = {y_mean:.3f}")
print(f" β1 = {slope_manuale:.3f}")
print(f" β0 = {intercetta_manuale:.3f}")
print(f"\nConfronto con scipy.stats.linregress:")
print(f" β1 scipy: {slope:.3f} (differenza: {abs(slope - slope_manuale):.6f})")
print(f" β0 scipy: {intercetta:.3f} (differenza: {abs(intercetta - intercetta_manuale):.6f})")
print("=" * 70)
```


Metodo dei Minimi Quadrati - Regressione Lineare



Metodo dei Minimi Quadrati (Ordinary Least Squares - OLS)

Visualizzazione dei Residui $e_i = y_i - \hat{y}_i$ 

Proprietà degli stimatori

Nel tempo i ricercatori hanno sviluppato una teoria legata agli stimatori per capire quali caratteristiche devono avere gli stimatori per essere "buoni".

Uno stimatore "buono" dovrebbe avere alcune proprietà che in questo corso accenneremo solamente.

Ma ovviamente è fondamentale conoscere l'idea che è possibile in teoria "costruire" diversi stimatori e quindi è necessario individuare dei parametri per capire quale fra i vari possibili stimatori è migliore (ovviamente migliore o peggiore in matematica, fisica, statistica è sempre rispetto ad una misura che si desidera ottimizzare)

Non distorsione (Unbiasedness)

Uno stimatore è **non distorto** se:

$$\mathbb{E}[\hat{\theta}] = \theta$$

Si definisce Bias la quantità:

$$\text{Bias}(\hat{\theta}) = \mathbb{E}[\hat{\theta}] - \theta$$

Esempio:

- la media campionaria è uno stimatore non distorto della media
- uno stimatore non distorto della varianza della popolazione è la varianza campionaria corretta:

$$s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2$$

Consistenza

Uno stimatore è **consistente** se:

Confronto tra Diverse Rette e loro SSE

$$\hat{\theta} \xrightarrow{P} \theta \text{ per } n \rightarrow \infty$$

Ciò converge al vero parametro con l'aumentare dei dati.

Varianza ed efficienza

Tra stimatori non distorti si preferisce quello con:

- varianza minore

Errore quadratico medio (MSE)

Tiene conto sia di:

- varianza
- distorsione

Si può dimostrare infatti per qualsiasi stimatore $\hat{\theta}$ di un parametro θ :

$$\text{MSE}(\hat{\theta}) = \text{Var}(\hat{\theta}) + [\text{Bias}(\hat{\theta})]^2$$

- Il **bias** è la distanza tra il centro della distribuzione di $\hat{\theta}$ e il valore vero θ
- La **varianza** è la dispersione dei valori di $\hat{\theta}$ attorno al loro valore medio

Un ragionamento sul MSE merita un approfondimento a parte perché centrale nel ragionamento relativo alla costruzione di un qualunque modello statistico e di Machine Learning.

Stima puntuale vs stima per intervalli

Stima puntuale

Restituisce un singolo valore:

Parametri Veri:

Intercetta: 2.000
Slope: 1.500

Intervallo di confidenza

Fornisce un intervallo che contiene il parametro con una certa probabilità:

Intercetta: 3.162
Slope: 1.216

$$P(\theta \in [L, U]) = 1 - \alpha$$

Esempio:

Errore di Stima:

- Errore Intercetta: 1.162
- intervallo di confidenza al 95%
Errore Slope: 0.284

Collegamento con il Teorema del Limite Centrale

Molti stimatori (come la media campionaria) hanno distribuzione asintotica normale:

RMSE (Radice MSE): 1.108
Errore Standard: 0.0861

$$\sqrt{n}(\hat{\theta} - \theta) \Rightarrow \mathcal{N}(0, \sigma^2)$$

Questo permette:

FORMULA DEI MINIMI QUADRATI

- costruzione di intervalli di confidenza

- test statistici

Data una serie di punti $(x_1, y_1), \dots, (x_n, y_n)$, cerchiamo la retta

$y = \beta_0 + \beta_1 x$ che minimizza:

Esempio riassuntivo

$$\text{SSE} = \sum (y_i - \hat{y}_i)^2 = \sum (y_i - \beta_0 - \beta_1 x_i)^2$$

Se: Le soluzioni in forma chiusa sono:

$$\beta_1 = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sum (x_i - \bar{x})^2}$$

$$X_i \sim \text{Poisson}(\lambda)$$

allora:

$$\beta_0 = \bar{y} - \beta_1 \bar{x}$$

- MLE: $\hat{\lambda} = \bar{X}$
dove $\bar{x}$ e $\bar{y}$ sono le medie campionario di x e y .
- stimatore non distorto

- consistente
- asintoticamente normale

Usando le formule dirette:

Conclusione

$$\bar{y} = 9.243$$

$$\bar{x} = 1.216$$

La stima dei parametri è il cuore della statistica inferenziale Attraverso i metodi visti è possibile collegare dati osservati e modelli teorici.

I metodi visti sono rigorosi in quanto hanno un fondamento matematico

Confronto con `scipy.stats.linregress`:

β_1 scipy: 1.216 (differenza: 0.000000)

Comprendere come e perché uno stimatore funziona è più importante che applicare formule meccanicamente.

Inizia a programmare o [genera](#) codice con l'IA.

▼ Stima dei parametri di una distribuzione dai dati (Fitting)

Quanto fin qui spiegata aveva un taglio "teorico". Cerchiamo di dare in questa seconda parte della lezione un taglio più applicativo vicino al lavoro di chi lavora nel campo del **Machine Learning**.

Lo faremo cercando di fornire anche degli esempi pratici per richiamare gli aspetti concettuali.

1. Obiettivo del fitting

Dato un **campione di dati osservati**

$$x_1, x_2, \dots, x_n$$

si cerca di:

1. **scegliere una famiglia di distribuzioni** (Normale, Binomiale, Poisson, ecc.)
2. **stimare i parametri** della distribuzione (media, varianza, λ , p , ...)
3. usare la distribuzione stimata per:
 - inferenza statistica
 - simulazione
 - predizione
 - valutazione di probabilità

2. Esempio intuitivo

Supponiamo di avere a disposizione un campione di altezze di persone. Per esempio una lista di altezze come queste:

170, 168, 172, 175, 169, 171, ...

L'ipotesi più "sensata" che si potrebbe fare è che queste misure seguano una distribuzione normale.

Ipotesi:

- i dati seguono una **Normale** $\mathcal{N}(\mu, \sigma^2)$

A questo punto ci potremmo chiedere:

Quali sono i valori "migliori" di μ e σ ?

Scelta del modello di distribuzione

Una possibile scelta può essere fatta in base alla natura del dato.

Tipo di dato	Distribuzione tipica
Continua simmetrica	Normale
Conteggi	Poisson
Bernoulli	Binomiale
Tempo di attesa	Esponenziale

Verifica grafica (EDA)

Una buona prassi è sempre quella di fare una analisi esplorativa iniziale dei dati (in genere è indicata con il termine inglese Exploratory Data Analysis o EDA)

Si possono per esempio realizzare le seguenti analisi esplorative:

- istogramma
- QQ-plot
- densità stimata (KDE)

Non si stima nulla se prima non si guarda il dato

Valutazione del fitting

Grafica

- QQ-plot
- confronto densità stimata vs istogramma
- residui

Test statistici

- Kolmogorov–Smirnov
- Anderson–Darling
- Chi-quadro

Criteri informativi

Criterio	Formula
AIC	$2k - 2\ell$
BIC	$k \log n - 2\ell$

Confronto tra modelli

Il **Q–Q plot (Quantile–Quantile plot)** è uno strumento **grafico** usato in statistica per **confrontare la distribuzione di un campione di dati** con una **distribuzione teorica** (per esempio la normale), oppure per confrontare **due campioni tra loro**.

L'idea è semplice: se le due distribuzioni sono simili, **i loro quantili coincidono**.

✓ Idea di base

- Un **quantile** è un valore sotto il quale cade una certa percentuale dei dati (mediana = 50%, quartili = 25% e 75%, ecc.).

Nel Q–Q plot:

- sull'asse **x** metti i quantili della distribuzione teorica
- sull'asse **y** metti i quantili dei dati osservati

Se i punti stanno **circa su una retta**, le due distribuzioni sono compatibili.

A cosa serve il Q–Q plot

È usato soprattutto per:

- verificare se i dati seguono una **distribuzione normale**
- controllare **asimmetria (skewness)**
- individuare **code pesanti o leggere**
- individuare **outlier**

È uno strumento **diagnostico**, non un test formale.

3. Come si costruisce (concettualmente)

Supponiamo di avere dati $x_1, \dots, x_n$:

1. Ordina i dati:

$$x_{(1)} \leq x_{(2)} \leq \dots \leq x_{(n)}$$

2. Associa a ciascun dato una probabilità teorica:

$$p_i = \frac{i - 0.5}{n}$$

3. Calcola il quantile teorico:

$$q_i = F^{-1}(p_i)$$

dove F^{-1} è la funzione quantile della distribuzione teorica (es. normale).

4. Traccia i punti $(q_i, x_{(i)})$

4. Interpretazione grafica

Caso ideale

- **Punti allineati su una retta** → buona compatibilità con la distribuzione teorica

Asimmetria

- Curva verso l'alto o il basso → distribuzione asimmetrica

Code pesanti / leggere

- Punti estremi molto lontani dalla retta → code più pesanti o più leggere della distribuzione teorica

Outlier

- Punti isolati lontani dalla retta → possibili outlier

Q-Q plot vs istogramma

Istogramma	Q-Q plot
Dipende dal numero di bin	Non dipende da bin
Meno sensibile alle code	Molto sensibile alle code
Più intuitivo	Più diagnostico

Spesso si usano **insieme**.

Esempio in Python

```
import numpy as np
import scipy.stats as stats
import matplotlib.pyplot as plt

# dati simulati
np.random.seed(0)
x = np.random.normal(loc=0, scale=1, size=100)

# Q-Q plot
stats.probplot(x, dist="norm", plot=plt)
plt.title("Q-Q plot rispetto alla Normale")
plt.show()
```

Q-Q plot tra due campioni

Puoi anche confrontare due dataset:

- quantili del campione A sull'asse x
- quantili del campione B sull'asse y

Serve per verificare se **due campioni hanno la stessa distribuzione**.

Collegamento con MLE e modellazione

Nel contesto del **fitting**:

- il Q-Q plot è un **controllo visivo post-stima**
- dopo aver stimato μ e σ , verifichi se il modello gaussiano è plausibile
- se il Q-Q plot mostra forti deviazioni → il modello è inadeguato

In sintesi:


Il Q-Q plot confronta i quantili dei dati con quelli di una distribuzione teorica: se stanno su una retta, il modello è plausibile.

Inizia a programmare o [genera](#) codice con l'IA.

```
import numpy as np
import matplotlib.pyplot as plt
import statsmodels.api as sm

# Esempio: dati da testare
np.random.seed(42)
data = np.random.normal(0, 1, 200) #
print(len(data))
# Q-Q-plot
sm.qqplot(data, line='45')
plt.title("QQ-plot (Statsmodels)")
```

```
plt.show()
```



Introduzione (non rigorosa) ai test di ipotesi

I test di ipotesi fanno parte della grammatica della scienza e più in generale delle decisioni razionali.

In quasi ogni contesto umano siamo chiamati a prendere delle decisioni.

In ambito scientifico e industriale spesso queste decisioni vanno prese con motivazioni che non possono essere soggettive.

Per questo motivo si sono sviluppati i test di ipotesi.

Quando osserviamo dei dati, spesso vogliamo rispondere a domande del tipo:

- *Questo nuovo farmaco funziona?*
- *Questa classe ha risultati diversi rispetto all'anno scorso?*
- *La differenza che vedo è reale o solo frutto del caso?*
- *Le dimensioni del contenitore rispettano la normativa?**

Il problema è che i dati **contengono sempre rumore**: anche se due fenomeni sono uguali, i numeri osservati non saranno mai identici.

In fisica questo fatto è bene noto. Ogni misurazione fatta è appunto affetta da errore e, per esempio, misurando lo stesso fenomeno con strumenti e in momenti diversi si ottengono risultati leggermente differenti.

I test di ipotesi servono proprio a questo: decidere se ciò che osserviamo è compatibile con il caso oppure no.

La logica dei test di ipotesi: l'idea di base da cui si parte

Un test di ipotesi parte sempre da un'ipotesi "di riferimento", detta "Ipotesi nulla":

Ipotesi nulla (H_0)

È l'ipotesi più prudente e conservativa. Di solito afferma che **non c'è alcun effetto**, nessuna differenza, nessun cambiamento.

Esempi:

- "Il farmaco **non** ha effetto"
- "Le due medie sono uguali"
- "La moneta è equa"
- "Le dimensioni del contenitore non sono diverse da quelle richieste dalla normativa"

Accanto a questa ipotesi nulla c'è in modo "dicotomico" anche una ipotesi alternativa:

Ipotesi alternativa (H_1)

L'ipotesi alternativa rappresenta quello che vorremmo cercare di verificare in modo per quanto possibile "oggettivo":

- "Il farmaco ha un effetto"
- "Le medie sono diverse"
- "La moneta è truccata"
- "Il contenitore ha dimensioni fuori standard"

Idea intuitiva su come funziona un test di ipotesi

1. **Assumiamo che H_0 sia vera** Anche se può sembrare strano, partiamo facendo finta che assumiamo non ci sia alcun effetto.
2. **Calcoliamo quanto sono "strani" i dati osservati** assumendo che l'ipotesi nulla sia vera. In altri termini ci chiediamo:
Se H_0 fosse vera, quanto sarebbe probabile osservare dati come questi (o ancora più estremi)?
3. **Valutiamo questa probabilità** Questa quantità è il famoso **p-value**.

Cos'è il p-value (senza formule)

Sul *p-value*, il suo significato e il suo modo errato di interpretarlo sono stati scritti decine di articoli. Qui per brevità ci limiteremo a "semplificare" le cose dicendo, in prima battuta, che il **p-value** misura quanto i dati sono **compatibili con l'ipotesi nulla**.

- **p-value grande** → i dati sono plausibili sotto H_0
- **p-value piccolo** → i dati sono difficili da spiegare se H_0 fosse vera

NOTA BENE!!!

Il p-value **NON** è:

- la probabilità che H_0 sia vera
- la probabilità che il risultato sia dovuto al caso

È invece:

La probabilità di osservare dati almeno così estremi, assumendo che H_0 sia vera.

La decisione

Si fissa una soglia, chiamata **livello di significatività** (di solito 5%, cioè 0.05).

- Se **p-value ≤ 0.05** → rifiutiamo H_0
- Se **p-value > 0.05** → non rifiutiamo H_0

Importante: *Non rifiutare H_0 non significa dimostrare che H_0 è vera*, ma solo che **i dati non sono sufficientemente forti per smentirla**.

Un esempio intuitivo

Immagina un processo in tribunale:

- **H_0** : l'imputato è innocente
- **Dati**: le prove raccolte
- **p-value**: quanto sarebbero improbabili quelle prove se l'imputato fosse davvero innocente

Se le prove sono **molto improbabili** sotto l'innocenza → condanna

Se non lo sono → assoluzione (ma non "prova di innocenza")

Test di Ipotesi in Statistica (presentazione più rigorosa)

Un test di ipotesi è un problema di **decisione statistica**.

Si parte da due ipotesi:

$$H_0 : \theta \in \Theta_0 \quad (\text{ipotesi nulla})$$

$$H_1 : \theta \in \Theta_1 \quad (\text{ipotesi alternativa})$$

dove Θ_0 e Θ_1 sono insiemi disgiunti dei possibili valori del parametro θ .

Regione critica e statistica test

Un test definisce:

- una **statistica test** $T(X)$
- una **regione critica** C

Si rifiuta H_0 se:

$$T(X) \in C$$

La regione critica è scelta in modo che:

$$P(T(X) \in C \mid H_0) = \alpha$$

dove α è il livello di significatività.

Errore di Tipo I e Tipo II

Errore di Tipo I

$$\alpha = P(\text{rifiutare } H_0 \mid H_0 \text{ vera})$$

Errore di Tipo II

$$\beta = P(\text{non rifiutare } H_0 \mid H_1 \text{ vera})$$

Potenza del test

$$\text{Potenza} = 1 - \beta$$

Cosa è il p-value

Il **p-value** è definito come:

$$p = P(T(X) \geq T(x_{\text{obs}}) \mid H_0)$$

per test a una coda, oppure:

$$p = P(|T(X)| \geq |T(x_{\text{obs}})| \mid H_0)$$

per test a due code.

Test parametrici classici

Test z per la media (assumendo varianza nota)

Campione $X_1, \dots, X_n$ avente una media μ e varianza σ^2 , con σ nota.

$$H_0 : \mu = \mu_0$$

In questo caso la statistica test è:

$$Z = \frac{\bar{X} - \mu_0}{\sigma/\sqrt{n}}$$

Sotto H_0 :

$$Z \sim N(0, 1)$$

Test t per la media (varianza ignota)

$$T = \frac{\bar{X} - \mu_0}{S/\sqrt{n}}$$

dove:

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$$

Sotto H_0 :

$$T \sim t_{n-1}$$

Test per due medie (campioni indipendenti)

Varianze uguali (t-test pooled)

$$S_p^2 = \frac{(n_1 - 1)S_1^2 + (n_2 - 1)S_2^2}{n_1 + n_2 - 2}$$

$$T = \frac{\bar{X}_1 - \bar{X}_2}{S_p \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}}$$

$$T \sim t_{n_1 + n_2 - 2}$$

Test chi-quadro per la varianza

$$H_0 : \sigma^2 = \sigma_0^2$$

$$\chi^2 = \frac{(n-1)S^2}{\sigma_0^2}$$

$$\chi^2 \sim \chi_{n-1}^2$$

Test di ipotesi per proporzioni

Campione binomiale $X \sim \text{Bin}(n, p)$.

$$\hat{p} = \frac{X}{n}$$

Test z:

$$Z = \frac{\hat{p} - p_0}{\sqrt{p_0(1-p_0)/n}}$$

Test di ipotesi nella "vita reale"

Salvo rarissimi casi, i test di ipotesi vengono realizzati avvalendosi dell'uso di un programma o di un linguaggio di programmazione.

Python ovviamente nel modulo statsmodel e numpy ha implementato tutto quello che serve.

Nella pratica, quindi, è necessario capire essenzialmente:

- in che caso siamo per formulare il test di ipotesi
- trovare .a statistica test/ test di ipotesi più adeguato in base ai dati

In Python esistono diverse librerie per fare **test di ipotesi statistici**, ognuna con un ruolo un po' diverso. Ecco le principali, con esempi tipici di utilizzo.

◆ 1. SciPy (**scipy.stats**) → la più usata per i test

È la libreria standard per la statistica classica.

Test disponibili

- **t-test:** `ttest_1samp`, `ttest_ind`, `ttest_rel`
- **z-test** (manuale o con statsmodels)
- **test non parametrici:**
 - Mann-Whitney: `mannwhitneyu`
 - Wilcoxon: `wilcoxon`
 - Kruskal-Wallis: `kruskal`
- **chi-quadro:** `chi2_contingency`
- **normalità:** `shapiro`, `normaltest`
- **correlazione:** `pearsonr`, `spearmanr`, `kendalltau`
- **ANOVA:** `f_oneway`
- **KS test:** `kstest`, `ks_2samp`

Esempio

```
from scipy import stats

stats.ttest_1samp(data, popmean=10)
stats.mannwhitneyu(x, y)
stats.chi2_contingency(tabella)
```

2. Statsmodels (**statsmodels.stats**) → inferenza statistica avanzata

Molto usata in econometria e statistica applicata.

Test disponibili

- **z-test:** `ztest`
- **t-test:** `ttest_ind`
- **test per proporzioni:** `proportions_ztest`
- **ANOVA, regressione con p-value**

Esempio

```
from statsmodels.stats.weightstats import ztest

ztest(data, value=10)
```

3. Pingouin → statistica “user friendly”

Accenniamo all'esistenza di questa altra libreria moderna e semplice per test comuni.

Esempio

```
import pingouin as pg

pg.ttest(data, 10)
pg.anova(data=df, dv="y", between="gruppo")
```

Esempio stesso test con librerie diverse

t-test con SciPy

```
from scipy import stats

stats.ttest_1samp(data, 10)
```

z-test con Statsmodels

```
from statsmodels.stats.weightstats import ztest

ztest(data, value=10)
```

t-test con Pingouin

```
import pingouin as pg

pg.ttest(data, 10)
```

✓ Esempi esercizi sul **test di ipotesi per la media con varianza nota**

Useremo sempre il modello:

- popolazione: $X \sim N(\mu, \sigma^2)$
- σ^2 **nota**, μ incognita
- campione: $X_1, \dots, X_n$ indipendenti

La statistica del test sarà:

$$Z = \frac{\bar{X} - \mu_0}{\sigma / \sqrt{n}}$$

Esercizio 1 – Test bilaterale, decisione con p-value

Un'azienda produce bottiglie da **1 litro**. Si sospetta che la macchina sia leggermente starata.

La quantità imbottigliata (in litri) può essere considerata $X \sim N(\mu, \sigma^2)$ con $\sigma = 0,02$ litri nota.

Viene prelevato un campione di ($n = 25$) bottiglie, con media campionaria $\bar{X} = 0,992$ litri.

Al livello di significatività $\alpha = 0,05$, si vuole testare:

- la macchina **riempie correttamente** oppure **no**?

1. Formulazione di H_0 e H_1

Stiamo controllando se la media è davvero 1 litro.

$$H_0 : \mu = 1,00$$

Poiché non diciamo se pensiamo sia minore o maggiore, il test è **bilaterale**:

$$H_1 : \mu \neq 1,00$$

2. Statistica del test

Usiamo:

$$Z = \frac{\bar{X} - \mu_0}{\sigma/\sqrt{n}}$$

Qui:

- $\bar{X} = 0,992$
- $\mu_0 = 1,00$
- $\sigma = 0,02$
- $n = 25 \Rightarrow \sqrt{n} = 5$

Quindi:

$$Z = \frac{0,992 - 1,00}{0,02/5} = \frac{-0,008}{0,004} = -2$$

3. Calcolo del p-value (test bilaterale)

Per un test **bilaterale**:

$$p = 2 \cdot P(Z \geq |z_{\text{oss}}|)$$

Qui $|z_{\text{oss}}| = 2$. Dalla normale standard sappiamo circa:

$$P(Z \geq 2) \approx 0,0228$$

Quindi:

$$p \approx 2 \cdot 0,0228 = 0,0456$$

4. Decisione

Confrontiamo p con $\alpha = 0,05$:

- $p \approx 0,0456 < 0,05 \rightarrow$ **rifiutiamo** H_0 .

Cosa possiamo dedurre quindi?

Al livello del 5%, i dati suggeriscono che la macchina **non riempie esattamente 1 litro**: la differenza osservata è statisticamente significativa.

Esercizio 2 – Test unilaterale, decisione con regione critica

Si vuole verificare se una nuova dieta **riduce** il colesterolo medio rispetto al valore abituale di $\mu_0 = 220$ mg/dL.

Si sa (da studi precedenti) che la deviazione standard del colesterolo in questa popolazione è circa $\sigma = 30$ mg/dL.

Viene applicata la dieta a $n = 36$ persone, ottenendo una media campionaria $\bar{X} = 210$ mg/dL.

Livello di significatività: $\alpha = 0,01$.

Formulazione di H_0 e H_1

Vogliamo vedere se la dieta **riduce** il colesterolo, quindi ipotesi unilaterale “verso il basso”:

$$H_0 : \mu = 220$$

$$H_1 : \mu < 220$$

Statistica del test

$$Z = \frac{\bar{X} - \mu_0}{\sigma/\sqrt{n}}$$

Dati:

- $\bar{X} = 210$
- $\mu_0 = 220$
- $\sigma = 30$
- $n = 36 \Rightarrow \sqrt{n} = 6$

$$Z = \frac{210 - 220}{30/6} = \frac{-10}{5} = -2$$

Regione critica (test unilaterale sinistro)

Livello $\alpha = 0,01$, test a **una coda verso sinistra**:

- cerchiamo $z_{0,01}$ tale che $P(Z \leq z_{0,01}) = 0,01$
- dalla normale standard: $z_{0,01} \approx -2,33$

Regione critica:

$$C = \{z : z \leq -2,33\}$$

Decisione

- il nostro $z_{\text{oss}} = -2$
- -2 **non è** $\leq -2,33$

Quindi:

- z_{oss} **non cade nella regione critica** $\rightarrow$ **non rifiutiamo H_0 **.

Conclusione:

Al livello dell'1%, i dati **non sono sufficienti** per concludere che la dieta riduca il colesterolo.

Si osserva una media più bassa, ma non è statisticamente significativa a $\alpha = 0,01$.

Nota: a $\alpha = 0,05$ il risultato sarebbe invece significativo.

```
# ricordiamo che SciPy offre funzioni specifiche come
# norm.pdf() (funzione di densità),
# norm.cdf() (distribuzione cumulativa)
# e norm.rvs() per simulare la distribuzione
# e la funzione ppf() che in scipy.stats sta per Percent Point Function
# ppf ed è semplicemente l'inversa della CDF (funzione di distribuzione cumulativa).

# codice per capire significato delle varie funzioni relative ad una
# distribuzione di probabilità
# e per capire i test di ipotesi

import scipy as sp
import numpy as np
import matplotlib.pyplot as plt




print(sp.stats.norm.cdf(1.96))

print(sp.stats.norm.cdf(-2))

print(sp.stats.norm.ppf(0.97500))

plt.figure(1)
plt.title("Grafico pdf: probability density function")
plt.plot(np.arange(-3,3,0.01), sp.stats.norm.pdf(np.arange(-3,3,0.01)))
plt.axvline(1.96, color='r', linestyle='--')
plt.figure(2)
plt.title("Grafico cdf: cumulative density function")
plt.plot(np.arange(-3,3,0.01), sp.stats.norm.cdf(np.arange(-3,3,0.01)))
plt.axhline(0.975, color='r', linestyle='--')
plt.axvline(1.96, color='r', linestyle='--')
plt.figure(3)
plt.title("Grafico ppf: percent point function")
plt.plot(np.arange(0,1,0.01), sp.stats.norm.ppf(np.arange(0,1,0.01)))
plt.axvline(0.975, color='r', linestyle='--')
plt.axhline(1.96, color='r', linestyle='--')
```

```
0.9750021048517795
0.022750131948179195
1.959963984540054
<matplotlib.lines.Line2D at 0x7a3c287d5dc0>
```



```
import scipy as sp
import numpy as np
import matplotlib.pyplot as plt

z_value= 1.2

prob_z_less_z_value= sp.stats.norm.cdf(z_value)

print(sp.stats.norm.cdf(-2))

print(sp.stats.norm.ppf(0.97500))

plt.figure(1)
plt.title("Grafico pdf: probability density function")
plt.plot(np.arange(-3,3,0.01), sp.stats.norm.pdf(np.arange(-3,3,0.01)))
plt.axvline(1.96, color='r', linestyle='--')
plt.figure(2)
plt.title("Grafico cdf: cumulative density function")
plt.plot(np.arange(-3,3,0.01), sp.stats.norm.cdf(np.arange(-3,3,0.01)))
plt.axhline(0.975, color='r', linestyle='--')
plt.axvline(1.96, color='r', linestyle='--')
plt.figure(3)
plt.title("Grafico ppf: percent point function")
plt.plot(np.arange(0,1,0.01), sp.stats.norm.ppf(np.arange(0,1,0.01)))
```

```
plt.axvline(0.975, color='r', linestyle='--')
plt.axhline(1.96, color='r', linestyle='--')
```

```
0.022750131948179195
```

```
1.959963984540054
```

```
<matplotlib.lines.Line2D at 0x7a3c1535d1f0>
```

Grafico pdf: probability density function




Grafico cdf: cumulative density function





Grafico ppf: percent point function



✓ Rivediamo il test di ipotesi ad una coda

Struttura del test

1. Le ipotesi:

- H_0 (ipotesi nulla): l'affermazione "standard" che vuoi verificare, ad esempio $\mu = \mu_0$
- H_1 (ipotesi alternativa): ciò che sospetti sia vero

2. Test ad una coda: Nel test ad una coda, l'ipotesi alternativa specifica una direzione:

- **Coda destra:** $H_1: \mu > \mu_0$ (vuoi verificare se la media è maggiore)
- **Coda sinistra:** $H_1: \mu < \mu_0$ (vuoi verificare se la media è minore)

Con varianza nota (σ^2 nota)

Quando la varianza della popolazione è conosciuta, usi la distribuzione normale standardizzata (Z).

La statistica test è:

$$Z = (\bar{x} - \mu_0) / (\sigma / \sqrt{n})$$

dove:

- $\bar{x}$ = media campionaria
- μ_0 = valore ipotizzato per la media
- σ = deviazione standard della popolazione (nota)
- n = dimensione del campione

Procedura passo per passo

Passo 1: Definisci le ipotesi e scegli il livello di significatività α (tipicamente 0,10, 0,05 o 0,01)

Passo 2: Calcola la statistica test Z

Passo 3: Determina il valore critico o calcola il p-value

Passo 4: Prendi la decisione:

- Se test coda destra: rifiuti H_0 se $Z > z_\alpha$
- Se test coda sinistra: rifiuti H_0 se $Z < -z_\alpha$

Esempio pratico

Supponi che un'azienda produca lampadine con durata media dichiarata di 1000 ore ($\mu_0 = 1000$). La varianza è nota: $\sigma = 50$ ore. Vuoi verificare se un nuovo processo aumenta la durata. Prendi un campione di $n = 25$ lampadine e trovi $\bar{x} = 1015$ ore.

- $H_0: \mu = 1000$
- $H_1: \mu > 1000$ (test coda destra)
- $\alpha = 0,05$, quindi $z_{0,05} = 1,645$

Calcolo: $Z = (1015 - 1000)/(50/\sqrt{25}) = 15/10 = 1,5$

Decisione: poiché $1,5 < 1,645$, non rifiuti H_0 . Non hai evidenza sufficiente per concludere che il nuovo processo aumenti la durata.

Esercizio 3 – Costruisci tu il test (scelta del tipo di test)

Una fabbrica produce componenti il cui peso dovrebbe essere in media $\mu_0 = 50$ grammi.

La deviazione standard è nota: $\sigma = 5$ grammi.

Un ingegnere pensa che la produzione recente sia **più pesante** del solito.

Viene preso un campione di $n = 64$ pezzi, con media campionaria $\bar{X} = 51,2$ grammi.

Si lavori a livello $\alpha = 0,05$.

Scegliere il tipo di test e formulare H_0, H_1

L'ingegnere sospetta che i pezzi siano **più pesanti** → test unilaterale a destra.

$$H_0 : \mu = 50$$

$$H_1 : \mu > 50$$

Statistica del test

$$Z = \frac{\bar{X} - \mu_0}{\sigma/\sqrt{n}}$$

Dati:

- $\bar{X} = 51,2$
- $\mu_0 = 50$
- $\sigma = 5$
- $n = 64 \Rightarrow \sqrt{n} = 8$

$$Z = \frac{51,2 - 50}{5/8} = \frac{1,2}{0,625} = 1,92$$

Regione critica (test unilaterale destro)

Livello $\alpha = 0,05$, test a **una coda verso destra**:

- cerco $z_{0,95}$ tale che $P(Z \leq z_{0,95}) = 0,95 - z_{0,95} \approx 1,645$

Regione critica:

$$C = \{z : z \geq 1,645\}$$

Decisione

- $z_{oss} = 1,92$

- $1,92 \geq 1,645 \rightarrow z_{\text{oss}}$ è nella regione critica

Quindi:

- rifiutiamo H_0 .

p-value

Per test unilaterale destro:

$$p = P(Z \geq 1,92)$$

Dalla normale standard:

- $P(Z \geq 1,92) \approx 0,027$ (circa)

$$p \approx 0,027 < 0,05$$

Conferma la decisione: rifiutare H_0 .

Conclusione

Al livello del 5%, ci sono evidenze statistiche che i componenti pesino **più di 50 g** in media.

Caso test di ipotesi varianza ignota

Vediamo ora il caso, molto più realistico in cui sia la media che la varianza siano incognite e vengano stimate dal campione.

Spieghiamo il tutto con un esempio.

Il problema

Hai un campione di dati:

$$X_1, X_2, \dots, X_n$$

e vuoi verificare se la **media della popolazione** è uguale a un valore noto μ_0 , ma: **la varianza della popolazione σ^2 non è nota** (caso più realistico nella pratica).

Ipotesi

Test classico sulla media:

- **Ipotesi nulla:**

$$H_0 : \mu = \mu_0$$

- **Ipotesi alternativa:**

- Bilaterale: $H_1 : \mu \neq \mu_0$
- Destra: $H_1 : \mu > \mu_0$
- Sinistra: $H_1 : \mu < \mu_0$

Statistica test: la t di Student

Poiché la varianza è **ignota**, la stimiamo con la varianza campionaria (s^2):

$$s^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$$

N.B. ricordiamo che la varianza campionaria (ottenuta dividendo per $n-1$) è non distorta ma che ovviamente per n grande la differenza fra la stima della varianza campionaria e σ^2 tendono a diminuire.

La statistica test è:

$$T = \frac{\bar{X} - \mu_0}{s/\sqrt{n}}$$

dove:

- $\bar{X}$ = media campionaria
- s = deviazione standard campionaria
- n = dimensione del campione

Se l'ipotesi nulla è vera e i dati sono normali (o n grande), allora:

$$T \sim t_{n-1}$$

cioè segue una **distribuzione t di Student con (n-1) gradi di libertà**.

Perché si usa la t invece della z?

Quando la varianza è nota → **z-test** Quando la varianza è ignota → **t-test**

La distribuzione t:

- è simile alla normale
- ma ha **code più larghe** → tiene conto dell'incertezza nella stima di s
- per n grande, la t → normale standard

Regola decisionale (metodo della tabella t)

Passaggi

1. **Fissa il livello di significatività:** α (es. 0.05)
2. **Calcola la statistica t:**

$$t_{\text{obs}} = \frac{\bar{X} - \mu_0}{s/\sqrt{n}}$$

3. **Determina i gradi di libertà:**

$$\nu = n - 1$$

4. **Consulta la tabella della t di Student**
5. **Confronta** t_{obs} con il valore critico

Come usare la tabella della t di Student

La tabella riporta i valori critici $t_{\alpha,\nu}$ per:

- diversi **livelli di significatività** α
- diversi **gradi di libertà** ν

Caso 1: Test bilaterale

Ipotesi: $H_1 : \mu \neq \mu_0$

- Dalla tabella cerchi:

$$t_{\alpha/2, n-1}$$

- **Regione critica:**

$$|t_{\text{obs}}| > t_{\alpha/2, n-1}$$

Se la t calcolata cade fuori dall'intervallo → **rifiuti (H_0)**.

Caso 2: Test unilaterale destro

Ipotesi: $H_1 : \mu > \mu_0$

- Cerchi:

$$t_{\alpha, n-1}$$

- **Regione critica:**

$$t_{\text{obs}} > t_{\alpha, n-1}$$

Caso 3: Test unilaterale sinistro

Ipotesi: $H_1 : \mu < \mu_0$

- Cerchi:

$$-t_{\alpha, n-1}$$

- **Regione critica:**

$$t_{\text{obs}} < -t_{\alpha, n-1}$$

Esempio numerico (con tabella)

Supponiamo:

- $n = 16$
- $\bar{X} = 102$
- $s = 4$
- $\mu_0 = 100$
- $\alpha = 0.05$
- Test bilaterale

Calcolo della statistica:

$$t_{\text{obs}} = \frac{102 - 100}{4/\sqrt{16}} = \frac{2}{1} = 2$$

Gradi di libertà:

$$\nu = 16 - 1 = 15$$

Valore critico dalla tabella:

Per $\alpha = 0.05$ bilaterale $\rightarrow \alpha/2 = 0.025$ Dalla tabella t:

$$t_{0.025,15} \approx 2.131$$

Confronto:

$$|t_{\text{obs}}| = 2 < 2.131$$

→ **Non rifiuto (H_0)**: il campione non fornisce evidenza sufficiente per dire che la media è diversa da 100.

Interpretazione

- Se $|t_{\text{obs}}| \leq t_{\text{critico}} \rightarrow$ dati compatibili con (H_0)
- Se $|t_{\text{obs}}| > t_{\text{critico}} \rightarrow$ dati troppo improbabili sotto $H_0 \rightarrow$ **rifiuto H_0**

Collegamento con p-value

Il metodo della tabella equivale al confronto con il **p-value**:

- Se **p-value** < $\alpha \rightarrow$ rifiuto H_0
- Se **p-value** $\geq \alpha \rightarrow$ non rifiuto H_0

La tabella ti dice “quanto deve essere grande t per essere raro”.

✓ Test con varianza ignota

- popolazione normale $X \sim N(\mu, \sigma^2)$
- σ^2 **ignota**
- campione $X_1, \dots, X_n$ indipendenti

La statistica del test per μ è:

$$T = \frac{\bar{X} - \mu_0}{S/\sqrt{n}}$$

dove

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$$

e sotto $H_0: T \sim t_{n-1}$.

Esercizio 1 – Test bilaterale t per la media

Un nutrizionista studia il contenuto medio di zucchero (in grammi) in una certa bevanda.

Non si conosce la varianza della popolazione, ma si assume che la distribuzione sia approssimativamente normale.

Prende un campione di $n = 16$ bottiglie e trova:

- media campionaria $\bar{X} = 35$ g
- deviazione standard campionaria $S = 4$ g

Vuole verificare, al livello $\alpha = 0,05$, se il contenuto medio di zucchero è **diverso da** $\mu_0 = 33$ g.

1. Formulazione di H_0 e H_1

“Diverso da” $\rightarrow$ test **bilaterale**.

$$H_0 : \mu = 33$$

$$H_1 : \mu \neq 33$$

2. Statistica del test t

Usiamo:

$$T = \frac{\bar{X} - \mu_0}{S/\sqrt{n}}$$

Sostituiamo i valori:

- $\bar{X} = 35$
- $\mu_0 = 33$
- $S = 4$
- $n = 16 \Rightarrow \sqrt{n} = 4$

$$T = \frac{35 - 33}{4/4} = \frac{2}{1} = 2$$

Quindi $t_{\text{oss}} = 2$.

I gradi di libertà sono:

$$df = n - 1 = 15$$

3. Valore critico del test bilaterale

Livello $\alpha = 0,05$, test bilaterale:

- $\alpha/2 = 0,025$ in ciascuna coda
- cerchiamo $t_{0,975;15}$ tale che $P(T \leq t_{0,975;15}) = 0,975$

Dalla tavola t, approssimativamente:

$$t_{0,975;15} \approx 2,131$$

Regione critica (test bilaterale):

$$C = \{t : |t| > 2,131\}$$

4. Decisione

- $|t_{\text{oss}}| = |2| = 2$
- $2 < 2,131$

Quindi:

- t_{oss} **non** cade nella regione critica
- **non rifiutiamo** H_0 .

5. Conclusione in parole

Al livello del 5%, i dati **non sono sufficienti** per concludere che il contenuto medio di zucchero sia diverso da 33 g.

La differenza osservata (35 vs 33) non è statisticamente significativa con questo campione.

Esercizio 2 – Test unilaterale sinistro (t-test)

Un insegnante pensa che il nuovo metodo didattico **abbassi** il punteggio medio in una prova standardizzata, rispetto al valore storico di $\mu_0 = 70$.

Si verifica su un campione di $n = 10$ studenti, ottenendo:

- media $\bar{X} = 66$
- deviazione standard campionaria $S = 8$

Assumi normalità dei punteggi. Al livello $\alpha = 0,05$, l'insegnante ha ragione?

1. Formulazione di (H_0) e (H_1)

Pensa che il punteggio **sia minore** di 70 $\rightarrow$ test a una coda verso il basso:

$$H_0 : \mu = 70$$

$$H_1 : \mu < 70$$

2. Statistica t

$$T = \frac{\bar{X} - \mu_0}{S/\sqrt{n}}$$

Dati:

- $\bar{X} = 66$
- $\mu_0 = 70$
- $(S = 8 - n = 10 \rightarrow \sqrt{n} \approx 3,162)$

$$T = \frac{66 - 70}{8/\sqrt{10}} = \frac{-4}{8/3,162} = \frac{-4}{2,529} \approx -1,58$$

Gradi di libertà:

$$df = 10 - 1 = 9$$

3. Regione critica (unilaterale sinistro)

Livello $\alpha = 0,05$, coda sinistra:

- cerchiamo $t_{0,05;9}$ tale che $P(T \leq t_{0,05;9}) = 0,05$
- dalla tavola t: $t_{0,05;9} \approx -1,833$

Regione critica:

$$C = \{t : t \leq -1,833\}$$

4. Decisione

- $t_{\text{oss}} \approx -1,58$
- $-1,58$ non è $\leq -1,833$

Quindi:

- non rifiutiamo H_0 .**

5. Conclusione

Al livello del 5%, **non ci sono prove sufficienti** per dire che il nuovo metodo abbia abbassato il punteggio medio rispetto a 70. La media è più bassa (66), ma il campione è piccolo e la variabilità alta.

Esercizio 3 – Test unilaterale destro e p-value

Una macchina riempie sacchetti di farina. Il peso nominale è $\mu_0 = 1$ kg.

La varianza è ignota, ma si assume normalità.

Un controllo di qualità su $n = 20$ sacchetti dà:

- $\bar{X} = 1,03$ kg
- $S = 0,05$ kg

Si vuole verificare se la macchina **sta riempiendo più del dovuto**. Livello $\alpha = 0,05$.

1. Ipotesi

Sospetto: “più del dovuto” $\rightarrow$ media maggiore:

$$H_0 : \mu = 1,00$$

$$H_1 : \mu > 1,00$$

2. Statistica t

$$T = \frac{\bar{X} - \mu_0}{S/\sqrt{n}}$$

Dati:

- $\bar{X} = 1,03$
- $\mu_0 = 1,00$
- $S = 0,05$
- $n = 20 \Rightarrow \sqrt{n} \approx 4,472$

$$T = \frac{1,03 - 1,00}{0,05/\sqrt{20}} = \frac{0,03}{0,05/4,472} = \frac{0,03}{0,01118} \approx 2,683$$

Gradi di libertà:

$$df = 20 - 1 = 19$$

3. p-value (test unilaterale destro)

Per un test a destra:

$$p = P(T \geq t_{\text{oss}}) = P(T \geq 2,683), \quad T \sim t_{19}$$

Dalla tavola t:

- $t_{0,975;19} \approx 2,093$
- $t_{0,99;19} \approx 2,539$

Poiché 2,683 è **oltre** il quantile 0,99, vuol dire che:

$$P(T \geq 2,683) < 0,01$$

Stimiamo $p \approx 0,008$ (ordine di grandezza: tra 0,005 e 0,01).

4. Decisione

- a livello $\alpha = 0,05$: $p \approx 0,008 < 0,05 \rightarrow$ **rifiutiamo H_0**
- anche a $\alpha = 0,01$ sarebbe significativo

5. Conclusione in parole

Ci sono forti evidenze statistiche che la macchina **riempia più di 1 kg in media**.

Quindi, dal punto di vista del controllo qualità, la macchina sta probabilmente sovradosando.

✓ Esempio con Python

Esempio: il farmaco funziona davvero?

Supponiamo di testare un farmaco che dovrebbe **ridurre la pressione sistolica**.

Ipotesi

- **H_0 (ipotesi nulla)**: la pressione media = 120 mmHg
- **H_1 (alternativa)**: la pressione media $\neq$ 120 mmHg

Abbiamo misurato la pressione di **20 pazienti** dopo il trattamento.

Dati osservati

```
import numpy as np

data = np.array([
    118, 121, 117, 119, 116,
    120, 118, 117, 119, 116,
    115, 118, 117, 119, 116,
    117, 118, 116, 119, 117
])

n = len(data)
sample_mean = data.mean()
sample_std = data.std(ddof=1)

sample_mean, sample_std
```

Supponiamo che il risultato sia:

```
Media campionaria ≈ 117.6
Deviazione standard ≈ 1.6
```

Test di ipotesi: t-test a una media

Dato che:

- il campione è piccolo
- la varianza è stimata dai dati

usiamo un **t-test a una media**.

Statistica test

$$t = \frac{\bar{x} - \mu_0}{s/\sqrt{n}}$$

In Python

```
from scipy import stats

mu0 = 120
```

```
t_stat, p_value = stats.ttest_1samp(data, mu0)
```

```
t_stat, p_value
```

Supponiamo che otteniamo:

```
t ≈ -6.6
p-value ≈ 0.000002
```

Interpretazione

- Il **p-value** è molto piccolo ($\ll 0.05$)
- I dati sono **estremamente improbabili** se la media fosse davvero 120

👉 **Rifiutiamo H_0**

Conclusione:

C'è evidenza statistica che la pressione media dopo il trattamento **non sia 120 mmHg** (e in particolare sembra più bassa).

Interpretazione intuitiva

Stiamo dicendo:

“Se la vera media fosse 120, sarebbe quasi impossibile osservare un campione con media 117.6 così concentrato. Quindi H_0 non è plausibile.”

Visualizzazione

```
import matplotlib.pyplot as plt

plt.hist(data, bins=8, edgecolor="black", alpha=0.7)
plt.axvline(sample_mean, color="red", label=f"Media campione = {sample_mean:.1f}")
plt.axvline(mu0, color="black", linestyle="--", label="Media  $H_0$  = 120")
plt.xlabel("Pressione sistolica")
plt.ylabel("Frequenza")
plt.legend()
plt.title("Dati osservati vs ipotesi nulla")
plt.show()
```

Cosa **NON** stiamo dicendo

“La probabilità che H_0 sia vera è 0.000002” “Il farmaco funziona al 100%”

Stiamo dicendo:

I dati osservati sono incompatibili con H_0 .

Riassunto finale

1. Formuliamo H_0 e H_1
2. Calcoliamo una statistica test
3. Otteniamo un p-value
4. Confrontiamo con α (es. 0.05)
5. Prendiamo una decisione **probabilistica**

Se vuoi, nel prossimo passo posso:

- mostrare **errori di tipo I e II**
- collegare il test all'**intervallo di confidenza**
- rifare lo stesso esempio in versione **bayesiana**

```
import numpy as np

data = np.array([
    118, 121, 117, 119, 116,
```

```

120, 118, 117, 119, 116,
115, 118, 117, 119, 116,
117, 118, 116, 119, 117
])

n = len(data)
sample_mean = data.mean()
sample_std = data.std(ddof=1)

print(sample_mean, sample_std)

```

```
117.65 1.5312533566021211
```

```

from scipy import stats

mu0 = 120

t_stat, p_value = stats.ttest_1samp(data, mu0)

print(t_stat, p_value)

```


```
-6.86334462480448 1.5077467069533214e-06
```

```

import matplotlib.pyplot as plt

plt.hist(data, bins=8, edgecolor="black", alpha=0.7)
plt.axvline(sample_mean, color="red", label=f"Media campione = {sample_mean:.1f}")
plt.axvline(mu0, color="black", linestyle="--", label="Media H0 = 120")
plt.xlabel("Pressione sistolica")
plt.ylabel("Frequenza")
plt.legend()
plt.title("Dati osservati vs ipotesi nulla")
plt.show()

```



test del chi-quadro per l'indipendenza statistica

Il test χ^2 (chi-quadro) di indipendenza serve a verificare se due variabili categoriche sono indipendenti tra loro oppure se esiste un'associazione.

In pratica:

La distribuzione di una variabile cambia al variare dell'altra?

Esempi tipici:

- Genere ↔ Preferenza politica
- Trattamento (A/B) ↔ Esito (Successo/Fallimento)
- Livello di istruzione ↔ Tipo di contratto

Ipotesi

- **Ipotesi nulla (H_0):** le due variabili sono indipendenti

- **Ipotesi alternativa (H_1):** le due variabili **non sono indipendenti** (c'è associazione)

Dati: tabella di contingenza

I dati devono essere in una **tabella a doppia entrata** (frequenze osservate):

	B1	B2	Totale
A1	20	30	50
A2	40	10	50
Totale	60	40	100

Frequenze attese

Se A e B fossero **indipendenti**, la frequenza nella cella (i, j) dovrebbe essere:

$$E_{ij} = \frac{(\text{totale riga } i) \cdot (\text{totale colonna } j)}{N}$$

Esempio:

$$E_{11} = \frac{50 \cdot 60}{100} = 30$$

Statistica test

Il test misura **quanto le frequenze osservate (O_{ij})** si discostano da quelle **attese (E_{ij})**:

$$\chi^2 = \sum_{i,j} \frac{(O_{ij} - E_{ij})^2}{E_{ij}}$$

Più grande è χ^2 , maggiore è la distanza da ciò che ci aspetteremmo se le variabili fossero indipendenti.

Distribuzione e gradi di libertà

La statistica χ^2 segue (approssimativamente) una **distribuzione chi-quadro** con:

$$\text{g.d.l.} = (r - 1)(c - 1)$$

dove:

- r = numero di righe
- c = numero di colonne

Decisione

Si calcola il **p-value**:

- se **p-value** < α (es. 0.05) → **rifiuto H_0** → le variabili **non sono indipendenti**
- se **p-value** $\geq \alpha$ → **non rifiuto H_0** → dati compatibili con indipendenza

Esempio intuitivo

Supponiamo di studiare:

Fumo (Si/No) e Malattia (Si/No)

Se fossero indipendenti:

- la percentuale di malati tra fumatori dovrebbe essere simile a quella dei non fumatori

Se invece osserviamo:

	Malato	Sano
Fuma	40	60
Non fuma	10	90

qui la differenza è evidente → il test χ^2 quantifica se questa differenza è **statisticamente significativa** o potrebbe essere dovuta al caso.

Esempio in Python

```
import numpy as np
from scipy.stats import chi2_contingency

# Tabella di contingenza (osservati)
```