


Regressione Lineare

Fondamenti Statistici e Applicazioni Pratiche

Parte 1: Teoria e Concetti Fondamentali



Cosa Impareremo

01

Comprendere il concetto di Regressione Lineare

Esploreremo come questo algoritmo fondamentale permette di modellare relazioni tra variabili e fare previsioni quantitative su dati continui.

02

Imparare il modello matematico $Y = \beta_0 + \beta_1 X + \epsilon$

Analizzeremo ogni componente dell'equazione: variabili dipendenti e indipendenti, coefficienti e termine di errore.

03

Scoprire come interpretare i coefficienti

Capiremo il significato pratico di intercetta e pendenza, traducendo i numeri in insight di business utilizzabili.

04

Applicare il metodo dei Minimi Quadrati (OLS)

Studieremo l'algoritmo che trova la retta ottimale minimizzando la distanza dai punti osservati.

05

Valutare la bontà del modello

Impareremo a misurare la qualità delle previsioni usando metriche come R^2 , RMSE e MAE, e a verificare le assunzioni statistiche.

Perché la Regressione Lineare?

Diffusione Globale

L'algoritmo supervisionato più usato al mondo, applicato in ogni settore da decenni.

Fondamentale

Base teorica per modelli più complessi come reti neurali e regressione logistica.

Semplice e Potente

Spesso la prima baseline da testare: facile da implementare ma sorprendentemente efficace.

Interpretabilità

Fornisce spiegazioni chiare e trasparenti dei parametri, essenziale per il business.



Applicazioni nel Mondo Reale

La regressione lineare trova impiego in molteplici settori professionali, dalla finanza alla medicina. Ogni applicazione sfrutta la capacità del modello di quantificare relazioni causa-effetto e generare previsioni affidabili.



Immobiliare

Prevedere il prezzo di vendita di una casa basandosi su caratteristiche come metratura, numero di stanze, posizione geografica e anno di costruzione.



Marketing

Analizzare l'impatto della spesa pubblicitaria su diversi canali (TV, Social Media, Radio) sul volume delle vendite per ottimizzare l'allocazione del budget.



Finanza

Valutare il rischio sistematico di un asset (Beta) analizzando la relazione lineare tra il rendimento del titolo e quello del mercato di riferimento.



Medicina

Studiare la relazione quantitativa tra il dosaggio di un farmaco somministrato e la variazione fisiologica misurata, come la pressione sanguigna.



FONDAMENTI

Apprendimento Supervisionato

Il processo di apprendimento in cui forniamo al modello un dataset contenente sia gli **input** che gli **output corretti** (etichette). È come insegnare a uno studente mostrando sia il problema che la soluzione.

1

Training Set

Il modello si allena su esempi "risolti", come uno studente che studia su un libro con le soluzioni alla fine. Ogni esempio mostra la relazione tra input e output desiderato.

2

Mapping

L'obiettivo è imparare la relazione matematica (funzione) che mappa l'input X all'output Y in modo generalizzabile, non solo memorizzando i dati.

3

Generalizzazione

Il test finale non è memorizzare i dati passati, ma prevedere correttamente l'output per nuovi dati mai visti prima, dimostrando vera comprensione.



Regressione vs Classificazione

Entrambi sono problemi di apprendimento supervisionato, ma differiscono nel tipo di output che producono. La scelta tra i due dipende dalla natura del problema che vogliamo risolvere.

Regressione

Prevede valori numerici **continui**.
Risponde alla domanda *"Quanto?"*

Esempi pratici:

- Prezzo delle case (€)
- Temperatura atmosferica (°C)
- Fatturato aziendale annuale
- Distanza percorsa (km)
- Peso corporeo (kg)

La regressione cerca una **relazione continua** che possa assumere infiniti valori.

Classificazione

Prevede categorie **discrete** (etichette).
Risponde alla domanda *"Quale?"*

Esempi pratici:

- Email: Spam/Non-Spam
- Immagine: Gatto/Cane/Uccello
- Diagnosi: Malato/Sano
- Cliente: Fedele/A Rischio
- Sentiment: Positivo/Neutro/Negativo

La classificazione cerca un **confine di separazione** tra categorie distinte.

Notazione del Dataset

Per comunicare con precisione, utilizziamo una notazione matematica standard che descrive la struttura dei nostri dati. Familiarizzare con questi simboli è essenziale per comprendere la letteratura scientifica.

m - Numero di Esempi

Il numero totale di righe nel training set. Se abbiamo venduto 1000 case, allora $m = 1000$. Rappresenta la dimensione del nostro campione.

x - Variabile di Input

Le caratteristiche (features) usate per la previsione. Ad esempio, la metratura di una casa espressa in metri quadrati. Può essere un vettore se abbiamo più features.

y - Variabile di Output

La variabile target da prevedere, cioè quello che vogliamo stimare. Nel nostro esempio immobiliare, è il prezzo di vendita in euro.

$(x^{(i)}, y^{(i)})$ - Esempio Singolo

L' i -esimo esempio specifico nel dataset. Ad esempio, $(x^{(3)}, y^{(3)})$ rappresenta la terza casa: la sua metratura e il suo prezzo. L'apice indica l'indice, non una potenza.

L'Equazione della Regressione Lineare

$$Y = \beta_0 + \beta_1 X + \varepsilon$$

Questa equazione elegante cattura l'essenza della regressione lineare. Ogni simbolo ha un significato preciso e rappresenta un concetto fondamentale del modello.



Y - Variabile Dipendente

Il valore che vogliamo prevedere o spiegare. È l'output del nostro modello, chiamato anche target o variabile risposta.



X - Variabile Indipendente

Il dato che possediamo e usiamo per fare la previsione. È l'input (feature) che utilizziamo come predittore.



β_0 - Intercetta

Il valore atteso di Y quando X è uguale a 0. Geometricamente, rappresenta il punto in cui la retta interseca l'asse verticale.



β_1 - Coefficiente Angolare

La pendenza della retta. Indica di quanto cambia Y per ogni unità aggiuntiva di X, determinando la forza della relazione.



ε - Termine di Errore

Rappresenta la variabilità di Y che X non riesce a spiegare. Include fattori omessi, errori di misurazione e casualità intrinseca.

Componenti del Modello: Parte 1

Approfondiamo il significato delle prime tre componenti dell'equazione di regressione, partendo dalle variabili fondamentali fino al concetto di intercetta.

Y - Variabile Dipendente

La variabile che vogliamo prevedere o spiegare. È l'output del modello, chiamata "dipendente" perché dipende dal valore di X.

Esempio concreto: Il prezzo della casa in euro (€). È ciò che vogliamo stimare basandoci su altre informazioni disponibili.

X - Variabile Indipendente

Il dato che possediamo e usiamo per fare la previsione. È l'input (feature) del modello, chiamata "indipendente" perché la controlliamo o osserviamo direttamente.

Esempio concreto: La metratura della casa in metri quadrati (m²). È l'informazione che utilizziamo per fare la nostra stima.

β_0 - Intercetta

Il valore atteso di Y quando X è uguale a 0. Rappresenta il punto in cui la retta interseca l'asse verticale nel piano cartesiano.

Esempio concreto: Il valore base (teorico) della casa quando la metratura è zero. In pratica, può rappresentare costi fissi come il valore del terreno o permessi.

Componenti del Modello: Parte 2

Completiamo l'analisi dell'equazione esaminando la pendenza e il termine di errore, due elementi cruciali per comprendere la qualità e i limiti del modello.

β_1 - Coefficiente Angolare (Pendenza)

La pendenza della retta rappresenta il cuore interpretativo del modello. Indica di quanto cambia Y per ogni unità aggiuntiva di X, determinando sia la forza che la direzione della relazione tra le variabili.

Interpretazione pratica: Se $\beta_1 = 3000$, significa che ogni metro quadrato in più aumenta il prezzo previsto di 3000€. Un β_1 positivo indica una relazione diretta, mentre un β_1 negativo indica una relazione inversa.

Implicazioni: Un coefficiente vicino a zero suggerisce una relazione debole o assente, mentre valori elevati indicano una forte dipendenza di Y da X.

ϵ - Termine di Errore (Residuo)

Rappresenta la variabilità di Y che la variabile X non riesce a spiegare. Nessun modello è perfetto: ci sarà sempre una componente di incertezza non catturata.

Fonti dell'errore:

- Fattori rilevanti omessi dal modello (es. zona, stato di manutenzione)
- Errori di misurazione negli strumenti o nei dati raccolti
- Casualità intrinseca e variabilità naturale del fenomeno

Esempio concreto: La differenza tra il prezzo reale di vendita di una casa (€250.000) e quello stimato dal modello (€245.000). Il residuo è $\epsilon = €5.000$.

Interpretazione Geometrica

La regressione lineare può essere compresa visivamente come il tentativo di tracciare una linea retta attraverso una nuvola di punti dispersi. Questa rappresentazione geometrica rende intuitivo il funzionamento dell'algoritmo.

Ordine nel Caos

La regressione traccia una linea retta attraverso la "nuvola" dispersa dei dati osservati. I punti rappresentano le osservazioni reali, mentre la linea rappresenta il modello che cerca di catturare il pattern sottostante.

Minimizzare la Distanza

L'obiettivo è trovare la retta che passa "il più vicino possibile" a tutti i punti contemporaneamente. Non esiste una linea che passa per tutti i punti, quindi cerchiamo il miglior compromesso.

Il Residuo

La distanza verticale tra un punto reale e la retta rappresenta l'errore di previsione per quella osservazione. La somma di tutti questi errori (al quadrato) deve essere minimizzata.

Caso Studio: Previsione Prezzi Case

Scenario

Sei un agente immobiliare che opera nel competitivo mercato di **Roma, Italia**. Ogni giorno clienti ti chiedono valutazioni immediate di proprietà.

Domanda di Business

"Quanto vale questa casa?" - Una domanda apparentemente semplice ma che richiede esperienza, dati storici e un metodo affidabile per generare stime accurate.

Dati Disponibili


Hai accesso allo storico delle vendite passate degli ultimi 3 anni, con informazioni su **Metratura (m²)** e **Prezzo di Vendita (€)** per centinaia di transazioni.

La Sfida

Un cliente ti mostra una casa di **110 m²**, una metratura che non compare esattamente nel tuo storico. Come puoi stimare il prezzo in modo affidabile?

Soluzione

Costruire un modello di **Regressione Lineare** che impari la relazione tra metratura e prezzo dai dati storici, permettendoti di interpolare e fare previsioni anche per metrature mai viste.



Visualizzazione dei Dati

Dataset

Dati storici di vendita immobiliare di una città. Il grafico mostra chiaramente una relazione positiva: all'aumentare della dimensione, tende ad aumentare anche il prezzo.

Obiettivo

Identificare e quantificare la relazione tra la dimensione della casa (asse X) e il suo prezzo di vendita (asse Y). La linea rossa rappresenta il nostro modello di regressione lineare che cattura questo trend.

❏ **Nota importante:** I punti blu rappresentano le osservazioni reali (dati osservati), mentre la linea rossa rappresenta il modello (regressione). La dispersione dei punti attorno alla linea indica la variabilità non spiegata dal modello.

Come Stimare i Coefficienti?

Abbiamo visto l'equazione teorica, ma come troviamo concretamente i valori di β_0 e β_1 ? Questo è il cuore del problema statistico della regressione.

Il Problema

Non conosciamo i veri parametri β_0 e β_1 della popolazione. Questi valori "veri" sono teorici e inaccessibili nella realtà.

I Dati

Abbiamo solo un campione di osservazioni (x, y) - un sottoinsieme limitato della popolazione totale.
Dobbiamo lavorare con ciò che abbiamo.

L'Obiettivo

Calcolare delle stime b_0 e b_1 basate sui dati del campione. Queste sono approssimazioni dei parametri veri, e dipendono dai dati che raccogliamo.

La Domanda Cruciale

Come troviamo la retta **migliore** tra le infinite possibili? Serve un criterio oggettivo per definire cosa significa "migliore". La risposta è il **Metodo dei Minimi Quadrati**.

Il Metodo dei Minimi Quadrati (OLS)

OLS sta per *Ordinary Least Squares*, ed è l'algoritmo standard per stimare i coefficienti della regressione lineare. Fu sviluppato da Gauss e Legendre all'inizio del XIX secolo.

1

L'Obiettivo

Vogliamo trovare la retta che minimizza l'errore complessivo rispetto a tutti i punti del dataset. Ma come definiamo "errore complessivo"?

2

Il Residuo

Per ogni punto, calcoliamo la differenza tra il valore reale (y) e quello previsto dalla retta ($\hat{y}$). Questo scarto si chiama residuo: $e = y - \hat{y}$.

3

La Strategia

Non minimizziamo la somma semplice degli errori (che potrebbe essere zero anche con una retta pessima), ma la somma dei loro quadrati.

Somma dei Quadrati dei Residui (SSR)

$$SSR = \sum_{i=1}^m (y_i - \hat{y}_i)^2$$

Perché al quadrato?

- Rende tutti gli errori positivi, evitando che +5 e -5 si annullino a vicenda
- Penalizza maggiormente gli errori grandi (outlier): un errore di 10 conta 100 volte più di un errore di 1
- Produce una funzione matematicamente "liscia" e derivabile

Il Risultato

L'algoritmo OLS trova i valori di b_0 e b_1 che rendono SSR il più piccolo possibile. Questa è la retta "ottimale" secondo il criterio dei minimi quadrati.

Formule OLS

Le formule matematiche che permettono di calcolare i coefficienti ottimali. Queste equazioni derivano dalla minimizzazione della funzione SSR usando il calcolo differenziale.

1. Pendenza (b_1)

$$b_1 = \frac{\text{Cov}(X, Y)}{\text{Var}(X)} = \frac{\sum_{i=1}^m (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^m (x_i - \bar{x})^2}$$

Rapporto tra covarianza (come variano insieme X e Y) e varianza di X (quanto varia X da solo). Indica la relazione tra X e Y rispetto alla variabilità dell'input.

Interpretazione: Misura quanto fortemente X e Y si muovono insieme, normalizzato per la dispersione di X. Se X aumenta di 1, Y aumenta (in media) di b_1 .

2. Intercetta (b_0)

$$b_0 = \bar{y} - b_1 \bar{x}$$

Calcolata dopo b_1 , garantisce matematicamente che la retta passi sempre attraverso il punto medio $(\bar{x}, \bar{y})$ del dataset. Questo è un risultato elegante della teoria.

Nota importante: $\bar{x}$ e $\bar{y}$ sono le medie campionarie di X e Y, calcolate come $\bar{x} = (1/m)\sum x_i$ e $\bar{y} = (1/m)\sum y_i$.

Interpretazione: Coefficiente Angolare (β_1)

β_1

Il coefficiente angolare è il parametro più importante del modello perché quantifica la **forza e la direzione** della relazione tra X e Y.

Significato Matematico

Indica la variazione attesa di **Y** per ogni aumento unitario di **X**. È la pendenza della retta nel piano cartesiano.

Esempio Pratico

Se $b_1 = 3000$ nel contesto immobiliare, significa che ogni metro quadrato aggiuntivo di superficie aumenta il prezzo previsto della casa di 3000€. Se la casa passa da 80 m² a 81 m², il prezzo stimato aumenta di 3000€.

Segno del Coefficiente

- $\beta_1 > 0$: Relazione positiva (crescente) - all'aumentare di X, aumenta anche Y
- $\beta_1 < 0$: Relazione negativa (decrescente) - all'aumentare di X, diminuisce Y
- $\beta_1 \approx 0$: Nessuna relazione lineare significativa tra le variabili



Interpretazione: Intercetta (β_0)

Definizione Matematica

È il valore previsto di Y quando $X = 0$. Geometricamente, è il punto in cui la retta interseca l'asse verticale (asse Y) del piano cartesiano.

Funzione

Serve come "punto di partenza" o livello base della variabile dipendente, indipendentemente dal valore del predittore. Ancora matematicamente il modello.

Attenzione al Significato Pratico

L'intercetta ha senso fisico **solo se $X = 0$ è plausibile** nel contesto del problema. In molti casi (es. altezza, peso, metratura) X non può essere zero: qui l'intercetta è un **ancoraggio matematico** e non va interpretata letteralmente.

Esempio Immobiliare


"Una casa di 0 m² costa 50.000€"

Questa affermazione non ha senso fisico diretto, ma l'intercetta potrebbe rappresentare implicitamente il valore del terreno, dei permessi, o altri costi fissi non legati alla metratura. **Non è un errore del modello**, è semplicemente un parametro matematico necessario per definire la retta.

Correlazione vs Regressione

Due concetti spesso confusi ma con scopi e interpretazioni diverse. Entrambi studiano la relazione tra variabili, ma con approcci complementari.

Correlazione



Obiettivo

Misurare la **forza** e la **direzione** dell'associazione lineare tra due variabili. Risponde alla domanda: "Quanto sono legate X e Y?"

Natura


Simmetrica: non distingue tra causa ed effetto. $\text{Corr}(X, Y) = \text{Corr}(Y, X)$. Nessuna variabile è privilegiata.

Output

Un singolo numero (r) compreso tra -1 e +1. Fornisce solo intensità e direzione, non permette previsioni quantitative.

 **Regola pratica:** Usa la correlazione per esplorare i dati e identificare associazioni. Usa la regressione quando hai una direzione causale ipotizzata e vuoi fare previsioni.

Regressione



Obiettivo

Modellare la relazione per fare **previsioni** quantitative. Risponde alla domanda: "Dato un valore di X, quale sarà il valore di Y?"

Natura


Asimmetrica: assume che X influenzi Y (non viceversa). $Y = f(X)$ è diverso da $X = f(Y)$. C'è una direzione causale ipotizzata.

Output

Un'equazione matematica completa: $Y = b_0 + b_1X$. Permette di calcolare previsioni specifiche per nuovi valori di X.

Il Coefficiente di Correlazione (r)

Un numero puro che misura l'intensità e la direzione della relazione lineare tra due variabili, indipendentemente dalle unità di misura. È standardizzato e varia sempre tra -1 e +1.



-1

Perfetta Negativa

Tutti i punti giacciono esattamente su una retta decrescente.
Relazione inversa perfetta: quando X aumenta, Y diminuisce in modo perfettamente prevedibile.

0

Assenza


Nessuna relazione lineare. I punti formano una nuvola senza pattern. X e Y sono linearmente indipendenti (potrebbero comunque avere relazioni non lineari).

+1

Perfetta Positiva

Tutti i punti giacciono esattamente su una retta crescente.
Relazione diretta perfetta: quando X aumenta, Y aumenta in modo perfettamente prevedibile.

Interpretazione dell'Intensità



$|r| < 0.3$

Correlazione Debole - Relazione quasi trascurabile

$0.3 < |r| < 0.7$

Correlazione Moderata - Relazione presente ma con variabilità

$|r| > 0.7$

Correlazione Forte - Relazione marcata e consistente

Correlazione vs Causalità

Correlazione $\neq$ Causalità

Uno degli errori più comuni in statistica: assumere che una correlazione implichi automaticamente un rapporto causa-effetto. La presenza di una correlazione **non implica** necessariamente che una variabile causi l'altra.

L'Osservazione Ingannevole

Dati osservati: Quando aumentano le vendite di gelati, aumentano anche gli attacchi di squali nelle spiagge.

Conclusione errata: "I gelati attirano gli squali!" o "Gli squali fanno vendere gelati!"

Questo è un classico esempio di correlazione spuria (falsa). Non c'è nessuna relazione causale diretta tra le due variabili.

La Variabile Nascosta

La vera causa: È l'**Estate** (temperatura elevata).

Il caldo estivo causa:

- Aumento del consumo di gelati (la gente cerca refrigerio)
- Aumento delle persone che vanno al mare (più bagnanti = più interazioni con squali)

Le due variabili sono correlate perché entrambe dipendono da una terza variabile comune (temperatura/stagione), non perché una causa l'altra.

❏ **Lezione fondamentale:** Per affermare una relazione causale servono esperimenti controllati, teoria solida e meccanismi chiari. La correlazione è solo il primo indizio, mai la prova definitiva.

Riepilogo Parte 1

Abbiamo gettato le fondamenta teoriche della regressione lineare, esplorando il modello matematico, il metodo di stima e i principi di interpretazione. Consolidiamo i concetti chiave.

01

Il Modello

La regressione lineare assume una relazione rettilinea tra input (X) e output (Y). L'equazione fondamentale è $Y = \beta_0 + \beta_1 X + \varepsilon$, dove β_0 è l'intercetta, β_1 la pendenza, e ε l'errore residuo.

03

Interpretazione

β_1 (Pendenza): Quanto cambia Y se X aumenta di 1 unità. Misura la forza della relazione.

β_0 (Intercetta): Valore di base quando X è 0 (va interpretata con cautela nel contesto).

02

Il Metodo OLS

Stimiamo i coefficienti β_0 e β_1 utilizzando il metodo dei Minimi Quadrati Ordinari (OLS), che minimizza la **Somma dei Quadrati dei Residui (SSR)**. Questo garantisce la retta "ottimale" secondo un criterio matematico preciso.

04

Obiettivo

A differenza della semplice correlazione che misura solo l'associazione, la regressione ci permette di costruire un modello predittivo per fare **previsioni quantitative** su nuovi dati mai osservati prima.



Parte 2

Valutazione e Pratica

Dopo aver compreso la teoria, passiamo a misurare la qualità del modello e ad implementarlo con codice Python. Dalla teoria all'applicazione pratica.



Metriche di Valutazione

- Coefficiente R^2 (R-quadro)
- Errore RMSE (Root Mean Squared Error)
- Errore MAE (Mean Absolute Error)
- Confronto e interpretazione delle metriche



Assunzioni del Modello

- Linearità della relazione
- Indipendenza degli errori
- Omoschedasticità (varianza costante)
- Normalità dei residui



Python Lab

- Libreria Scikit-learn
- Preparazione e pulizia dei dati
- Training & Test split
- Analisi dei risultati

Valutare la Bontà del Modello

Non basta calcolare una retta di regressione. Dobbiamo quantificare quanto possiamo fidarci delle sue previsioni. Un modello non validato è inutile o, peggio, pericoloso per le decisioni di business.

Precisione

"Quanto sbaglia il modello in media?"

Misuriamo l'errore medio delle previsioni usando metriche come **RMSE** e **MAE**. Ci dicono di quanto ci discostiamo mediamente dalla realtà.

Spiegazione

"Quanta variabilità dei dati abbiamo catturato?"

Il coefficiente **R²** quantifica la percentuale di varianza spiegata dal modello. Un R² alto indica che il modello cattura bene il fenomeno.

Validità

"Le assunzioni teoriche sono rispettate?"

L'**analisi dei residui** verifica se le ipotesi statistiche del modello OLS sono soddisfatte. Senza questo, le stime potrebbero essere distorte.



Coefficiente di Determinazione (R^2)

Rappresenta la **percentuale di varianza** della variabile dipendente (Y) che viene spiegata dal modello. È la metrica più citata per valutare la bontà di adattamento di una regressione.

$$R^2 = 1 - \frac{SSR}{SST} = 1 - \frac{\sum (y_i - \hat{y}_i)^2}{\sum (y_i - \bar{y})^2}$$

L'Intuizione

È come il "voto" del modello, espresso come proporzione da 0 a 1 (o 0% a 100%). **$R^2 = 0.80$** significa che il modello ha "spiegato" l'80% della variabilità osservata nei dati, mentre il 20% rimane inspiegato (errore residuo).


Componenti

- **SSR (Sum of Squared Residuals):** Errore del modello - quanto i punti si discostano dalla retta
- **SST (Total Sum of Squares):** Variabilità totale dei dati - quanto i punti si discostano dalla media



R^2 può essere visto come un confronto: quanto è migliore il nostro modello rispetto a un modello "stupido" che prevede sempre la media? Se $R^2 = 0$, il modello non fa meglio della media. Se $R^2 = 1$, il modello è perfetto.

Interpretazione di R²



SST — Variabilità totale (verde)

Linee verdi puntinate verticali

- vanno dalla **media di Y** (linea verde orizzontale)
- fino ai **valori reali** (punti neri)

Significato:

Quanto ogni valore reale di Y si discosta dalla **media**.

SST = il problema totale da spiegare, prima di usare qualsiasi modello.

SSE — Errore residuo (rosso)

Linee rosse tratteggiate verticali

- vanno dalla **retta di regressione** (linea blu)
- fino ai **valori reali** (punti neri)

Significato:

Quanto il modello **sbaglia ancora** dopo aver fatto la previsione.

SSE = **errore che rimane**, quello che il modello non spiega.

SSR — Variabilità spiegata (blu ↔ verde)

NON è disegnato con segmenti, ma si vede così:

- distanza tra **retta blu** e **linea verde della media**


Significato:

Quanto la retta si allontana dalla media → quanto il modello spiega.

SSR = parte di variabilità catturata dal modello

Interpretazione di R^2

Il Coefficiente di Determinazione (R^2) fornisce una misura intuitiva dell'efficacia del modello. Non esiste un valore "perfetto", poiché l'interpretazione dipende dal dominio e dalla complessità del fenomeno, ma possiamo categorizzarlo così:



Interpretazione di R^2

Non esiste un valore "buono" universale per R^2 . Il contesto del problema e la natura dei dati determinano cosa considerare soddisfacente. Vediamo delle linee guida generali.



Basso (< 0.5)

Il modello spiega meno del 50% della variabilità. I dati sono molto dispersi attorno alla retta, oppure mancano variabili esplicative importanti. Potrebbe essere necessario aggiungere predittori o considerare relazioni non lineari.



Moderato (0.5 - 0.75)

Buon adattamento per fenomeni complessi o dati reali con rumore intrinseco. In molti contesti applicativi (scienze sociali, economia) questo range è considerato eccellente, data la complessità dei fenomeni studiati.



Alto (> 0.75)

Il modello cattura quasi tutta la variabilità osservata. Ottimo risultato, ma attenzione: se R^2 si avvicina troppo a 1.00, potrebbe indicare **overfitting** (il modello memorizza i dati invece di generalizzare) o un errore nei dati.

Il Contesto è Re

Un valore "buono" dipende fortemente dal dominio applicativo.

In Fisica: Ci aspettiamo $R^2 > 0.99$ perché le leggi fisiche sono deterministiche e precise. La gravità non ha "giorni no".

Nelle Scienze Sociali: Un $R^2 = 0.30$ può essere un risultato eccellente, data l'enorme complessità del comportamento umano e la presenza di innumerevoli fattori confondenti.

Root Mean Squared Error (RMSE)

Rappresenta la deviazione standard dei residui. Indica quanto, in media, le previsioni del modello si discostano dai valori reali. È una delle metriche più utilizzate per quantificare l'errore di previsione.

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$$



Unità di Misura

È espresso nella **stessa unità** della variabile target (Y). Se prevediamo prezzi in euro, l'RMSE è in euro. Questo lo rende direttamente interpretabile: "Il modello sbaglia mediamente di X euro".



Interpretazione

Valori più bassi indicano un modello migliore. Un RMSE di 0 indica un adattamento perfetto (impossibile nella realtà con dati reali). È l'errore "tipico" che ci aspettiamo di commettere su una nuova previsione.



Sensibilità

Poiché eleva gli errori al quadrato prima di fare la media, **penalizza fortemente gli errori grandi** (outlier). Un singolo errore molto grande influenza pesantemente l'RMSE. Questo può essere un vantaggio o uno svantaggio a seconda del contesto.

Mean Absolute Error (MAE)

La media delle differenze assolute tra i valori previsti e quelli reali. Misura l'errore medio senza considerare la direzione (positivo o negativo) e senza penalizzare eccessivamente gli outlier.

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$

Unità di Misura

Come l'RMSE, è espresso nella **stessa unità** della variabile target (Y). Questo garantisce interpretabilità immediata nel contesto del problema.

Interpretazione

Molto intuitivo da spiegare a stakeholder non tecnici: "In media, il modello sbaglia di X euro". Tratta tutti gli errori allo stesso modo: un errore di 10 conta esattamente 10 volte più di un errore di 1.


Robustezza

A differenza dell'RMSE, **non penalizza eccessivamente** gli errori molto grandi (outlier). È più stabile e affidabile in presenza di dati anomali o distribuzioni con code pesanti. Preferibile quando gli outlier non sono particolarmente critici.

Confronto: RMSE vs MAE

Due metriche complementari che misurano l'errore in modi diversi. La scelta tra le due dipende dalla sensibilità agli outlier che vogliamo nel nostro sistema di valutazione.

RMSE



Comportamento


Sensibile agli Outlier. Gli errori grandi vengono elevati al quadrato prima della media, dominando il calcolo finale e influenzando pesantemente il risultato.

Esempio: Errore = 10 → Contributo al calcolo = $10^2 = 100$

Quando Usarlo

Preferisci RMSE quando gli errori grandi sono particolarmente inaccettabili o pericolosi (es. previsioni di sicurezza, dosaggio farmaci, investimenti ad alto rischio). Vuoi che il modello sia fortemente penalizzato per errori grossolani.

MAE



Comportamento

Robusto agli Outlier. Tratta tutti gli errori in modo lineare e proporzionale. Un errore grande vale esattamente quanto la sua grandezza reale, senza amplificazioni.

Esempio: Errore = 10 → Contributo al calcolo = $|10| = 10$

Quando Usarlo

Preferisci MAE quando vuoi una metrica facile da interpretare e comunicare, specialmente se nel dataset ci sono outlier naturali che non vuoi penalizzare eccessivamente. Più adatto per reporting a stakeholder non tecnici.

☐ **Regola empirica:** RMSE sarà sempre maggiore o uguale a MAE. Se $RMSE \gg MAE$, significa che il modello ha problemi significativi con alcuni outlier. Se $RMSE \approx MAE$, gli errori sono abbastanza uniformi.

Metriche in Pratica

Vediamo un esempio concreto per capire come si comportano MAE e RMSE di fronte agli stessi errori. Questo esempio numerico chiarisce perché RMSE è sempre maggiore o uguale a MAE.

Casa	Reale (y)	Previsto ($\hat{y}$)	Errore (e)	Errore ²
A	200k	210k	+10	100
B	300k	280k	-20	400
C	400k	400k	0	0

Calcolo MAE

$$MAE = \frac{|10| + |-20| + |0|}{3} = \frac{30}{3} = 10.0$$

Il MAE ci dice che in media il modello sbaglia di **10.000€** per casa. Interpretazione semplice e diretta.

Calcolo RMSE

$$RMSE = \sqrt{\frac{100 + 400 + 0}{3}} = \sqrt{\frac{500}{3}} = \sqrt{166.67} = 12.9$$

L'RMSE è **12.900€**, significativamente più alto del MAE perché penalizza l'errore grossolano della Casa B.

 **Nota importante:** RMSE > MAE (12.9 > 10.0) in questo caso perché l'RMSE penalizza maggiormente l'errore più grande (-20k) della Casa B. La differenza tra RMSE e MAE indica la presenza di variabilità negli errori.

Assunzioni Fondamentali

Il modello OLS è il "migliore" stimatore (BLUE - Best Linear Unbiased Estimator) solo se queste quattro condizioni fondamentali sono rispettate. Violazioni sistematiche possono invalidare le conclusioni.

1. Linearità

La relazione tra la variabile indipendente (X) e la media della variabile dipendente (Y) deve essere lineare. Se la relazione vera è curva o esponenziale, una retta non catturerà bene il fenomeno.

2. Indipendenza

Gli errori (residui) sono indipendenti tra loro. Non c'è autocorrelazione: l'errore su un'osservazione non fornisce informazioni sull'errore della prossima. Particolarmente importante nelle serie temporali.

3. Omoschedasticità

La varianza degli errori è costante per tutti i valori di X. L'incertezza della previsione non deve "allargarsi" o "restringersi" al variare di X. Dal greco: stesso (homo) spargimento (skedasis).


4. Normalità

Gli errori seguono una distribuzione Normale (Gaussiana) con media zero. Fondamentale per calcolare intervalli di confidenza, test di ipotesi e p-value. Meno critica con grandi campioni (teorema del limite centrale).

Assunzione 1: Linearità

Il modello assume che la relazione tra le variabili sia approssimabile con una linea retta. Se la vera relazione è curvilinea, il modello lineare produrrà previsioni sistematicamente distorte.


Corretto: Relazione Lineare



I punti sono distribuiti casualmente attorno alla retta senza pattern sistematico. Il modello cattura efficacemente il trend dei dati. I residui non mostrano struttura.

Diagnosi: Scatter plot mostra una nuvola oblunga attorno a una retta. R^2 elevato, residui casuali.

Violazione: Relazione Curvilinea




I punti seguono una curva (parabolica o esponenziale), non una retta. La linea sbaglia sistematicamente: sovrastima al centro, sottostima agli estremi.

Soluzione: Trasformare i dati (es. $\log(Y)$, $\sqrt{X}$) o usare regressione polinomiale: $Y = \beta_0 + \beta_1 X + \beta_2 X^2$.

Assunzione 2: Indipendenza

Gli errori (residui) non devono avere "memoria" o struttura temporale. Il valore di un errore non deve permettere di prevedere l'errore successivo. Questa assunzione è spesso violata nei dati temporali o spaziali.

Indipendenza (OK)



I residui sono distribuiti casualmente nel tempo o nello spazio. Nessun pattern visibile: alternanza casuale di positivi e negativi.

Autocorrelazione (NO)



Pattern ciclico, onde, o trend nei residui. Tipico nelle **serie temporali** (prezzi azioni, vendite mensili) o dati spaziali (quartieri vicini).

❏ **Perché è importante:** L'autocorrelazione invalida gli errori standard delle stime, rendendo i test statistici (p-value, intervalli di confidenza) inaffidabili anche se le previsioni sembrano buone.

Assunzione 3: Omoschedasticità

Dal greco *homos* (uguale) e *skedasis* (dispersione). La **varianza degli errori** deve rimanere costante lungo tutto il range dei dati. L'incertezza della previsione non deve dipendere dal valore di X.

Corretto: Omoschedasticità



Residui contenuti in una fascia orizzontale di ampiezza costante. L'incertezza (spread verticale) è la stessa per X piccolo o grande.

Interpretazione: Possiamo fidarci allo stesso modo delle previsioni in tutto il range di X.

Test formale: Breusch-Pagan o White test per rilevare eteroschedasticità. Se violata, i coefficienti rimangono corretti ma gli errori standard sono sbagliati.

Violazione: Eteroschedasticità




Residui formano un "imbuto" o "cono": l'errore aumenta (o diminuisce) con X. Comune nei dati economici (ricchezza, reddito).

Soluzione: Trasformazione logaritmica $\log(Y)$, regressione pesata (WLS), o errori robusti (Huber-White).

Assunzione 4: Normalità

Gli errori (residui) devono seguire una **distribuzione Normale** (Gaussiana) centrata sullo zero. Questa assunzione è cruciale per l'inferenza statistica, ma meno critica per le previsioni pure.

Distribuzione Ideale dei Residui



Istogramma dei residui ideale: forma a campana simmetrica centrata su zero.

La maggior parte degli errori è piccola (vicino a zero), con pochi errori grandi simmetrici in entrambe le direzioni. La curva segue la famosa "campana di Gauss".

Perché è importante?

È fondamentale per l'inferenza statistica: calcolo affidabile dei **p-value**, **intervalli di confidenza**, e test di ipotesi sui coefficienti.

Se violata, le previsioni puntuali possono ancora essere valide, ma non possiamo fidarci degli intervalli di confidenza.

Analisi dei Residui

Guida rapida alla diagnosi visiva: interpretare i pattern grafici per identificare problemi e migliorare il modello. L'analisi dei residui è lo strumento principale per verificare le assunzioni.



Nuvola Casuale

I residui non hanno struttura riconoscibile: dispersione casuale attorno allo zero, senza pattern, trend o forma.

✓ **Modello Valido** - Tutte le assunzioni rispettate. Il modello ha catturato tutte le informazioni sistematiche nei dati.



Forma a U

Residui formano una parabola o curva: positivi agli estremi, negativi al centro (o viceversa).

🔍 **Azione:** Relazione non lineare non catturata. Aggiungi termini polinomiali (X^2 , X^3) o trasforma i dati.



Imbuto

La varianza dell'errore cresce (o diminuisce) con X: forma a cono o imbuto.

🔍 **Azione:** Eteroschedasticità. Trasforma Y con logaritmo, radice quadrata, o usa regressione pesata (WLS).



Outlier

Punti isolati molto distanti dalla massa principale dei residui.

⚠️ **Investigare:** Errore nei dati? Anomalia reale? Valuta se rimuovere, correggere, o usare metodi robusti agli outlier.

Librerie Python per Data Science

Il toolkit essenziale per implementare la regressione lineare in modo professionale. Queste quattro librerie formano l'ecosistema standard della data science in Python.



pandas

Manipolazione Dati

Struttura i dati in **DataFrame** (tabelle bidimensionali). Fondamentale per caricare file CSV, Excel, SQL e pulire i dati. Offre operazioni intuitive simili a Excel ma molto più potenti.



matplotlib

Visualizzazione

Crea grafici professionali: scatter plot, istogrammi, boxplot. Essenziale per visualizzare la retta di regressione, i residui e comunicare i risultati visivamente.



NumPy

Calcolo Numerico

Array multidimensionali e operazioni matematiche ad alte prestazioni. Alla base di tutto il calcolo scientifico Python. Implementa algebra lineare, statistica e funzioni matematiche ottimizzate.



scikit-learn

Machine Learning

Libreria standard per ML. Include **LinearRegression** e decine di altri algoritmi pronti all'uso. API uniforme e documentazione eccellente.

Workflow di Machine Learning

Dal dato grezzo alla previsione: i 6 passi fondamentali del processo di sviluppo di un modello predittivo. Ogni fase ha un ruolo specifico e critico per il successo del progetto.

01

Raccolta Dati

Importazione del dataset da diverse fonti (CSV, Excel, database SQL, API) e prima esplorazione delle variabili. Comprensione della struttura, delle tipologie di dati e delle dimensioni del dataset.

03

Train/Test Split

Divisione strategica dei dati: tipicamente 80% per addestrare il modello (training set) e 20% per testarlo (test set). Fondamentale per valutare la capacità di generalizzazione.

05

Valutazione

Verifica rigorosa delle performance sul Test Set usando metriche come R^2 , RMSE, MAE. Confronto con baseline e analisi dei residui per verificare le assunzioni.

02

Pre-processing

Pulizia approfondita: gestione dei valori mancanti (eliminazione o imputazione), rimozione dei duplicati, identificazione e trattamento degli outlier, selezione delle feature rilevanti.

04

Training

L'algoritmo (es. LinearRegression) elabora i dati di training, applica OLS e calcola i coefficienti β_0 e β_1 che minimizzano l'errore quadratico medio.

06

Deploy

Utilizzo del modello validato per fare previsioni su nuovi dati reali in produzione. Monitoraggio continuo delle performance nel tempo (drift detection).

Preparazione dei Dati

"Garbage In, Garbage Out" - La qualità del modello non può mai superare la qualità dei dati di input.

La fase di preparazione richiede spesso l'80% del tempo totale di un progetto di data science, ma è la più importante. Dati sporchi portano inevitabilmente a modelli inaffidabili.

Pulizia

Rimuovi duplicati che distorcerebbero le statistiche, correggi errori di battitura nei nomi delle categorie, e assicurati che i numeri siano interpretati come numeri (non come stringhe di testo).

Codice Python:

```
df = df.drop_duplicates()
df['prezzo'] = df['prezzo'].astype(float)
```

Missing Values

Non lasciare "buchi" nei dati. Puoi eliminare le righe incomplete (se sono poche) o riempirle (imputazione) con valori ragionevoli come media, mediana, o modelli più sofisticati.

Codice Python:

```
df = df.dropna() # Elimina righe con NaN
df = df.fillna(df.mean()) # Riempi con media
```

Outlier

Identifica valori anomali che potrebbero distorcere la retta (es. casa venduta a 1€ per errore). Valuta caso per caso se rimuoverli, correggerli o usare metodi robusti.

Codice Python:

```
from scipy import stats
z_scores = np.abs(stats.zscore(df['prezzo']))
df = df[z_scores < 3] # Rimuovi outlier oltre 3σ
```

Divisione Train/Test

Non possiamo valutare il modello sugli stessi dati usati per crearlo. Sarebbe come dare a uno studente le risposte esatte prima dell'esame: i voti sarebbero ottimi ma non significativi.

Training Set (80%)

Dati per l'apprendimento

Fase di Studio: Il modello usa questi dati per "imparare": calcola i coefficienti (intercetta e pendenza) minimizzando l'errore sui dati di training. È come studiare su un libro di esercizi con le soluzioni.

Il modello "vede" questi dati e può adattarsi perfettamente ad essi, ma questo non garantisce che funzioni su dati nuovi.


Test Set (20%)

Dati per la verifica

Fase di Esame: Il modello fa previsioni su questi dati **mai visti prima** durante il training. Confrontiamo le previsioni con la realtà per calcolare R^2 , RMSE e MAE.

Questa è la vera prova: quanto bene il modello *generalizza* su situazioni nuove? È l'esame finale che misura la competenza reale.

❏ **Importante:** La divisione deve essere casuale per evitare bias. In scikit-learn usiamo `train_test_split()` che mescola automaticamente i dati prima di dividerli.



Addestramento del Modello

Il momento cruciale in cui l'algoritmo "impara" dai dati per trovare la retta ottimale secondo il criterio OLS. Vediamo il codice Python passo dopo passo.

01

Inizializzazione

Creiamo un'istanza del modello: è una "scatola vuota" senza conoscenze, pronta ad apprendere.

```
from sklearn.linear_model import  
LinearRegression  
model = LinearRegression()
```

02

Fitting (Adattamento)

Il metodo `.fit()` esegue l'algoritmo OLS per trovare β_0 e β_1 che minimizzano la somma dei quadrati dei residui.

```
model.fit(X_train, y_train)
```

03

Cosa succede sotto il cofano?

Il modello calcola automaticamente l'intercetta e la pendenza usando le formule OLS viste prima, e le salva negli attributi `model.intercept_` e `model.coef_`.

```
print(f"Intercetta: {model.intercept_}")  
print(f"Pendenza: {model.coef_[0]}")
```

In poche righe di codice, abbiamo implementato tutta la matematica complessa vista nelle slide precedenti!

Fare Previsioni

Una volta addestrato, il modello diventa una "funzione magica" per trasformare nuovi input (X) in output previsti ($\hat{y}$). Questo è lo scopo finale di tutto il lavoro fatto finora.

Input (X)

Nuovi dati mai visti (es. case di 50 m² e 75 m²).
Deve essere un array 2D per compatibilità con scikit-learn.

```
X_new = [[50],  
         [75]]
```

Modello

Applica internamente l'equazione appresa durante il training:

$$\hat{y} = b_0 + b_1 \cdot x$$

Per ogni valore di X fornito, calcola il corrispondente Y previsto usando i coefficienti stimati.

Output ($\hat{y}$)

I valori previsti dal modello (es. prezzi stimati per le case di 50 e 75 m²).

```
y_pred =  
model.predict(X_new)  
# [150000, 225000]
```

Codice Completo

```
X_new = [[50], [75]]  
y_pred = model.predict(X_new)  
  
for mq, prezzo in zip(X_new, y_pred):  
    print(f"Casa {mq[0]} m²: Prezzo stimato {prezzo:.2f}€")
```

Output:

Casa 50 m²: Prezzo stimato 150000.00€
Casa 75 m²: Prezzo stimato 225000.00€

Valutazione in Python

Calcolare R^2 , RMSE e MAE per quantificare oggettivamente l'errore del modello. Scikit-learn fornisce funzioni già pronte per tutte le metriche standard.

```
import numpy as np
from sklearn.metrics import mean_squared_error, r2_score, mean_absolute_error

# Predici sul test set
y_pred = model.predict(X_test)

# Calcola metriche
mae = mean_absolute_error(y_test, y_pred)
rmse = np.sqrt(mean_squared_error(y_test, y_pred))
r2 = r2_score(y_test, y_pred)

print(f"MAE: {mae:.2f}")
print(f"RMSE: {rmse:.2f}")
print(f"R²: {r2:.4f}")
```

Output Esempio

```
> python evaluation.py
MAE: 1250.50
RMSE: 1840.20
R²: 0.8754
```

MAE

mean_absolute_error

Errore medio assoluto in euro

RMSE

np.sqrt(MSE)

Radice dell'errore quadratico medio

R^2

r2_score

Percentuale varianza spiegata

Interpretazione

Il modello spiega l'87.54% della variabilità e sbaglia mediamente di ~1250€

Vantaggi e Limitazioni

Come ogni strumento, la regressione lineare ha punti di forza e debolezze. Conoscerli è essenziale per applicarla correttamente e interpretarne i risultati con spirito critico.

Vantaggi

Interpretabilità

È un modello "White Box" trasparente. Capiamo esattamente come ogni variabile influenza il risultato. Ogni coefficiente ha un significato chiaro e comunicabile.

Velocità

Addestramento quasi istantaneo anche su grandi dataset (milioni di righe).
Bassa complessità computazionale $O(n)$: scala linearmente con i dati.

Fondamentale

È la base concettuale per capire modelli più complessi: reti neurali (combinazioni di regressioni), regressione logistica, GLM. Conoscerla è un prerequisito.

Limitazioni

Linearità

Assume che la relazione sia una linea retta perfetta. Fallisce completamente con dati complessi, curvi, ciclici o con interazioni non lineari tra variabili.

Outlier

Molto sensibile ai valori anomali estremi, che possono "tirare" la retta in direzioni sbagliate e rovinare completamente il modello.

Indipendenza

Richiede che le variabili predittive non siano fortemente correlate tra loro (no multicollinearità). Problematico quando le feature sono ridondanti.

Quando Usare la Regressione Lineare

Non è sempre la soluzione migliore per ogni problema, ma è spesso il miglior punto di partenza. Vediamo i contesti in cui brilla maggiormente.

Baseline

Usala come primo modello di riferimento (baseline). Se modelli più complessi non riescono a batterla significativamente, probabilmente non serve complicare. Mantieni la semplicità.

Inferenza

Quando devi spiegare il **perché** delle previsioni a stakeholder, clienti o regolatori. La trasparenza è più importante della precisione assoluta in molti contesti di business e medicina.

Dati Limitati

Funziona bene anche con dataset piccoli (poche centinaia di osservazioni), dove modelli complessi (Random Forest, Neural Networks) tendono a sovradattare memorizzando i dati invece di generalizzare.

Regola d'oro del Machine Learning: Inizia sempre con il modello più semplice possibile. Aumenta la complessità solo se strettamente necessario e giustificato dai dati. La semplicità è una virtù, non un limite.