

▼ Premessa statistica

Dal punto di vista della statistica è importante fare una premessa terminologica.

Le variabili possono variare nel tempo e un fenomeno può dipendere da altre variabili (covariate) che variano anche queste nel tempo.

Si parla in questi casi di **dataset longitudinale** o anche **dati panel**.

Ecco i punti chiave: Struttura: Ogni soggetto (i) viene osservato ripetutamente nel tempo (t), creando un dataset "lungo" (es. 100 persone osservate per 5 anni = 500 righe).

Tipi di Panel:

- Bilanciato: Tutte le unità sono osservate in tutti i periodi temporali.
- Non bilanciato: Alcune osservazioni mancano per determinati periodi.

-Vantaggi: Ideali per studi su comportamenti, fedeltà alla marca o impatto di politiche nel tempo, poiché seguono il soggetto nel corso del tempo.

- Applicazioni: Ricerche di mercato (Nielsen), studi sull'audience (Auditel), indagini economiche (ISTAT).

I dati panel si distinguono da quelli "cross-section" (una foto istantanea di tanti soggetti) e dalle serie storiche (un solo soggetto nel tempo).

Curiosità:

Il nome della libreria Python pandas deriva direttamente dal termine econometrico "Panel Data" (dati panel), che si riferisce a dataset strutturati contenenti osservazioni su più periodi di tempo per gli stessi soggetti 000000

Introduzione all'Analisi delle Serie Temporal

Per brevità faremo solo dei cenni ad alcuni degli aspetti di base delle serie temporali.

Una **serie temporale** è una sequenza di osservazioni numeriche raccolte (o registrate) a **intervalli regolari** nel tempo.

Esempi classici:

- Vendite giornaliere/mensili di un prodotto
- Temperatura media giornaliera in una città
- Prezzo di chiusura di un'azione in borsa
- Consumi elettrici ogni 15 minuti
- Numero di visitatori su un sito web ogni ora
- Tasso di disoccupazione mensile
- Produzione industriale trimestrale
- Battiti cardiaci misurati ogni secondo

Caratteristica fondamentale: **l'ordine temporale è importante**. Questo vuol dire che non possiamo mischiare casualmente le osservazioni.

Componenti principali di una serie temporale

La maggior parte delle serie temporali può essere scomposta (almeno concettualmente) in 4 parti:

Componente	Descrizione	Esempio tipico	Matematicamente tendenzialmente...
Trend	Movimento di lungo periodo (crescita/decrecita lenta)	Aumento graduale delle temperature globali	additivo o moltiplicativo
Stagionalità	Pattern che si ripete a intervallo fisso (giornaliero, settimanale, annuale)	Picchi di vendite natalizie ogni dicembre	periodico fisso
Ciclo	Oscillazioni di periodo variabile e non fisso (più lungo della stagionalità)	Cicli economici di 5-10 anni	non fisso, non prevedibile con Fourier
Rumore / residuo	Variazioni casuali / imprevedibili / non spiegabili dagli altri componenti	Errori di misurazione, eventi eccezionali	componente casuale / stocastica

Molto spesso si usa la scomposizione additiva:

$$Y_t = \text{Trend}_t + \text{Stagionalità}_t + \text{Ciclo}_t + \text{Residuo}_t$$

oppure moltiplicativa (più comune quando l'ampiezza cresce col tempo):

$$Y_t = \text{Trend}_t \times \text{Stagionalità}_t \times \text{Ciclo}_t \times \text{Residuo}_t$$

Nel codice sotto vedremo un esempio in cui applicare entrambe le possibilità e riflettere sulle differenze.

Tipologie di serie temporali (classificazione utile)

Tipo	Frequenza tipica	Esempi	Difficoltà di previsione
Molto alta frequenza	secondi / minuti	dati di sensori, trading ad alta frequenza	★★★★★
Alta frequenza	oraria / giornaliera	consumi elettrici, traffico web	★★★★
Media frequenza	giornaliera / settimanale	vendite al dettaglio, meteo	★★★
Bassa frequenza	mensile / trimestrale	PIL, disoccupazione, indici macro	★★
Molto bassa frequenza	annuale	popolazione, emissioni CO ₂ storiche	★

Obiettivi principali nell'analisi delle serie temporali

Inseriamo qui questo elenco non esaustivo in modo che in una futura esperienza lavorativa un problema possa essere ricollegato allo strumento della serie temporale.

1. **Descrizione** → capire pattern, trend, stagionalità
2. **Previsione** (forecasting) → stimare valori futuri
3. **Anomaly detection** → trovare valori anomali / cambi di regime
4. **Decomposizione** → separare le componenti
5. **Analisi di correlazione temporale** → autocorrelazione, cross-correlazione
6. **Modellazione causale** → capire relazioni tra più serie (VAR, VECM...)
7. **Intervento / valutazione impatto** → es. effetto di una campagna marketing

5. Concetti fondamentali da conoscere

Concetto	Significato breve	Perché è importante?
Stazionarietà	Media, varianza e covarianza non cambiano nel tempo	Molti modelli classici (ARIMA) la richiedono
Autocorrelazione (ACF)	Correlazione tra la serie e se stessa spostata di k passi	Serve per identificare ordine di AR e MA
Autocorrelazione parziale (PACF)	Correlazione dopo aver eliminato l'effetto dei lag intermedi	Aiuta a scegliere ordine AR
Differenziazione	$y'_t = y_t - y_{t-1}$	Trasforma serie non stazionaria in stazionaria
Stagionalità	Pattern periodico ripetitivo	Deve essere modellata o rimossa prima di ARIMA
Cambi di regime / breakpoint	Cambi improvvisi di media/varianza/trend	Molti modelli falliscono se non li gestiamo

Pipeline tipica di analisi (flusso consigliato)

1. **Importazione e pulizia**
(missing values, duplicati, allineamento temporale)
2. **Visualizzazione esplorativa**
 - Plot della serie
 - Plot stagionale
 - Boxplot per mese/giorno della settimana
 - Decomposizione classica / STL
3. **Verifica stazionarietà**
 - Test ADF / KPSS
 - Plot ACF/PACF
4. **Trasformazioni** se necessario
 - Log, radice quadrata
 - Differenziazione (d)
 - Rimozione stagionalità (D)
5. **Scelta e stima del modello**

Questa parte per motivi di tempo non è stata trattata ma la riportiamo perché centrale. E' possibile utilizzare anche in questo ambito alcune competenze acquisite nel campo del Machine Learning:

- ARIMA / SARIMA
- Exponential Smoothing
- Prophet
- modelli ML (XGBoost, LightGBM con lag)
- reti neurali (LSTM, Transformer, N-BEATS...)

6. **Validazione**
 - Train / Validation / Test split **temporale** (no random split!)
 - Cross-validation rolling / expanding window
7. **Previsione e valutazione**
 - MAE, RMSE, MAPE, sMAPE, MASE...
8. **Interpretazione e comunicazione**

```

import pandas as pd
import matplotlib.pyplot as plt
from statsmodels.datasets import get_rdataset
from statsmodels.tsa.seasonal import seasonal_decompose

# =====
# 1. CARICAMENTO DATASET
# =====
data = get_rdataset("AirPassengers").data

# Costruzione serie temporale
date = pd.date_range(start="1949-01", periods=len(data), freq="M")
df = pd.DataFrame({
    "date": date,
    "value": data["value"]
})

df.set_index("date", inplace=True)

# =====
# 2. GRAFICO SERIE TEMPORALE
# =====
plt.figure(figsize=(10,5))
plt.plot(df.index, df["value"], label="Passeggeri")
plt.title("Serie temporale - AirPassengers")
plt.xlabel("Anno")
plt.ylabel("Numero passeggeri")
plt.legend()
plt.grid()
plt.show()

# =====
# 3. MEDIA MOBILE
# =====
window = 12 # stagionalità annuale (dati mensili)
df["moving_avg"] = df["value"].rolling(window=window).mean()

plt.figure(figsize=(10,5))
plt.plot(df.index, df["value"], label="Serie originale", alpha=0.5)
plt.plot(df.index, df["moving_avg"], label="Media mobile (12 mesi)", color="red")
plt.title("Media mobile")
plt.legend()
plt.grid()
plt.show()

# =====
# 4. TREND E STAGIONALITÀ
# =====
#result = seasonal_decompose(df["value"], model="multiplicative", period=12)

result = seasonal_decompose(df["value"], model="additive", period=12)

result.plot()
plt.show()

# =====
# 5. COMPONENTI
# =====
df["trend"] = result.trend
df["seasonal"] = result.seasonal
df["residual"] = result.resid

print(df.head(15))

```




```
data = get_rdataset("AirPassengers").data
type(data)
```

```
data.columns
```


```
Index(['time', 'value'], dtype='object')
```

```
plt.plot(data['time'], data['value'])
plt.show()
```



Inizia a programmare o [genera](#) codice con l'IA.

```
data.head()
```



Inizia a programmare o [genera](#) codice con l'IA.

