



Prompt Engineering e AI: Deep Dive

Dalla Teoria alla Pratica — Tecniche, Infrastrutture e Applicazioni Reali

ITS — Corso Avanzato

Docente: **Corrado Centrone** — Fractional Digital Executive | AI & Data
Analytics



2017 — GOOGLE RESEARCH

Il Contesto — La Nascita dell'AI Moderna

Nel 2017 il paper "**Attention Is All You Need**" introdusse l'architettura **Transformer**, il motore alla base di quasi tutta l'AI moderna.

Prima (RNN/LSTM)

I modelli leggevano le frasi **una parola alla volta**, in sequenza. Processo lento con memoria a breve termine limitata.

Dopo (Transformer)

Il modello può prestare attenzione a **tutte le parole contemporaneamente**, comprendendo il contesto in modo profondo.

- 📖 **Analogia:** È la differenza tra leggere un libro una parola alla volta senza poter tornare indietro, e avere l'intero libro aperto davanti a sé, potendo collegare istantaneamente il primo capitolo con l'ultimo.

L'Accelerazione Esponenziale dei Modelli

Anno	Modello	Parametri	Analogia
2018	GPT-1	117 Milioni	Un piccolo dizionario
2019	GPT-2	1.5 Miliardi	Un'enciclopedia
2020	GPT-3	175 Miliardi	Una biblioteca
2023–2024	Llama 3.1, Mistral Large	8–405 Miliardi	Una grande biblioteca specializzata
2023+	GPT-4, Gemini, Claude	> 1 Trilione	Conoscenza umana digitalizzata

📌 I modelli open source (Llama 3.1, Mistral, Qwen) offrono prestazioni eccellenti per applicazioni marketing a **costo zero di licenza**. Questa accelerazione ha reso possibile la Generative AI.

I Tre Tipi di AI — Confronto

AI Tradizionale

Ruolo: Classificatore/Predittore

Input: Dati strutturati

Output: Etichette, numeri

Esempio: Riconoscimento spam, diagnosi medica

AI Generativa (GenAI)

Ruolo: Creatore/Conversatore

Input: Prompt

Output: Testo, immagini, codice

Esempio: ChatGPT, Midjourney

AI Agentica

Ruolo: Attore/Risolutore

Input: Obiettivi/Missioni

Output: Azioni eseguite, workflow

Esempio: Agente che pianifica un viaggio e prenota autonomamente

Terminologia Essenziale — LLM

LLM — Large Language Model

Modelli con **miliardi di parametri** (tipicamente >7B) addestrati su enormi dataset testuali. Capaci di ragionamento complesso, generazione di testo di alta qualità e comprensione di contesti articolati.

Esempi: GPT-4, Claude, Llama 70B, Gemini

Richiedono GPU potenti e molta VRAM. Ideali per task complessi: analisi strategica, contenuti articolati, ragionamento multi-step.

Terminologia Essenziale — SLM

SLM — Small Language Model

Modelli più compatti (tipicamente <7B parametri) progettati per essere efficienti e veloci. Richiedono meno risorse computazionali e possono girare anche su dispositivi edge o laptop.

Esempi: Phi-3 Mini (3.8B), Gemma 2B, Mistral 7B, Llama 3 8B

Ideali per: classificazione testi, chatbot semplici, task specifici dove la velocità conta più della profondità.

📌 **Quando usare cosa:** SLM per task ripetitivi, classificazione, risposte rapide. LLM per ragionamento complesso, contenuti creativi, analisi strategiche. La tendenza è verso SLM specializzati che competono con LLM generalisti su task specifici.

Terminologia Essenziale — Tokenizzazione

Tokenizzazione — Come i Modelli "Leggono" il Testo

Il processo di **suddivisione del testo in unità più piccole**, chiamate **token**. Questi token possono essere parole, parti di parole (subword) o singoli caratteri, e sono la rappresentazione numerica del linguaggio che i modelli AI possono elaborare.

- Ogni token viene convertito in un **ID numerico** univoco.
- I modelli operano su queste sequenze di numeri, non direttamente sulle parole.
- La **qualità** della tokenizzazione influisce sulla **comprensione** e sulla **generazione** del testo da parte dell'LLM.

📌 **Esempio:** La frase "Prompt Engineering" potrebbe essere tokenizzata come ["Prompt", "Engin", "eering"], dove ogni parte ha un ID numerico associato. Questo permette al modello di gestire anche parole nuove o complesse.

Terminologia Essenziale — Embedding

Embedding — Rappresentazioni Vettoriali

Gli **embedding** sono rappresentazioni numeriche di dati (testo, immagini, audio) convertiti in **vettori** in uno spazio matematico ad alta dimensionalità. Questi vettori catturano il significato semantico e le relazioni tra i dati.


- **Ricerca Semantica:** Consentono di trovare contenuti simili per significato, non solo per corrispondenza di parole chiave.
- **Riduzione Dimensionalità:** Trasformano dati complessi in una forma più efficiente per i modelli AI.
- **Confrontabilità:** Elementi semanticamente simili hanno vettori numericamente "vicini" nello spazio vettoriale.
- **Fondamentali per l'AI:** Alla base di molte applicazioni, dalla personalizzazione ai sistemi di raccomandazione.

📌 **Pensateli come una "mappa semantica":** ogni concetto è un punto, e concetti correlati sono raggruppati vicini l'uno all'altro, rendendo facile per l'AI comprenderne le relazioni.

Terminologia Essenziale - RAG

Retrieval-Augmented Generation

Tecnica che permette agli LLM di accedere a **fonti dati esterne verificate** prima di generare una risposta.



LLM senza RAG = studente a memoria.

LLM con RAG = studente con libro aperto.

Terminologia Essenziale — Context Window

Context Window — La "Memoria" del Modello

La **context window**, o finestra di contesto, definisce la quantità massima di testo (misurata in token) che un modello AI può considerare in un singolo scambio. È come la memoria a breve termine del modello: tutto ciò che è al suo interno è "ricordato" e utilizzato per generare la risposta.

- Limita la lunghezza del prompt e della risposta generata.
- Influenza la coerenza e la profondità del ragionamento.
- Modelli con context window più ampie gestiscono conversazioni più lunghe e documenti complessi.

❏ **Importante:** Se il testo supera la context window, le informazioni più vecchie vengono "dimenticate", compromettendo la capacità del modello di mantenere il contesto.

Terminologia Essenziale — MCP

MCP — Model Context Protocol

Protocollo open-source sviluppato da Anthropic che standardizza il modo in cui le applicazioni AI si collegano a fonti dati e strumenti esterni.

È come una "**porta USB universale**" per l'AI: un'interfaccia standard che permette ai modelli di accedere a database, API, file system, CRM e qualsiasi servizio esterno in modo sicuro e strutturato.

- Interoperabilità tra modelli e strumenti
- Sicurezza nell'accesso ai dati
- Facilità di integrazione con sistemi aziendali esistenti

Esempio pratico: un chatbot che tramite MCP accede in tempo reale al CRM aziendale per rispondere sullo stato di un ordine.

MCP in Azione — Uno Scenario Concreto

Il Model Context Protocol (MCP) semplifica radicalmente l'integrazione dei modelli AI con servizi esterni, trasformando un complesso labirinto di connessioni in un punto di accesso unificato.

Senza MCP — Integrazione Diretta

Immaginate di voler collegare un modello AI a Gmail. Senza MCP, sareste costretti a:

- Implementare connessioni separate per ogni funzionalità (lettura, invio, modifica email).
- Configurare e gestire autenticazioni individuali per ciascuna API di Gmail.
- Affrontare complessità e overhead di sviluppo per ogni nuovo servizio integrato.

Un approccio frammentato, vulnerabile e difficile da scalare.

Con MCP — La Soluzione Semplificata

Con MCP, il modello AI si connette a un'unica interfaccia che agisce da "traduttore" universale:

- Un singolo accesso e configurazione per l'MCP.
- L'MCP gestisce autonomamente il collegamento alle varie API di Gmail (o qualsiasi altro strumento).
- Autenticazione centralizzata e accesso sicuro a tutti i servizi.

Un'integrazione snella, sicura e facilmente estensibile.

Terminologia Essenziale — Hallucination

Cos'è l'Hallucination?

L' **hallucination** è la tendenza dei modelli AI a generare informazioni **false, inventate o fuorvianti** che non sono supportate dai dati di addestramento o dal contesto fornito, pur presentandole con grande sicurezza e plausibilità. È una delle sfide maggiori nella costruzione di sistemi AI affidabili.

Terminologia Essenziale — Guardrail

Guardrail

Sistemi di sicurezza e controllo che monitorano e filtrano input e output dei modelli AI. Funzionano come "**binari di sicurezza**" che impediscono al modello di deragliare.

- **Input Guardrail:** filtrano le richieste dell'utente prima che raggiungano il modello
- **Output Guardrail:** verificano le risposte del modello prima di inviarle all'utente
- **Guardrail di processo:** monitorano il comportamento durante l'esecuzione

Perché servono: compliance normativa (EU AI Act), protezione del brand, prevenzione di risposte dannose.

Guardrail in Azione — Un Esempio Pratico

I guardrail sono essenziali per garantire che i modelli AI operino in modo sicuro, etico e conforme alle normative, filtrando sia le richieste non appropriate che le risposte potenzialmente problematiche.

1

Input Guardrail: Blocco Preventivo

Scenario: Un dipendente chiede a un chatbot HR interno: "Come posso accedere ai dati salariali degli altri colleghi?"

Azione del Guardrail: Il **Guardrail di Input** (pre-modello) rileva parole chiave sensibili relative all'accesso non autorizzato a informazioni private.

Risultato: La richiesta viene bloccata prima di raggiungere il modello AI. Il chatbot risponde: *"Mi dispiace, non posso fornire informazioni sensibili o private. Posso aiutarti con domande sulle politiche aziendali generali o sui benefici."*

2

Output Guardrail: Filtro Post-Generazione

Scenario: Un dipendente chiede: "Quali sono i benefit specifici per il congedo parentale?"

Azione del Guardrail: Il modello AI genera una risposta accurata, ma include accidentalmente il nome di un dipendente specifico o un dettaglio confidenziale preso dai dati di training.

Risultato: Il **Guardrail di Output** (post-modello) intercetta la risposta, identifica e rimuove le informazioni personali sensibili (PII) o confidenziali, quindi la consegna al dipendente in una versione sicura.

Terminologia Essenziale — Human-in-the-Loop (HITL)

Supervisione Umana nei Processi Automatizzati

Human-in-the-Loop (HITL) è un approccio in cui l'intervento umano è richiesto o consentito per garantire la precisione e la correttezza nei processi di intelligenza artificiale. In pratica, il sistema AI svolge compiti che necessitano di convalida, correzione o miglioramento da parte di un essere umano.

Validazione e Correzione

Gli esseri umani convalidano le previsioni dell'AI o correggono i suoi errori, specialmente in casi ambigui o ad alto rischio.

Apprendimento Continuo

Il feedback umano viene utilizzato per addestrare ulteriormente e migliorare le prestazioni del modello AI nel tempo.

Gestione delle Eccezioni

L'intervento umano è fondamentale per gestire situazioni complesse o "edge case" che l'AI non è in grado di affrontare autonomamente.

HITL è cruciale per **ridurre le allucinazioni**, mitigare i bias e garantire che i sistemi AI operino in modo etico e affidabile, combinando l'efficienza dell'automazione con la capacità di giudizio umana.

Terminologia Essenziale — Synthetic Data

Cos'è il Synthetic Data?

Synthetic Data sono dati generati artificialmente che replicano le proprietà statistiche e le relazioni dei dati reali, ma non contengono informazioni originali. Sono creati da algoritmi per essere utilizzati in training e testing di modelli AI.

Questo tipo di dati è cruciale per la **privacy** (evitando l'uso di dati sensibili), la **scalabilità** (generando volumi elevati quando i dati reali sono limitati) e la **riduzione dei bias** (bilanciando dataset sbilanciati), accelerando lo sviluppo e il testing in ambienti controllati.

Terminologia Essenziale — AI Act

AI Act — Il Regolamento Europeo sull'Intelligenza Artificiale

Il primo quadro giuridico completo al mondo che mira a regolamentare lo sviluppo e l'uso dell'Intelligenza Artificiale, garantendo sicurezza, rispetto dei diritti fondamentali e promuovendo al contempo l'innovazione responsabile.

- **Classificazione basata sul rischio:** I sistemi AI sono categorizzati in base al loro livello di rischio (inaccettabile, alto, limitato, minimo), con obblighi crescenti all'aumentare del rischio.
- **Obblighi specifici:** Per i sistemi ad "alto rischio" (es. in sanità, giustizia, istruzione) sono previsti requisiti stringenti su governance dei dati, trasparenza, sorveglianza umana e robustezza della sicurezza informatica.
- **Divieti:** Sono vietati sistemi AI che manipolano il comportamento umano in modo dannoso o che utilizzano il social scoring indiscriminato.

L'AI Act è stato approvato dal Parlamento Europeo a marzo 2024. Entrerà in vigore a scaglioni, con le prime disposizioni applicabili dopo 6 mesi e la piena operatività per i sistemi ad alto rischio entro 24-36 mesi dall'entrata in vigore ufficiale.



Terminologia Essenziale — Infrastruttura e Deployment

Per comprendere appieno le applicazioni e le potenzialità dell'AI, è fondamentale conoscere l'infrastruttura che ne supporta lo sviluppo e l'implementazione.

Edge AI

L'esecuzione di modelli di intelligenza artificiale direttamente su dispositivi locali (come smartphone, sensori IoT, telecamere) anziché su server cloud centralizzati. Offre bassa latenza, funzionamento offline e maggiore privacy, riducendo la dipendenza dalla connettività.

MLOps

Una metodologia che estende i principi DevOps al ciclo di vita del machine learning, focalizzandosi su deployment, monitoraggio, gestione, retraining e mantenimento dei modelli AI in produzione in modo efficiente e automatizzato. È cruciale per la scalabilità e l'affidabilità.

Vector Database

Un tipo di database specializzato nell'archiviazione e nella ricerca efficiente di vettori ad alta dimensionalità (embeddings). È essenziale per funzionalità come la ricerca semantica, i sistemi di raccomandazione e le architetture RAG (Retrieval-Augmented Generation) nei LLM.

AI On-Premise — Dove Ospitare l'Intelligenza Artificiale?

La scelta dell'infrastruttura non è solo tecnica, ma **strategica**. Ogni decisione impatta profondamente il business, la sicurezza e la capacità di innovare.



Impatto sui Costi

CAPEX vs OPEX



Sicurezza dei Dati

Privacy e GDPR



Sovranità Digitale

Controllo totale sui dati



Velocità di Innovazione

Time to market

☐ Per molte aziende europee, la **protezione dei dati è priorità assoluta**. La scelta on-premise garantisce sovranità completa.

On-Premise vs Cloud — Analisi Comparativa

Metrica	On-Premise	Cloud
Controllo	ALTO (Totale)	BASSO (Dipendente dal Provider)
Sicurezza Dati	SOVRANITÀ TOTALE	CONDIVISA
Costi	CAPEX ALTO / OPEX BASSO	OPEX ALTO / SCALABILE
Scalabilità	LIMITATA (Hardware fisico)	ELASTICA
Time to Market	MEDIO-LUNGO	IMMEDIATO
Latenza	MINIMA (LAN)	VARIABILE (Internet)

Il Dilemma Strategico — Public Cloud vs On-Premise

Public Cloud

OPEX (Pay-as-you-go)

Costi scalano linearmente con l'uso.
Prevedibilità bassa su volumi elevati.

Dati Esterni

I dati lasciano il perimetro aziendale.
Rischi di compliance e privacy.

Latenza di Rete

Dipendenza dalla connessione internet.

Ideale per

Startups e picchi imprevedibili

On-Premise

CAPEX (Investimento)

Costo marginale per inferenza quasi zero.
ROI positivo su volumi elevati.

Sovranità dei Dati

Controllo totale e compliance GDPR garantita.

Zero Latency

Accesso diretto ai dati aziendali. Performance costanti.

Ideale per

Aziende con dati sensibili, volumi prevedibili, margini da proteggere

Privacy First — Quando Scegliere **On-Premise**

1 Privacy e Sovranità

I dati delle prenotazioni e dei profili utente non lasciano mai i server aziendali. Controllo totale su ogni informazione sensibile.

2 Costi Prevedibili

Ammortamento dell'hardware (CAPEX) vs costi API variabili e potenzialmente esplosivi (OPEX). Budget stabile e prevedibile.

3 Performance e Latenza

Latenza ridotta per integrazioni dirette con i sistemi legacy interni (ERP, CRM). Tempi di risposta costanti e ottimali.

4 Indipendenza Tecnologica

Nessun lock-in con provider specifici (AWS, Azure, OpenAI). Libertà di cambiare modello e tecnologia.



Anatomia di un Motore LLM — I Quattro Pilastri

Inference Runtime

Il motore esecutivo. Gestisce il caricamento dei pesi, l'allocazione della memoria (KV Cache) e l'ottimizzazione dei calcoli sulla GPU.

Tech: vLLM, Ollama, TensorRT-LLM

Orchestrazione

Il sistema nervoso. Gestisce il ciclo di vita dei container, lo scaling automatico e la distribuzione del carico tra i nodi.

Tech: Kubernetes (K8s), Docker

Storage Layer

La memoria a lungo termine. Ospita i modelli, i dataset per il fine-tuning e i database vettoriali per il contesto (RAG).

Tech: NVMe, MinIO, pgvector

Networking

Le arterie del sistema. Fondamentale per ridurre la latenza nel trasferimento dei tensori tra GPU.

Tech: 100GbE, InfiniBand, RDMA

Il Cuore del Sistema — Inference Runtime

Il Runtime **non è il modello**. È il motore software che carica i pesi, gestisce la memoria e serve le richieste.

1	2	3
Ollama DEVELOPMENT Ideale per laptop e test locali. Zero configuration (Plug & Play). Gestione modelli semplificata. Non ottimizzato per concorrenza.	vLLM PRODUCTION Standard per server di produzione. Throughput estremo (24x vs HuggingFace). API OpenAI Compatible native. PagedAttention Technology.	TensorRT-LLM PERFORMANCE Massime performance su hardware NVIDIA. Richiede compilazione e configurazione complessa, ma offre l'efficienza più elevata.

❏ **Killer Feature di vLLM — PagedAttention:** Divide la KV Cache in blocchi non contigui (come la memoria virtuale nei sistemi operativi). Elimina la frammentazione della memoria e permette il Continuous Batching, servendo centinaia di utenti simultaneamente.



Il "Menu" dei Modelli Open Source

GENERAL PURPOSE

LLAMA 3 — Meta

Il punto di riferimento generalista. Ottimo bilanciamento tra performance e risorse. Ideale per la maggior parte dei casi d'uso aziendali.

EFFICIENCY / RAG

MISTRAL — Mistral AI

Efficienza superiore grazie all'architettura MoE (Mixture of Experts). Ideale per RAG e applicazioni che richiedono contesti molto lunghi.

CODING / MULTILINGUA

QWEN — Alibaba

Eccellente nel coding e nel supporto multilingua. Ottime capacità di reasoning e problem solving.

OPEN DATA

FALCON — TII

Focus su trasparenza e dati di training di alta qualità. Licenza permissiva Apache 2.0 che favorisce l'adozione enterprise.

Llama 3: Il Nuovo Standard Open Source

Llama 3 di Meta AI rappresenta un significativo passo avanti nei modelli linguistici aperti, stabilendo un nuovo punto di riferimento per prestazioni e accessibilità.



General Purpose Avanzato

Llama 3 eccelle in una molteplicità di task, dalla generazione di testo alla programmazione, dalla traduzione alla comprensione del linguaggio naturale. È il punto di partenza ideale per la maggior parte dei progetti.



Performance e Scalabilità

Disponibile in versioni da 8B e 70B parametri, con versioni più grandi in arrivo. Offre prestazioni competitive con modelli proprietari e supporta un contesto esteso, rendendolo adatto per casi d'uso complessi e intensivi.



Disponibilità e Licenza

Completamente open source e distribuito con una licenza permissiva che ne consente l'uso commerciale, garantendo flessibilità e controllo agli sviluppatori. È integrato con i principali framework e piattaforme.



Fine-tuning e Customizzazione

La sua architettura modulare facilita il fine-tuning su dati specifici aziendali, permettendo la creazione di modelli altamente specializzati per le esigenze di ItalCamel.



Qwen: Intelligenza Multilingua e Coding

Sviluppato da Alibaba Cloud, Qwen si distingue per le sue eccezionali capacità multilingue e la sua maestria nella programmazione. È una scelta potente per scenari che richiedono precisione e flessibilità in contesti globali, supportando un'ampia gamma di applicazioni.



Supporto Multilingua Superiore

Addestrato su un dataset diversificato, Qwen eccelle in lingue non-inglesi, con una forte enfasi sulle lingue asiatiche. Ideale per applicazioni globali e traduzione.



Eccellenza nella Programmazione

Offre prestazioni di alto livello nella generazione di codice, debugging e comprensione di vari linguaggi di programmazione, un partner prezioso per gli sviluppatori.



Capacità di Ragionamento Avanzate

Le sue abilità di problem-solving e ragionamento logico lo rendono adatto per task complessi che richiedono analisi approfondite e soluzioni creative in ambiti scientifici e tecnici.



Flessibilità e Adattabilità

Disponibile in diverse dimensioni (da 0.5B a 72B parametri) e con licenze permissive, offre grande flessibilità per essere ottimizzato e integrato in varie infrastrutture.

Falcon: Trasparenza e Adozione Enterprise

Sviluppato dal Technology Innovation Institute (TII), i modelli Falcon si distinguono per il loro focus sulla trasparenza dei dati di training e per la loro licenza permissiva, che li rende particolarmente attraenti per l'adozione in contesti aziendali.



Qualità e Trasparenza nei Dati

I modelli Falcon sono stati addestrati su RefinedWeb, un dataset vasto e di alta qualità, con una documentazione approfondita sulle sue fonti e processi di curatela, garantendo affidabilità e trasparenza.



Libertà Commerciale

Distribuito con licenza Apache 2.0, Falcon offre piena libertà per l'uso commerciale, la modifica e la distribuzione, rimuovendo le barriere all'innovazione e all'integrazione in prodotti e servizi enterprise.



Openness e Riproducibilità

TII si impegna a promuovere un ecosistema AI aperto, fornendo dettagli sui processi di training e permettendo a ricercatori e aziende di riprodurre e verificare i risultati, favorendo la fiducia e la collaborazione.



Affidabilità e Integrazione

Grazie alla sua architettura robusta e alla licenza favorevole, Falcon è una scelta eccellente per le aziende che cercano soluzioni AI performanti, affidabili e facilmente integrabili nei propri flussi di lavoro esistenti.

Mistral: Efficienza e Intelligenza

Mistral AI si è rapidamente affermata come un attore chiave nel panorama degli LLM open source, offrendo modelli che combinano intelligenza avanzata con una notevole efficienza. È la scelta ideale per applicazioni che richiedono elevate prestazioni con un utilizzo ottimizzato delle risorse.



Architettura MoE Avanzata

Grazie all'innovativa architettura Mixture of Experts (MoE), Mistral attiva solo le parti del modello necessarie per ogni query, garantendo un'efficienza computazionale superiore e riducendo significativamente il consumo di energia e la latenza.



Eccellenza in RAG e Contesti Lunghi

I modelli Mistral sono particolarmente adatti per applicazioni Retrieval Augmented Generation (RAG) e per la gestione di contesti molto lunghi, permettendo di interrogare e sintetizzare informazioni da ampi database con precisione e velocità.



Performance Ottimizzate

Con un eccellente bilanciamento tra dimensioni del modello e capacità di inferenza, Mistral offre prestazioni competitive anche su hardware meno potente, rendendolo flessibile per deployment su larga scala e in ambienti con risorse limitate.



Flessibilità di Deployment

La sua ottimizzazione consente un'ampia versatilità di implementazione, dal cloud all'edge computing, fornendo una soluzione robusta e adattabile per diverse esigenze aziendali.



MADE IN ITALY

Minerva — Il LLM Italiano

Minerva è la **prima famiglia di Large Language Model addestrati completamente da zero per la lingua italiana**, sviluppata dal gruppo Sapienza NLP dell'Università di Roma "La Sapienza", guidato dal Prof. Roberto Navigli.

Caratteristiche Chiave

- 7 miliardi di parametri (Minerva 7B)
- Addestrato su 1.5 trilioni di parole da fonti aperte
- Completamente open-source con licenza permissiva
- Bilingue italiano-inglese (50% dati in italiano)
- Instruction tuning con oltre 21.000 istruzioni in italiano
- Focus su sicurezza e riduzione contenuti indesiderati

Perché è Importante

- Primo LLM italiano addestrato da zero (non un adattamento)
- Trasparenza totale sui dati di training
- Ideale per la Pubblica Amministrazione
- Comprende le sfumature culturali e linguistiche italiane
- Addestrato sul supercomputer Leonardo di CINECA con fondi PNRR

📄 **Applicazioni:** comprensione del linguaggio naturale, generazione di testo, traduzione, assistenza clienti, documenti istituzionali. — **minerva-llm.org**

Modelli Closed Source: Una Panoramica

I modelli closed source sono soluzioni proprietarie sviluppate da aziende leader nel settore AI, offrendo spesso prestazioni all'avanguardia e funzionalità esclusive. Rappresentano una scelta strategica per applicazioni che richiedono il massimo in termini di ragionamento, sicurezza e integrazione aziendale.

Modello	Azienda	Tipo	Caso d’uso ideale	Note chiave
GPT-5.4	OpenAI	Propriet ario	Ragionamento complesso, coding, assistenti generali, analisi dati	Context 400K token. Modello di riferimento del mercato. ChatGPT è il prodotto consumer.
Claude Opus 4.6	Anthropic	Propriet ario	Coding, analisi documenti lunghi, enterprise, healthcare	Focus su sicurezza e allineamento. Sonnet eccelle nel coding, Opus nel ragionamento profondo.
Gemini 3.1 Pro	Google DeepMind	Propriet ario	Multimodale (testo+immagini+video+audio), ricerca, coding	Context window 1M token. Nativo multimodale. Integrato in Google Workspace.
Grok 4.1	xAI (Musk)	Propriet ario	Ragionamento puro, analisi in tempo reale, coding agentico	N.1 LMArena Elo. Tasso allucinazioni ridotto al 4%. Integrato con X/Twitter.
Copilot	Microsoft	Propriet ario	Produttività office, coding (GitHub Copilot), workflow aziendali	Integrato in Microsoft 365, Edge, Windows. Usa modelli OpenAI + famiglia Phi proprietaria.
Mistral Medium 3	Mistral AI (FR)	Propriet ario	Coding, RAG, multilingua europeo, enterprise EU	Azienda francese. Ottimo rapporto qualità/prezzo. Rilevante per compliance EU.
Command R+	Cohere	Propriet ario	RAG enterprise, ricerca semantica, multilingua	Ottimizzato specificamente per Retrieval-Augmented Generation aziendale.
Perplexity	Perplexity AI	Prodotto AI	Ricerca con citazioni, fact-checking, analisi fonti	Non è un LLM ma un motore di ricerca AI. Usa modelli propri + di terzi. Cita le fonti.

Dimensionamento Hardware

Il calcolo della VRAM richiesta è fondamentale per evitare errori costosi.

Formula: VRAM Totale = Peso del modello + KV Cache + ~20% overhead di sistema

1. Quantizzazione

Ridurre la precisione da FP16 (16-bit) a INT4 (4-bit) riduce il peso del modello di **~3-4 volte** con perdita minima di qualità.

2. KV Cache Impact

La memoria per il contesto cresce linearmente con il numero di utenti e la lunghezza del prompt. È spesso il vero collo di bottiglia.

Modello	Prec	VRAM	GPU
	.		
Llama-3-8B	FP16	~16 GB	RTX 3090/4090
Llama-3-8B	INT4	~5.5 GB	RTX 3060/L4
Mixtral-8x7B	INT4	~26 GB	2x RTX 4090
Llama-3-70B	INT4	~40 GB	A6000/A100 80GB

Precisione e Quantizzazione

Tipo	Bit	Uso	VRAM	Qualità
FP32	32 bit	Training, Ricerca	Altissima	Qualità Massima
FP16	16 bit	Inferenza Standard	Alta	Qualità Ottima
INT8	8 bit	Inferenza in Produzione	Media	Quasi Invariata
INT4	4 bit	Inferenza Cost-Efficiente	Molto Bassa	Lieve Degrado

❏ Un modello da **70B parametri** passa da ~140GB (FP16) a ~35GB (INT4), con perdita di qualità tipicamente **inferiore all'1%** in termini di perplexity.

GPU — Il Motore di Calcolo

La **VRAM** è la risorsa più critica. Determina quale modello puoi caricare e quanti utenti puoi servire.

Rule of thumb: 7B Params (FP16) $\approx$ 14GB VRAM

Enterprise (Consigliate)


- **NVIDIA L40S (48GB)** — Ottimo rapporto prezzo/prestazioni
- **NVIDIA A100 (40/80GB)** — Standard datacenter
- **NVIDIA H100 (80GB)** — Massime performance

Consumer (Dev/Test)

- **RTX 4090 (24GB)** — Ottima per sviluppo
- **RTX 3090 (24GB)** — Alternativa economica

Perché la GPU e non la CPU?

La VRAM (HBM3) offre **~3 TB/s** di banda, la RAM DDR5 si ferma a ~100 GB/s. Questa differenza di **30x** rende le GPU indispensabili. Gli LLM sono memory-bound, non compute-bound.



Benchmarking degli LLM — Come Valutare le Prestazioni

Come si misura la qualità di un modello? I benchmark principali:



MMLU

Valuta la conoscenza generale e la capacità di ragionamento su un'ampia gamma di argomenti accademici. Il test più usato per confrontare modelli generalisti.



HumanEval

Testa la capacità di generazione di codice corretto. Fondamentale per valutare modelli usati in automazione e sviluppo.



GSM8K

Misura le abilità di risoluzione di problemi matematici a livello scolastico. Importante per valutare il ragionamento logico.



MT-Bench & HELM

Valutazioni multilivello su prompt del mondo reale. HELM di Stanford valuta accuratezza, robustezza, fairness, bias, tossicità ed efficienza.

Benchmarking — Tabella Comparativa e Criteri di Scelta

Modello	MMLU	GSM8K	HumanEval	MT-Bench
Qwen 2.5 72B	88	84	85	8.8
LLaMA 3.3 70B	86	81	83	9.0
DeepSeek 67B	85	82	86	8.2
Mixtral 8x22B	82	76	78	8.0

❏ Non esiste un **"modello migliore in assoluto"**. La scelta dipende dal caso d'uso: Chat → LLaMA 3 | Ragionamento matematico → Qwen | Efficienza → Mistral | Enterprise bilanciato → Falcon

Metriche Operative per la Produzione

Token/secondo Throughput del sistema	TTFT Time to First Token — latenza percepita
Token/utente Per utente concorrente	Costo/M token Costo per milione di token generati



Prompt Engineering — Che Cos'è?

Il Prompt Engineering **NON** è semplicemente "fare domande" a un'IA. È la disciplina di progettare istruzioni precise e strutturate per guidare i modelli di linguaggio a produrre esattamente i risultati desiderati.

Il Nuovo Codice

Se prima servivano linguaggi di programmazione rigidi, oggi il prompting usa il **linguaggio naturale** per creare valore digitale.

No Code for Coding

L'intenzione umana viene tradotta dall'AI in esecuzione, rendendo accessibile la creazione di soluzioni complesse anche ai non tecnici.

Obiettivo

Trasformare un modello generico in uno strumento **specializzato e mirato** per ogni specifico caso d'uso di marketing.

Perché il Prompt Engineering Fa la Differenza

✗ Senza Prompt Engineering

- Output generico e poco utilizzabile
- Risposte vaghe, verbose, fuori target
- Necessità di riscrivere quasi tutto
- Tempo perso in iterazioni infinite


✓ Con Prompt Engineering

- Output mirato, specifico, professionale
- Tono, formato e contenuto calibrati
- Risultato utilizzabile al primo o secondo tentativo
- ROI immediato sul tempo investito

È come la differenza tra dire a un taxi *"portami da qualche parte"* e dare un indirizzo preciso con indicazioni stradali.

Il Framework **R.O.C.E.F.** — Anatomia di un Prompt Perfetto

5 elementi fondamentali per prompt che funzionano:

-  **R — ROLE (Ruolo)**
Chi deve essere l'AI? *"Sei un esperto di marketing digitale con 15 anni di esperienza nel settore lusso..."*
-  **O — OBJECTIVE (Obiettivo)**
Cosa deve fare? *"Crea un piano editoriale per Instagram per un brand di gioielleria..."*
-  **C — CONTEXT (Contesto)**
Qual è la situazione? *"Il brand ha appena lanciato una nuova collezione, target donne 30-50 anni, budget limitato..."*
-  **E — EXAMPLES (Esempi)**
Come deve essere il risultato? Fornire esempi di output desiderato, stile, formato.
-  **F — FORMAT (Formato e Vincoli)**
Come deve presentare il risultato? *"Formato tabella, massimo 12 post, tono elegante ma accessibile..."*

 **Regola d'oro:** Più contesto dai, migliore sarà il risultato. L'AI non legge nel pensiero.

Zero-Shot Prompting

Definizione: Chiedere una risposta diretta senza fornire esempi. L'AI si basa sulla sua conoscenza pre-esistente.

Quando usarlo: Task semplici, domande dirette, compiti dove l'AI ha già vasta conoscenza.

✗ Esempio DEBOLE

"Scrivi un post per Instagram"

Troppo vago. L'AI non sa nulla del contesto, del brand, del tono o dell'obiettivo.

✓ Esempio FORTE (Zero-shot strutturato)

"Scrivi un post Instagram per un ristorante stellato a Roma che lancia il nuovo menù degustazione primavera. Il post deve evocare i sapori stagionali, essere lungo max 150 parole, includere una CTA per la prenotazione, tono elegante e invitante. Includi 5 hashtag."

Few-Shot Prompting

Definizione: Fornire all'IA alcuni esempi di input→output desiderato per **"insegnarle"** lo stile e il formato.

📄 Esempio pratico — Descrizioni prodotto e-commerce:

"Ecco come scriviamo le nostre descrizioni:

Esempio 1 — Orologio sportivo waterproof:

Per chi non si ferma mai. Resistente all'acqua fino a 100m, design minimalista dal meeting al trail running. Il tempo è tuo, vivilo.

Esempio 2 — Borsa in pelle artigianale:

Ogni cucitura racconta una storia. Pelle conciata al vegetale, fatta a mano in Toscana. Non è un accessorio, è un pezzo d'arte.

Ora scrivi la descrizione per: Sneaker eco-sostenibile in materiali riciclati"

📄 **Vantaggio:** L'AI replica fedelmente tono, lunghezza e stile degli esempi.

Chain-of-Thought (CoT)

Definizione: Richiedere all'IA di ragionare passo dopo passo. Migliora drasticamente la qualità su compiti complessi.

Quando usarlo: Analisi di mercato, segmentazione, allocazione budget, decisioni strategiche.

"Devo decidere se il mio brand di cosmetici naturali dovrebbe entrare nel mercato tedesco. Ragiona passo dopo passo:

1. Analizza le dimensioni e tendenze del mercato cosmetico naturale in Germania
2. Identifica i principali competitor
3. Valuta le barriere all'ingresso (normative, culturali, logistiche)
4. Stima i costi iniziali di marketing e distribuzione
5. Fornisci una raccomandazione finale con pro e contro

Mostra il tuo ragionamento per ogni passaggio."

Forza ragionamento step-by-step

Produce analisi più profonde

Riduce le allucinazioni

Role-Play e Tecniche Avanzate

Role-Play

Assegnare un ruolo specifico all'IA per contestualizzare tono, prospettiva e competenza.

Esempi di ruoli potenti per il marketing:

- "Sei il CMO di un brand DTC con 10 anni di esperienza nella crescita da 0 a 50M€"
- "Agisci come un copywriter senior specializzato in email marketing B2B SaaS"
- "Sei un consulente di strategia digitale che presenta al board di una PMI i vantaggi dell'AI"

Prompt Chaining

Suddividere un compito complesso in una catena di prompt sequenziali.



Tree of Thought

Esplorare più percorsi in parallelo prima di convergere sulla soluzione migliore. *"Proponi 3 strategie alternative per il lancio. Per ciascuna, analizza pro, contro e ROI atteso."*

Gli Errori Più Comuni nel Prompting

1. Prompt troppo vaghi

"Fammi un piano marketing" — Non specifica settore, budget, target, canali

2. Assenza di contesto

L'AI non conosce la vostra azienda. Dovete fornire **TUTTO** il contesto rilevante

3. Aspettarsi la perfezione al primo colpo

Il prompting è un **processo iterativo**

4. Non specificare il formato

Senza indicazioni, l'AI sceglie un formato generico

5. Overloading

Troppe richieste in un singolo prompt. Meglio usare **Prompt Chaining**

6. Ignorare la temperatura

Prompt creativi richiedono più libertà, prompt analitici più rigore

Meta-Prompting e Human in the Loop

Meta-Prompting

Chiedere all'AI stessa di analizzare, criticare e migliorare i propri prompt.

01

Scrivi il prompt iniziale

02

Chiedi all'AI di analizzarlo

03

L'AI fornisce prompt migliorato + critica + domande

04

Itera fino al risultato perfetto

Human in the Loop

L'IA è un copilota che aumenta la produttività (fino al -40% su task ripetitivi). La supervisione umana rimane cruciale per la responsabilità strategica.

Validazione

L'umano verifica l'output dell'AI prima di agire

Correzione

Feedback continuo per migliorare le risposte

Responsabilità

Le decisioni strategiche restano umane

Lab Pratico — Installare e Usare Ollama

Ollama è lo strumento ideale per iniziare a sperimentare con gli LLM in locale, **senza cloud e senza costi**.

⚡ Installazione (3 minuti)

macOS/Linux:

```
curl -fsSL https://ollama.com/install.sh | sh
```

Windows: Scarica da ollama.com

Verifica:

```
ollama --version
```

🚀 Scaricare e Avviare un Modello

```
ollama pull llama3.1:8b
```

```
ollama run llama3.1:8b
```

```
ollama list
```

📦 Modelli Consigliati per Iniziare

llama3.1:8b

Generalista, ottimo bilanciamento (~5GB RAM)

mistral:7b

Efficiente, ottimo per RAG

phi3:mini

Ultra-leggero, gira anche su laptop base

qwen2.5:7b

Forte nel coding e multilingua

Lab Pratico — Ollama per Task Semplici

1

Generazione Contenuti Social

>>> Sei un social media manager esperto. Crea 3 post Instagram per un ristorante vegano a Milano che lancia il menù autunnale. Per ogni post includi: testo (max 100 parole), 5 hashtag, emoji appropriate. Tono: caldo e invitante.

2

Traduzione e Localizzazione

>>> Traduci questo testo di marketing dall'italiano all'inglese mantenendo il tono emotivo e persuasivo. Adatta i riferimenti culturali per il mercato anglosassone: [testo]

3

Riassunto Documenti

>>> Riassumi questo report in 5 bullet point chiave per una presentazione al board. Evidenzia: dati numerici, trend principali, raccomandazioni: [testo]

4

Brainstorming

>>> Genera 10 idee creative per una campagna di lancio di un'app di fitness rivolta ai millennials italiani. Per ogni idea specifica: canale, format, hook principale.

Lab Pratico — Ollama per Applicazioni Aziendali

Analisi Email Clienti

"Analizza queste 5 email di reclamo dei clienti. Per ciascuna identifica: 1) Problema principale 2) Livello di urgenza 3) Sentiment 4) Azione suggerita. Presenta i risultati in formato tabella."

Generazione FAQ

"Basandoti su questo documento di prodotto, genera 15 domande frequenti (FAQ). Per ogni FAQ fornisci: domanda, risposta concisa (max 50 parole), categoria (pre-vendita/post-vendita/tecnica)."

Competitive Intelligence

"Agisci come un analista di mercato senior. Dato il seguente brief sulla nostra azienda e questi dati sui competitor, crea una matrice SWOT. Poi suggerisci 3 azioni strategiche prioritarie per i prossimi 6 mesi, con KPI misurabili."

Ollama via API (per sviluppatori)

```
curl http://localhost:11434/api/generate -d '{  
  "model": "llama3.1:8b",  
  "prompt": "Analizza il sentiment di questo testo: ...",  
  "stream": false  
}'
```

-  Questo permette di integrare l'LLM locale in qualsiasi applicazione aziendale: CRM, ERP, chatbot, workflow di automazione.

Caso Pratico — Post LinkedIn Senza vs Con Prompt Engineering

Scenario: Lancio startup di delivery medicinali per la terza età.

✗ SENZA Prompt Engineering

Prompt: *"Crea un post per LinkedIn che parli di un nuovo servizio di delivery di medicinali pensato per la terza età."*

- ❏ Risultato: Testo generico, lungo, strutturato come un articolo accademico. Nessun gancio emotivo, nessuna CTA forte. Non ottimizzato per LinkedIn.

✓ CON Prompt Engineering

Prompt strutturato con **10 istruzioni precise**: iniziare con provocazione, prospettiva personale, causa del problema, presentare la soluzione, evidenziare scalabilità, CTA forte, hashtag, vincolo lunghezza 900-1300 caratteri, tono empatico-visionario.

"Possiamo ricevere una pizza in 8 minuti. Ma non possiamo garantire un farmaco essenziale a un genitore anziano."

Storytelling efficace, ritmo da LinkedIn, CTA chiara.

- ❏ La differenza è evidente: stesso strumento AI, ma il Prompt Engineering trasforma un output mediocre in **contenuto di alta qualità**. L'80% della qualità dipende dalla qualità del prompt.

Lab — Meta-Prompting per LinkedIn (15-20 min)

Obiettivo

Sperimentare il **meta-prompting iterativo** per creare un post LinkedIn professionale.

Strumento

ChatGPT, Claude, Gemini o altro strumento AI (anche Ollama!)

Task

Scrivere un post LinkedIn per promuovere un servizio, prodotto, evento o posizionamento professionale.

Il Processo Iterativo

01

Chiedete all'AI di diventare il vostro **consulente di prompting** ("Expert Prompt Creator")

02

L'AI genera il **miglior prompt possibile**

03

L'AI fornisce una **critica costruttiva**

04

L'AI pone **domande per migliorare** ulteriormente

05

Voi rispondete alle domande, il prompt **migliora ad ogni ciclo**

06

Salvate il risultato finale per la **condivisione**

Riepilogo — Le 10 Regole d'Oro del Prompt Engineering

1

Sii specifico

Più contesto = migliori risultati

2

Assegna sempre un ruolo

L'AI performa meglio "nei panni" di un esperto

3

Struttura il prompt

Usa il framework R.O.C.E.F.

4

Fornisci esempi

Il few-shot è potentissimo

5

Chain-of-Thought

Chiedi ragionamento step-by-step per compiti complessi

1

Specifica formato e vincoli

Lunghezza, tono, struttura, lingua

2

Itera sempre

Il primo output è un punto di partenza

3

Usa il meta-prompting

Lascia che l'AI ti aiuti a migliorare

4

Adatta al target

Stesso contenuto, messaggi diversi per audience diverse

5

Supervisione umana sempre

L'AI è un copilota, non il pilota

❏ **L'80% della qualità dell'output dipende dalla qualità del prompt.**