



Sistema di Previsione Cancellazioni Prenotazioni Hotel (ML)

Previsione della probabilità che una prenotazione sia **confermata** (non cancellata)

Il Problema


Molte prenotazioni vengono cancellate, causando perdita di ricavi e camere vuote nei periodi di alta domanda.

L'Obiettivo

Stimare la **probabilità di conferma** per ogni prenotazione, identificando quelle a rischio prima che si cancellino.

L'Output

Supporto a **pricing dinamico** e **gestione della disponibilità** camere in tempo reale.



Target e Valore per il Business

Definizione del Target

La variabile originale del dataset è **is_canceled** (1 = cancellata, 0 = non cancellata).

Nel progetto è stata trasformata in:
booking_confirmed = 1 - is_canceled, dove 1 = confermata e 0 = cancellata. Questo rende l'output più intuitivo e orientato al business.

Valore Business Generato

- **Pricing dinamico:** alta probabilità di conferma → prezzo leggermente più alto; bassa probabilità → piccolo sconto per incentivare la conferma.
- **Yield management:** migliore allocazione delle camere nei periodi di alta domanda, riducendo il rischio di overbooking o camere vuote.
- **Riduzione cancellazioni:** applicare deposito o regole di cancellazione diverse per le prenotazioni classificate ad alto rischio.

Workflow del Progetto – Dal Dato alla Strategia di Business



Il progetto segue un flusso strutturato che trasforma dati storici in decisioni strategiche concrete.

Dataset e Variabili

Fonte e Dimensione

Dataset: Hotel Booking Demand (Kaggle)

Righe: ~120.000

Variabili: 30+ di tipo diverso: numeriche, categoriche, temporali

Unità di analisi: 1 riga = 1 prenotazione

Variabili Principali

Tempo

lead_time,
arrival_date_year/month/day,
stays_in_week_nights,
stays_in_weekend_nights,
total_nights

Cliente e Canale

market_segment,
distribution_channel,
customer_type, country


Prezzo e Condizioni

adr, deposit_type

Segnali di Intenzione

total_of_special_requests, booking_changes, required_car_parking_spaces, days_in_waiting_list

Stato Prenotazione



La distribuzione del target mostra che circa il **63%** delle prenotazioni risulta **confermata**, mentre il **37%** viene **cancellata** — una proporzione significativa che giustifica l'adozione di un modello predittivo.

Preparazione Dati e Nuove Feature



Il dataset grezzo è stato trasformato in due fasi successive: prima la pulizia, poi l'arricchimento con nuove feature ingegnerizzate.

Pulizia dei Dati

- Controllo valori mancanti e tipi di dato (es. **company**, **agent**, **country**)
- Gestione dei null: sostituzione dove ha senso (es. company/agent → 0) e rimozione righe quando necessario (es. country null)
- Controllo e riduzione delle categorie rare per diminuire la complessità del modello


Feature Engineering – Nuove Colonne

- **arrival_date**: unione di anno, mese e giorno di arrivo
- **season**: stagione di arrivo (winter / spring / summer / autumn)
- **weekend_flag**: flag per soggiorni che includono il weekend
- **lead_time_group**: fasce temporali di anticipo prenotazione
- **stay_type**: classificazione della durata del soggiorno
- **trip_type**: tipo di viaggio (business / weekend / mixed)
- **country_group**: top paesi + raggruppamento "Other"

Il Tempo Influenza il Rischio di Cancellazione

Insight chiave: lead_time è una delle variabili più importanti dell'intero modello. Le prenotazioni last minute sono molto più stabili di quelle fatte con largo anticipo.

Tasso di Conferma per Lead Time Group



→ **Last Minute (0-7 giorni)**
Circa il **90% delle prenotazioni** viene confermata. Chi prenota all'ultimo momento ha quasi certamente intenzione di soggiornare.

→ **Anticipo Elevato (180+ giorni)**
Il rischio di cancellazione aumenta drasticamente. Oltre i 600 giorni di anticipo, **quasi tutte le prenotazioni vengono cancellate**.


Tasso di Conferma per Stagione



→ **Effetto Stagionale**
In **estate** la probabilità di cancellazione è leggermente più alta rispetto alle altre stagioni, probabilmente per la maggiore offerta alternativa.

Il Tipo di Cliente e il Canale Influenzano la Stabilità

Conferma per Market Segment e Customer Type



Messaggi Principali

Direct e Corporate → Più Affidabili

I clienti che prenotano direttamente o tramite canale corporate mostrano tassi di conferma significativamente più alti. Il contatto diretto con la struttura riduce il rischio di abbandono.

Online TA → Più Cancellazioni

Le prenotazioni tramite agenzie di viaggio online (OTA) presentano il tasso di cancellazione più elevato. La facilità di cancellazione gratuita offerta da queste piattaforme è un fattore determinante.

Variabilità per Paese


Alcuni paesi mostrano comportamenti sistematicamente diversi: il **country_group** è quindi una variabile rilevante per la previsione del rischio.

Insight: Il canale di prenotazione è un forte indicatore del rischio di cancellazione e deve essere incluso nel modello.


Segnali che Indicano Alta Probabilità di Conferma

Le richieste speciali, le modifiche alla prenotazione e la richiesta di parcheggio sono i segnali più forti di reale intenzione di soggiorno. Chi si impegna attivamente nella prenotazione raramente la cancella.

Conferma per Numero di Richieste Speciali



Source:



Source:

Messaggi Chiave

0 Richieste Speciali

~50% di conferma. La prenotazione è a rischio elevato: il cliente non ha ancora mostrato coinvolgimento reale.

4+ Richieste Speciali

~90% di conferma. Chi personalizza il soggiorno ha chiaramente intenzione di presentarsi.

Modifiche alla Prenotazione

Chi modifica la prenotazione è molto più stabile: l'interazione attiva è un segnale positivo.

Richiesta Parcheggio

Alta probabilità di conferma: chi pianifica la logistica del viaggio raramente cancella.

"L'analisi esplorativa mostra che la probabilità di conferma dipende principalmente da: anticipo della prenotazione, canale di prenotazione e segnali di coinvolgimento del cliente."

Preparazione dei Dataset per il Machine Learning

Primo Approccio: Preprocessing **Manuale**

Descrizione: Trasformazioni applicate manualmente

Operazioni:

- Encoding delle variabili categoriche
- Normalizzazione delle variabili numeriche

Vantaggio: Controllo diretto delle trasformazioni applicate ai dati


Secondo Approccio: Preprocessing **Automatico** (Dataiku)

Descrizione: Preprocessing gestito direttamente da Dataiku durante l'addestramento

Operazioni automatiche:

- Encoding delle variabili categoriche
- Scaling delle variabili numeriche
- Gestione dei valori mancanti

Vantaggio: Semplifica il processo di modellazione



Confronto dei Risultati

Modello	Manuale	Automatico (Dataiku)
LightGBM	0.942	0.942
Logistic Regression	0.911	0.910

Modelli di Machine Learning Utilizzati

Il problema è una **classificazione binaria**: il modello deve prevedere se una prenotazione sarà confermata (1) o cancellata (0). Sono stati testati due approcci complementari.

Modello 1 – Logistic Regression (Baseline)

- Modello lineare, semplice e interpretabile
- Utilizzato come punto di riferimento (baseline) per valutare il miglioramento dei modelli più complessi
- Parametro principale: **C = 1** (Dataiku ha utilizzato una procedura di **hyperparameter search** per trovare il valore migliore)
- Vantaggi: veloce da addestrare, facile da spiegare al business

Modello 2 – LightGBM (Modello Finale)

- Il modello utilizza il metodo: **Gradient Boosting Decision Tree**
- Adatto a dataset di grandi dimensioni (~120.000 righe)
- Cattura relazioni non lineari tra le variabili
- Gestisce bene **variabili numeriche e categoriali**
- **Parametri principali:**
 - ~102 alberi (n_estimators)
 - 31 foglie per albero (num_leaves)
 - Learning rate = 0.05

Logistic Regression		0.910	✓ Done 25 minutes ago (2026-03-06 16:11:21)	☆ ⋮	
C Penalty Hyperparameter search size	1.0 12 5	Most important features		Train set Test set Train time	95108 rows 23786 rows about 36 seconds
		country_group			
		agent_group			
		deposit_type			
		special_requests_group			
		room_changed			
		lead_time			
				OPEN >	

LightGBM		🏆 0.942	✓ Done 25 minutes ago (2026-03-06 16:11:09)	☆ ⋮	
Boosting type Nb. estimators Nb. leaves Learning rate Hyperparameter search size	gbdt 102 31 0.05 2	Most important features		Train set Test set Train time	95108 rows 23786 rows about 24 seconds
		deposit_type			
		country_group			
		market_segment			
		agent_group			
		special_requests_group			
		lead_time			
				OPEN >	

Confronto delle Performance

Metrica Utilizzata: ROC AUC

Il ROC AUC misura la capacità del modello di distinguere correttamente tra prenotazioni confermate e cancellate, indipendentemente dalla soglia di classificazione scelta.

0.5

Modello Casuale

Nessuna capacità discriminante —
equivale a lanciare una moneta.

0.91

Logistic Regression

Ottimo risultato per un modello
baseline lineare.

0.942

LightGBM

Modello scelto per l'analisi finale.
Risultato eccellente.

Interpretazione dei Risultati

- Entrambi i modelli performano **molto bene**, superando ampiamente la soglia di 0.8 considerata un buon modello
- LightGBM ottiene risultati migliori** (+0.04 rispetto alla Logistic Regression)
- Il modello scelto per l'analisi finale è **LightGBM**


Le ragioni principali sono:

- LightGBM riesce a catturare **relazioni più complesse tra le variabili**
- gestisce meglio dataset **di grandi dimensioni**
- è particolarmente efficace con **molte variabili categoriali**

Il modello riesce a distinguere in modo molto accurato tra prenotazioni confermate e cancellate.

Quali Variabili Influenzano di Più la Conferma?

Feature Importance – LightGBM (Top 7)



❏ **Conclusion:** Il modello non decide in modo casuale — usa variabili coerenti con il comportamento reale dei clienti, confermando la solidità dell'approccio.

Interpretazione delle Variabili Chiave

→ Deposit Non Rimborsabile

Chi paga un deposito non rimborsabile ha meno incentivo a cancellare → **meno cancellazioni**.

→ Country Group

Alcuni paesi mostrano comportamenti sistematicamente diversi nella propensione alla cancellazione.

→ Lead Time Alto

Più è lontana la data di arrivo al momento della prenotazione, **più alto è il rischio** di cancellazione.

→ Richieste Speciali e Parcheggio

Molte richieste speciali e la richiesta di parcheggio sono **segnali forti di reale intenzione** di soggiorno.

Strategie di Business (1/2) – Gestione del Rischio

Depositi Intelligenti



Insight: deposit_type è la variabile più importante del modello

Azione: Deposito parziale/non rimborsabile per prenotazioni ad alto rischio; deposito flessibile per clienti affidabili

Obiettivo: Ridurre le cancellazioni mantenendo competitività

Gestione Canali di Vendita



Insight: market_segment influisce molto sul comportamento dei clienti

Azione: Incentivare Direct e Corporate; politiche più restrittive per OTA

Obiettivo: Migliorare la qualità delle prenotazioni

Strategie per Paese di Origine



Insight: country_group è tra le feature più importanti del modello

Azione: Offerte dedicate per paesi affidabili; conferma anticipata o depositi per paesi ad alto rischio

Obiettivo: Migliorare il tasso di conferma internazionale

Ottimizzazione tramite Agenti



Insight: agent_group è una variabile molto importante nel modello

Azione: Rafforzare collaborazione con agenti virtuosi; monitorare agenti con alta cancellazione

Obiettivo: Migliorare la qualità delle prenotazioni da agenzie

Strategie di Business (2/2) – Valorizzazione e Revenue

Gestione Prenotazioni Anticipate



Insight: lead_time alto indica maggiore rischio di cancellazione

Azione: Promozioni per chi conferma vicino alla data di arrivo; deposito per prenotazioni molto anticipate

Obiettivo: Ridurre l'incertezza delle prenotazioni future

Offerte per Clienti con Parcheggio



Insight: needs_parking indica clienti con soggiorni più strutturati (famiglie, viaggi lunghi)

Azione: Pacchetti con parcheggio incluso; offerte per soggiorni più lunghi

Obiettivo: Aumentare la durata media del soggiorno

Valorizzare Clienti con Richieste Speciali



Insight: special_requests_group è correlata con prenotazioni più affidabili

Azione: Offrire upgrade o servizi personalizzati; creare pacchetti premium per questi clienti

Obiettivo: Aumentare il valore medio della prenotazione

Pricing Dinamico tramite Probabilità del Modello



Insight: Il modello produce una probabilità di conferma per ogni prenotazione

Azione: Alta probabilità → prezzo leggermente più alto; bassa probabilità → sconto o incentivo


Obiettivo: Massimizzare i ricavi mantenendo un buon tasso di occupazione

Validazione del Modello su Dati Nuovi (2024)

Il modello LightGBM è stato addestrato sui dati storici (2015–2017). In questa fase lo applico ai dati del 2024 per testarne l'efficacia in uno scenario realistico..

Questa sezione simula l'uso operativo, confrontando le previsioni su dati nuovi e sconosciuti con gli esiti reali per misurare la precisione.

Esploreremo l'intera pipeline: dalla preparazione dei dati 2024 alla valutazione finale del modello.



Pipeline 2024: Dalla Preparazione alla Predizione



Questa pipeline illustra il processo end-to-end per applicare il nostro modello LightGBM ai nuovi dati del 2024, trasformando i dati grezzi in previsioni utilizzabili per decisioni strategiche.

❏ **Perché rimuovere il target?** In uno scenario reale, al momento dello scoring, la variabile ``booking_confirmed`` (esito futuro) non è ancora nota. Il modello deve prevederla.

A cosa serve ``row_id``? Consente di unire in modo sicuro le previsioni del modello con gli esiti reali una volta che diventano disponibili, per una valutazione accurata delle performance.

Output dello Scoring: Probabilità e Predizioni

Cosa Produce il Modello

Il modello LightGBM genera per ogni prenotazione una previsione dettagliata, fondamentale per le decisioni strategiche:

- `proba_0`: Probabilità che la prenotazione sia **cancellata** (Classe 0)
- `proba_1`: Probabilità che la prenotazione sia **confermata** (Classe 1)
- `prediction`: La classe predetta (**0 o 1**), basata sulla soglia definita (**0.375**)

Come Interpretare la Probabilità di Conferma (`proba_1`)

- Se `proba_1` è **vicino a 1** (es. 0.85): Il modello è molto sicuro che la prenotazione sarà **confermata**.
- Se `proba_1` è **vicino a 0.375**: Il modello è incerto; la prenotazione potrebbe andare in entrambi i modi.
- Se `proba_1` è **vicino a 0** (es. 0.15): Il modello è molto sicuro che la prenotazione sarà **cancellata**.

Flessibilità della Soglia:

La soglia standard per la previsione è **0.375** (`prediction = 1` se `proba_1 > 0.375`). Tuttavia, questa soglia può essere **personalizzata** per allinearsi meglio agli obiettivi di business, ad esempio per ridurre i falsi positivi (cancellazioni previste ma che si confermano) o i falsi negativi (conferme previste ma che si cancellano).

Unione Predizioni e Realtà: Preparazione alla Valutazione

Il Problema: Come Confrontare Previsioni con Esiti Reali?

Per valutare l'accuratezza del modello sviluppato in questo progetto, devo confrontare le sue previsioni con ciò che è realmente accaduto. Il problema è come combinare questi due set di informazioni in modo affidabile:

- Le **predizioni del modello** (`proba\_1`, `prediction`) per le prenotazioni del 2024 sono salvate in `hotel_booking_2024_prediction`.
- Gli **esiti reali** (`booking\_confirmed`) delle stesse prenotazioni sono disponibili in `hotel_booking_2024_new_primary_key`.
- Per valutare il modello è necessario unire questi due dataset in modo sicuro, veloce e senza errori.

La Soluzione: Join su `row_id`

Il segreto per unire correttamente le previsioni agli esiti reali è l'utilizzo di una chiave univoca e consistente attraverso entrambi i dataset: il `row_id`.

Dataset Predizioni (A)

Contiene le stime del modello:

- `row_id`
- `proba_1` (Probabilità di conferma)
- `prediction` (Classe predetta)

Dataset Esiti Reali (B)

Contiene gli esiti osservati:

- `row_id`
- `booking_confirmed` (Confermato/Cancellato)

⬇ **Join Condition:** `Dataset A.row_id = Dataset B.row_id` ⬇

Questo processo genera un dataset unificato (`hotel_booking_2024_joined`), pronto per l'analisi delle performance.

Perché `row_id` è Cruciale?

- Una join basata su più colonne (es. `lead_time`, `mese`, `tipo_camera`) sarebbe rischiosa, potendo generare duplicati o errori di matching.
- `row_id` è una **chiave univoca e sequenziale** (e.g., 0, 1, 2, ..., 119382) assegnata a ogni singola prenotazione.
- Garantisce una **join 1-a-1** veloce e corretta, assicurando che ogni previsione sia associata al suo esito reale corrispondente.

📄 **Struttura del Dataset Finale:** Dopo la join, il nostro dataset includerà le colonne: `row_id`, `proba_1`, `prediction`, e `booking_confirmed`.

Questo ci permette di calcolare metriche chiave come: matrice di confusione, accuratezza (accuracy), precisione (precision), richiamo (recall) e F1-score, per una valutazione completa delle performance del modello.

Risultati della Valutazione: Performance del Modello su Dati 2024

Matrice di Confusione

La matrice di confusione mostra la distribuzione delle previsioni del modello rispetto agli esiti reali sul dataset del 2024.


	Predizione: 0 (Cancellata)	Predizione: 1 (Confermata)
Reale: 0 (Cancellata)	34 698 (TN)	9 456 (FP)
Reale: 1 (Confermata)	6 919 (FN)	67 821 (TP)

Totale prenotazioni valutate: 119,383

Metriche di Performance

Queste metriche riassumono l'efficacia del modello nel prevedere le cancellazioni e le conferme.

Metriche



Il grafico a barre mostra il valore percentuale delle metriche di valutazione chiave del modello. Con valori elevati sia per Precision che per Recall (entrambi superiori all'87%), il modello si dimostra ben bilanciato e affidabile sia nell'identificare correttamente le conferme sia nell'evitare falsi positivi.

Interpretazione Pratica

- **Alto Recall (91.46%):** Il modello cattura la grande maggioranza delle prenotazioni che si **confermeranno**.
- **Alta Precision (87.66%):** Quando il modello predice una **conferma**, ha ragione l'87.66% delle volte – molto più affidabile della versione precedente.
- **F1-Score elevato (89.52%):** Ottimo bilanciamento tra precision e recall.
- **Accuracy (86.63%):** Il modello classifica correttamente quasi 9 prenotazioni su 10.

In sintesi, il modello è ora più equilibrato e affidabile, con un'alta capacità di identificare le prenotazioni confermate (alto Recall) e una maggiore affidabilità nelle sue previsioni di conferma (alta Precision).

Possibili Miglioramenti e Trade-off

📄 Aumentare la Soglia di `proba_1`:

- Per ridurre i Falsi Positivi (prenotazioni previste come confermate ma che si cancellano), potremmo aumentare la soglia di decisione per `proba_1` (es. da **0.375** a 0.5 o 0.6).
- **Implicazione:** Questo aumenterebbe ulteriormente la **Precision** (il modello sarebbe ancora più affidabile quando predice una conferma), ma potrebbe ridurre il **Recall** (potrebbe non catturare tutte le conferme reali, aumentando i Falsi Negativi).

Il trade-off tra Precision e Recall deve essere bilanciato in base agli obiettivi di business specifici. Se l'hotel preferisce non rischiare di overbookare (alta precisione nelle conferme), potrebbe voler aumentare la soglia. Se invece l'obiettivo primario è non perdere nessuna prenotazione confermata (alto recall), la soglia attuale potrebbe essere più adeguata.

Validazione Completata: Modello Pronto per il Deployment

Cosa Abbiamo Imparato

I rigorosi test sul modello predittivo delle cancellazioni hanno fornito risultati chiari e incoraggianti:

Robustezza Verificata

Il modello LightGBM, addestrato su dati 2015-2017, ha mantenuto un'accuratezza dell'86.63% su dati completamente nuovi del 2024. Questo dimostra una forte capacità di generalizzazione e assenza di overfitting.

Coerenza delle Performance

Le performance osservate durante la fase di validazione sono coerenti con quelle registrate durante il training iniziale, confermando l'affidabilità del modello in scenari reali.

Punti di Forza del Modello

Performance Bilanciate ed Elevate

Il modello dimostra un **Recall elevato (91.46%)**, identificando la grande maggioranza delle prenotazioni che si confermeranno, e un'altrettanto forte **Precisione (87.66%)**, garantendo che le sue previsioni di conferma siano altamente affidabili. L'alto **F1-Score (89.52%)** conferma un ottimo bilanciamento tra queste metriche.

Affidabilità nelle Conferme

La sua elevata capacità di "catturare" le conferme e l'affidabilità nelle previsioni lo rendono uno strumento robusto per identificare le prenotazioni stabili, permettendo decisioni più sicure riguardo all'allocazione delle risorse e minimizzando il rischio di overbooking e perdite di opportunità.

Aree di Ulteriore Ottimizzazione


- Riduzione dei Falsi Positivi Residui:** Sebbene la Precisione sia ora elevata, c'è sempre spazio per affinare ulteriormente il modello per minimizzare i falsi positivi residui (prenotazioni previste come confermate che si cancellano). Questo può essere raggiunto attraverso un'ulteriore ingegnerizzazione delle feature (feature engineering) o un tuning più fine degli iperparametri, concentrandosi sulle casistiche borderline.
- Soglia Adattabile:** Esiste la possibilità di aggiustare la soglia di decisione per `proba_1`, personalizzandola in base agli specifici obiettivi di business (es. priorità assoluta alla riduzione dell'overbooking vs. massimizzazione delle occupazioni con un rischio controllato di cancellazioni non previste). Questo consente una flessibilità operativa per l'hotel.

Il Percorso del Progetto – Dal Dato alla Decisione

Il Percorso del Progetto



Feature più Importanti del Modello



Il Risultato

Il modello LightGBM, addestrato su dati 2015–2017 e validato su dati 2024, classifica correttamente l'86.63% delle prenotazioni — con un Recall del 91.46% e una Precision dell'87.66%. Un sistema pronto per guidare decisioni operative concrete nel settore alberghiero.

Prossimi Passi Concreti



Deployment in Produzione

Implementare il modello per lo scoring in tempo reale delle nuove prenotazioni, integrando le previsioni nei flussi di lavoro esistenti dell'hotel.



Monitoraggio Continuo

Stabilire un sistema di monitoraggio delle performance per rilevare eventuali derive del modello e garantire l'accuratezza nel tempo.



Feedback Operativo

Raccogliere feedback dagli operatori dell'hotel per identificare ulteriori opportunità di miglioramento e affinare il modello.



Integrazione Strategica

Esplorare l'integrazione del modello con i sistemi di pricing dinamico e gestione delle camere per massimizzare i ricavi e l'efficienza operativa.

In questo progetto ho trasformato circa 120.000 prenotazioni storiche in un modello predittivo validato.

Il modello raggiunge circa l'87% di accuratezza, con Precision e Recall superiori all'87%, rendendolo uno strumento ben bilanciato e pronto per la produzione.

Questo dimostra come il Machine Learning possa essere applicato concretamente alla gestione alberghiera per supportare decisioni strategiche basate sui dati.