



Sistema di Previsione Cancellazioni Prenotazioni Hotel (ML)

Previsione della probabilità che una prenotazione sia **confermata** (non cancellata)

Il Problema


Molte prenotazioni vengono cancellate, causando perdita di ricavi e camere vuote nei periodi di alta domanda.

L'Obiettivo

Stimare la **probabilità di conferma** per ogni prenotazione, identificando quelle a rischio prima che si cancellino.

L'Output

Supporto a **pricing dinamico** e **gestione della disponibilità** camere in tempo reale.



Target e Valore per il Business

Definizione del Target

La variabile originale del dataset è **is_canceled** (1 = cancellata, 0 = non cancellata).

Nel progetto è stata trasformata in:

booking_confirmed = $1 - \text{is_canceled}$, dove 1 = confermata e 0 = cancellata. Questo rende l'output più intuitivo e orientato al business.

Valore Business Generato

- **Pricing dinamico:** alta probabilità di conferma → prezzo leggermente più alto; bassa probabilità → piccolo sconto per incentivare la conferma.
- **Yield management:** migliore allocazione delle camere nei periodi di alta domanda, riducendo il rischio di overbooking o camere vuote.
- **Riduzione cancellazioni:** applicare deposito o regole di cancellazione diverse per le prenotazioni classificate ad alto rischio.

Workflow del Progetto – Dal Dato alla Strategia di Business



Il progetto segue un flusso strutturato che trasforma dati storici in decisioni strategiche concrete.

Dataset e Variabili

Fonte e Dimensione

Dataset: Hotel Booking Demand (Kaggle)

Righe: ~120.000

Variabili: 30+ di tipo diverso: numeriche, categoriche, temporali

Unità di analisi: 1 riga = 1 prenotazione

Variabili Principali

Tempo

lead_time,
arrival_date_year/month/day,
stays_in_week_nights,
stays_in_weekend_nights,
total_nights

Cliente e Canale

market_segment,
distribution_channel,
customer_type, country


Prezzo e Condizioni

adr, deposit_type

Segnali di Intenzione

total_of_special_requests, booking_changes, required_car_parking_spaces, days_in_waiting_list

Stato Prenotazione



La distribuzione del target mostra che circa il **63%** delle prenotazioni risulta **confermata**, mentre il **37%** viene **cancellata** — una proporzione significativa che giustifica l'adozione di un modello predittivo.

Preparazione Dati e Nuove Feature



Il dataset grezzo è stato trasformato in due fasi successive: prima la pulizia, poi l'arricchimento con nuove feature ingegnerizzate.

Pulizia dei Dati

- Controllo valori mancanti e tipi di dato (es. **company**, **agent**, **country**)
- Gestione dei null: sostituzione dove ha senso (es. company/agent → 0) e rimozione righe quando necessario (es. country null)
- Controllo e riduzione delle categorie rare per diminuire la complessità del modello


Feature Engineering – Nuove Colonne

- **arrival_date**: unione di anno, mese e giorno di arrivo
- **season**: stagione di arrivo (winter / spring / summer / autumn)
- **weekend_flag**: flag per soggiorni che includono il weekend
- **lead_time_group**: fasce temporali di anticipo prenotazione
- **stay_type**: classificazione della durata del soggiorno
- **trip_type**: tipo di viaggio (business / weekend / mixed)
- **country_group**: top paesi + raggruppamento "Other"

Il Tempo Influenza il Rischio di Cancellazione

Insight chiave: lead_time è una delle variabili più importanti dell'intero modello. Le prenotazioni last minute sono molto più stabili di quelle fatte con largo anticipo.

Tasso di Conferma per Lead Time Group



→ **Last Minute (0-7 giorni)**
Circa il **90% delle prenotazioni** viene confermata. Chi prenota all'ultimo momento ha quasi certamente intenzione di soggiornare.

→ **Anticipo Elevato (180+ giorni)**
Il rischio di cancellazione aumenta drasticamente. Oltre i 600 giorni di anticipo, **quasi tutte le prenotazioni vengono cancellate**.


Tasso di Conferma per Stagione



→ **Effetto Stagionale**
In **estate** la probabilità di cancellazione è leggermente più alta rispetto alle altre stagioni, probabilmente per la maggiore offerta alternativa.

Il Tipo di Cliente e il Canale Influenzano la Stabilità

Conferma per Market Segment e Customer Type



Messaggi Principali

Direct e Corporate → Più Affidabili

I clienti che prenotano direttamente o tramite canale corporate mostrano tassi di conferma significativamente più alti. Il contatto diretto con la struttura riduce il rischio di abbandono.

Online TA → Più Cancellazioni

Le prenotazioni tramite agenzie di viaggio online (OTA) presentano il tasso di cancellazione più elevato. La facilità di cancellazione gratuita offerta da queste piattaforme è un fattore determinante.

Variabilità per Paese


Alcuni paesi mostrano comportamenti sistematicamente diversi: il **country_group** è quindi una variabile rilevante per la previsione del rischio.

Insight: Il canale di prenotazione è un forte indicatore del rischio di cancellazione e deve essere incluso nel modello.


Segnali che Indicano Alta Probabilità di Conferma

Le richieste speciali, le modifiche alla prenotazione e la richiesta di parcheggio sono i segnali più forti di reale intenzione di soggiorno. Chi si impegna attivamente nella prenotazione raramente la cancella.

Conferma per Numero di Richieste Speciali



Source:



Source:

Messaggi Chiave

0 Richieste Speciali

~50% di conferma. La prenotazione è a rischio elevato: il cliente non ha ancora mostrato coinvolgimento reale.

4+ Richieste Speciali

~90% di conferma. Chi personalizza il soggiorno ha chiaramente intenzione di presentarsi.

Modifiche alla Prenotazione

Chi modifica la prenotazione è molto più stabile: l'interazione attiva è un segnale positivo.

Richiesta Parcheggio

Alta probabilità di conferma: chi pianifica la logistica del viaggio raramente cancella.

"L'analisi esplorativa mostra che la probabilità di conferma dipende principalmente da: anticipo della prenotazione, canale di prenotazione e segnali di coinvolgimento del cliente."

Preparazione dei Dataset per il Machine Learning

Primo Approccio: Preprocessing **Manuale**

Descrizione: Trasformazioni applicate manualmente

Operazioni:

- Encoding delle variabili categoriche
- Normalizzazione delle variabili numeriche

Vantaggio: Controllo diretto delle trasformazioni applicate ai dati


Secondo Approccio: Preprocessing **Automatico** (Dataiku)

Descrizione: Preprocessing gestito direttamente da Dataiku durante l'addestramento

Operazioni automatiche:

- Encoding delle variabili categoriche
- Scaling delle variabili numeriche
- Gestione dei valori mancanti

Vantaggio: Semplifica il processo di modellazione



Confronto dei Risultati

Modello	Manuale	Automatico (Dataiku)
LightGBM	0.951	0.955
Logistic Regression	0.914	0.919

Modelli di Machine Learning Utilizzati

Il problema è una **classificazione binaria**: il modello deve prevedere se una prenotazione sarà confermata (1) o cancellata (0). Sono stati testati due approcci complementari.

Modello 1 – Logistic Regression (Baseline)

- Modello lineare, semplice e interpretabile
- Utilizzato come punto di riferimento (baseline) per valutare il miglioramento dei modelli più complessi
- Parametro principale: **C = 10** (Dataiku ha utilizzato una procedura di **hyperparameter search** per trovare il valore migliore)
- Vantaggi: veloce da addestrare, facile da spiegare al business

Modello 2 – LightGBM (Modello Finale)

- Il modello utilizza il metodo: **Gradient Boosting Decision Tree**
- Adatto a dataset di grandi dimensioni (~120.000 righe)
- Cattura relazioni non lineari tra le variabili
- Gestisce bene **variabili numeriche e categoriali**
- **Parametri principali:**
 - ~101 alberi (n_estimators)
 - 31 foglie per albero (num_leaves)
 - Learning rate = 0.05

Logistic Regression (Logistic Regre... 0.919			✓ Done 1 day ago (2026-03-02 10:16:45)		
C Penalty Hyperparameter search size	10.0 12 5	Most important features		Train set Test set Train time	79912 rows 20088 rows about 37 seconds
		deposit_type			
		country_group			
		agent_group			
		lead_time			
		special_requests_group			
		needs_parking			

LightGBM (Logistic Regression ... 0.955			✓ Done 1 day ago (2026-03-02 10:16:39)		
Boosting type Nb. estimators Nb. leaves Learning rate Hyperparameter search size	gbdt 101 31 0.05 2	Most important features		Train set Test set Train time	79912 rows 20088 rows about 31 seconds
		deposit_type			
		country_group			
		agent_group			
		needs_parking			
		lead_time			
		market_segment			

Confronto delle Performance

Metrica Utilizzata: ROC AUC

Il ROC AUC misura la capacità del modello di distinguere correttamente tra prenotazioni confermate e cancellate, indipendentemente dalla soglia di classificazione scelta.

0.5

Modello Casuale

Nessuna capacità discriminante —
equivale a lanciare una moneta.

0.919

Logistic Regression

Ottimo risultato per un modello
baseline lineare.

0.955

LightGBM

Modello scelto per l'analisi finale.
Risultato eccellente.

Interpretazione dei Risultati

- Entrambi i modelli performano **molto bene**, superando ampiamente la soglia di 0.8 considerata un buon modello
- **LightGBM ottiene risultati migliori** (+0.04 rispetto alla Logistic Regression)
- Il modello scelto per l'analisi finale è **LightGBM**


Le ragioni principali sono:

- LightGBM riesce a catturare **relazioni più complesse tra le variabili**
- gestisce meglio dataset **di grandi dimensioni**
- è particolarmente efficace con **molte variabili categoriali**

Il modello riesce a distinguere in modo molto accurato tra prenotazioni confermate e cancellate.

Quali Variabili Influenzano di Più la Conferma?

Feature Importance – LightGBM (Top 7)



❏ **Conclusione:** Il modello non decide in modo casuale — usa variabili coerenti con il comportamento reale dei clienti, confermando la solidità dell'approccio.

Interpretazione delle Variabili Chiave

→ Deposit Non Rimborsabile

Chi paga un deposito non rimborsabile ha meno incentivo a cancellare → **meno cancellazioni**.

→ Country Group

Alcuni paesi mostrano comportamenti sistematicamente diversi nella propensione alla cancellazione.


→ Lead Time Alto

Più è lontana la data di arrivo al momento della prenotazione, **più alto è il rischio** di cancellazione.

→ Richieste Speciali e Parcheggio

Molte richieste speciali e la richiesta di parcheggio sono **segnali forti di reale intenzione** di soggiorno.

Come il lead time cambia la probabilità di conferma



Analisi "What-if"

lead_time = 7 giorni → 62.55% probabilità conferma

lead_time = 30 giorni → 19.4% probabilità conferma



Insight: Il lead_time è una delle leve più importanti per gestire il rischio di cancellazione.

Strategie di business basate sulle previsioni



Deposito per prenotazioni molto anticipate

Insight: Lead_time alto → rischio cancellazione alto

Azione: Per prenotazioni con lead_time > 100 giorni → richiedere deposito non rimborsabile oppure ridurre cancellazione gratuita

Obiettivo: Ridurre il rischio di cancellazioni tardive



Pricing dinamico

Insight: Il modello fornisce la probabilità di conferma

Azione: Alta probabilità → prezzo leggermente più alto; Bassa probabilità → piccolo sconto per incentivare conferma

Obiettivo: Massimizzare i ricavi mantenendo alta occupazione



Valorizzare clienti con forte intenzione

Insight: Molte special requests / booking changes → alta probabilità di conferma

Azione: Offrire upgrade stanza, proporre servizi aggiuntivi, applicare markup leggero

Obiettivo: Aumentare margine sui clienti più affidabili



Politiche differenziate per canale

Insight: Online TA → più cancellazioni; Corporate / Direct → più affidabili

Azione: Politiche più rigide per OTA, programmi fedeltà per corporate


Obiettivo: Ottimizzare gestione per canale

Validazione del Modello su Dati Nuovi (2024)

Il modello LightGBM è stato addestrato sui dati storici (2015–2017). In questa fase lo applico ai dati del 2024 per testarne l'efficacia in uno scenario realistico..

Questa sezione simula l'uso operativo, confrontando le previsioni su dati nuovi e sconosciuti con gli esiti reali per misurare la precisione.

Esploreremo l'intera pipeline: dalla preparazione dei dati 2024 alla valutazione finale del modello.



Pipeline 2024: Dalla Preparazione alla Predizione



Questa pipeline illustra il processo end-to-end per applicare il nostro modello LightGBM ai nuovi dati del 2024, trasformando i dati grezzi in previsioni utilizzabili per decisioni strategiche.

❏ **Perché rimuovere il target?** In uno scenario reale, al momento dello scoring, la variabile ``booking_confirmed`` (esito futuro) non è ancora nota. Il modello deve prevederla.

A cosa serve ``row_id``? Consente di unire in modo sicuro le previsioni del modello con gli esiti reali una volta che diventano disponibili, per una valutazione accurata delle performance.

Output dello Scoring: Probabilità e Predizioni

Cosa Produce il Modello

Il modello LightGBM genera per ogni prenotazione una previsione dettagliata, fondamentale per le decisioni strategiche:

- `proba_0`: Probabilità che la prenotazione sia **cancellata** (Classe 0)
- `proba_1`: Probabilità che la prenotazione sia **confermata** (Classe 1)
- `prediction`: La classe predetta (**0 o 1**), basata sulla soglia definita (**0.375**)

Come Interpretare la Probabilità di Conferma (`proba_1`)

- Se `proba_1` è **vicino a 1** (es. 0.85): Il modello è molto sicuro che la prenotazione sarà **confermata**.
- Se `proba_1` è **vicino a 0.375**: Il modello è incerto; la prenotazione potrebbe andare in entrambi i modi.
- Se `proba_1` è **vicino a 0** (es. 0.15): Il modello è molto sicuro che la prenotazione sarà **cancellata**.

Flessibilità della Soglia:

La soglia standard per la previsione è **0.375** (`prediction = 1` se `proba_1 > 0.375`). Tuttavia, questa soglia può essere **personalizzata** per allinearsi meglio agli obiettivi di business, ad esempio per ridurre i falsi positivi (cancellazioni previste ma che si confermano) o i falsi negativi (conferme previste ma che si cancellano).

Unione Predizioni e Realtà: Preparazione alla Valutazione

Il Problema: Come Confrontare Previsioni con Esiti Reali?

Per valutare l'accuratezza del modello sviluppato in questo progetto, devo confrontare le sue previsioni con ciò che è realmente accaduto. Il problema è come combinare questi due set di informazioni in modo affidabile:

- Le **predizioni del modello** (`proba\_1`, `prediction`) per le prenotazioni del 2024 sono salvate in `hotel_booking_2024_prediction`.
- Gli **esiti reali** (`booking\_confirmed`) delle stesse prenotazioni sono disponibili in `hotel_booking_2024_new_primary_key`.
- Per valutare il modello è necessario unire questi due dataset in modo sicuro, veloce e senza errori.

La Soluzione: Join su `row_id`

Il segreto per unire correttamente le previsioni agli esiti reali è l'utilizzo di una chiave univoca e consistente attraverso entrambi i dataset: il `row_id`.

Dataset Predizioni (A)

Contiene le stime del modello:

- `row_id`
- `proba_1` (Probabilità di conferma)
- `prediction` (Classe predetta)

Dataset Esiti Reali (B)

Contiene gli esiti osservati:

- `row_id`
- `booking_confirmed` (Confermato/Cancellato)

⬇ **Join Condition:** `Dataset A.row_id = Dataset B.row_id` ⬇

Questo processo genera un dataset unificato (`hotel_booking_2024_joined`), pronto per l'analisi delle performance.

Perché `row_id` è Cruciale?

- Una join basata su più colonne (es. `lead_time`, `mese`, `tipo_camera`) sarebbe rischiosa, potendo generare duplicati o errori di matching.
- `row_id` è una **chiave univoca e sequenziale** (e.g., 0, 1, 2, ..., 119382) assegnata a ogni singola prenotazione.
- Garantisce una **join 1-a-1** veloce e corretta, assicurando che ogni previsione sia associata al suo esito reale corrispondente.

📄 **Struttura del Dataset Finale:** Dopo la join, il nostro dataset includerà le colonne: `row_id`, `proba_1`, `prediction`, e `booking_confirmed`.

Questo ci permette di calcolare metriche chiave come: matrice di confusione, accuratezza (accuracy), precisione (precision), richiamo (recall) e F1-score, per una valutazione completa delle performance del modello.

Risultati della Valutazione: Performance del Modello su Dati 2024

Matrice di Confusione

La matrice di confusione mostra la distribuzione delle previsioni del modello rispetto agli esiti reali sul dataset del 2024.


	Predizione: 0 (Cancellata)	Predizione: 1 (Confermata)
Reale: 0 (Cancellata)	24,319 (TN)	19,901 (FP)
Reale: 1 (Confermata)	3,832 (FN)	71,331 (TP)

Totale prenotazioni valutate: 119,383

Metriche di Performance

Queste metriche riassumono l'efficacia del modello nel prevedere le cancellazioni e le conferme.

Metriche



Il grafico a barre mostra il valore percentuale delle metriche di valutazione chiave del modello.

Interpretazione Pratica

- **Alto Recall (94.90%):** Il modello è molto efficace nell'identificare le prenotazioni che si **confermeranno** (classe 1). Significa che il modello "perde" poche conferme reali, il che è cruciale per la gestione dell'inventario.
- **Precision Moderata (78.19%):** Quando il modello predice una **conferma**, ha ragione circa il 78% delle volte. Ciò implica che circa il 22% delle prenotazioni che il modello prevede come confermate, in realtà vengono **cancellate** (Falsi Positivi).

In sintesi, il modello è conservativo nel predire le cancellazioni e tende a sovra-prevedere le conferme, il che lo rende forte nell'identificare le prenotazioni stabili ma meno preciso nel filtrare quelle a rischio di cancellazione tra quelle previste come confermate.

Possibili Miglioramenti e Trade-off

📄 Aumentare la Soglia di `proba_1`:

- Per ridurre i Falsi Positivi (prenotazioni previste come confermate ma che si cancellano), potremmo aumentare la soglia di decisione per `proba_1` (es. da **0.375** a 0.5 o 0.6).
- **Implicazione:** Questo aumenterebbe la **Precision** (il modello sarebbe più affidabile quando predice una conferma), ma potrebbe ridurre il **Recall** (potrebbe non catturare tutte le conferme reali, aumentando i Falsi Negativi).

Il trade-off tra Precision e Recall deve essere bilanciato in base agli obiettivi di business specifici. Se l'hotel preferisce non rischiare di overbookare (alta precisione nelle conferme), potrebbe voler aumentare la soglia. Se invece l'obiettivo primario è non perdere nessuna prenotazione confermata (alto recall), la soglia attuale potrebbe essere più adeguata.

Validazione Completata: Modello Pronto per il Deployment

Cosa Abbiamo Imparato

I rigorosi test sul modello predittivo delle cancellazioni hanno fornito risultati chiari e incoraggianti:

Robustezza Verificata

Il modello LightGBM, addestrato su dati 2015-2017, ha mantenuto un'accuratezza dell'80% su dati completamente nuovi del 2024. Questo dimostra una forte capacità di generalizzazione e assenza di overfitting.

Coerenza delle Performance

Le performance osservate durante la fase di validazione sono coerenti con quelle registrate durante il training iniziale, confermando l'affidabilità del modello in scenari reali.

Punti di Forza del Modello

Recall Eccezionale (94.90%)

Il modello è estremamente efficace nell'identificare le prenotazioni che effettivamente si confermeranno. Questo è un vantaggio critico per la gestione dell'inventario e la pianificazione operativa dell'hotel, riducendo al minimo il rischio di perdere prenotazioni reali.

Affidabilità nelle Conferme

La sua elevata capacità di "catturare" le conferme lo rende uno strumento affidabile per identificare le prenotazioni stabili, permettendo decisioni più sicure riguardo all'allocazione delle risorse.

Aree di Miglioramento

- Precision Moderata (78.19%):** Circa 1 su 5 prenotazioni previste come confermate si cancella effettivamente. Questo indica che il modello genera un numero controllabile di falsi positivi.
- Potenziale di Ottimizzazione:** Questa metrica suggerisce che il modello potrebbe beneficiare di un'ulteriore ingegnerizzazione delle feature (feature engineering) o di un tuning più fine degli iperparametri, per migliorare la distinzione tra conferme e cancellazioni a rischio.
- Soglia Adattabile:** Esiste la possibilità di aggiustare la soglia di decisione per `proba_1`, personalizzandola in base agli specifici obiettivi di business (es. priorità alla riduzione dell'overbooking vs. massimizzazione delle occupazioni).

Il percorso del progetto



Fase 1: Analisi Esplorativa (EDA)

Identificati i fattori chiave (lead_time, segnali di intenzione, canale).



Fase 2: Modellazione

LightGBM supera Logistic Regression (ROC AUC 0.95 vs 0.91).



Fase 3: Validazione su Dati Nuovi

Modello mantiene 80% accuracy su dataset 2024.



Fase 4: Pronto per il Deployment

Recall 94.90%, Precision 78.19%.

Risultati Chiave

Performance Verificate

- Accuracy: **80.12%** su dati completamente nuovi (2024)
- Recall eccezionale: **94.90%** (cattura quasi tutte le conferme)
- Generalizzazione confermata: nessun overfitting
- Modello robusto e affidabile

Valore di Business Realizzato

- **Ridurre cancellazioni** impreviste (identificare prenotazioni a rischio)
- **Ottimizzare pricing dinamico** (prezzi basati su probabilità di conferma)
- **Gestione camere intelligente** (allocazione basata su previsioni)
- **Aumentare margine di guadagno** (strategie differenziate per segmento)

Fattori Critici Identificati

- **Lead_time**

Più è alto, più rischio di cancellazione.

- **Canale di Prenotazione**

Direct/Corporate affidabili, Online TA instabili.

- **Segnali di Intenzione**

Special requests, modifiche, parcheggio = alta conferma.

- **Profilo Cliente**

Aziendali stabili, Transient più volatili.

Prossimi Passi Concreti



Deployment in Produzione

Implementare il modello per lo scoring in tempo reale delle nuove prenotazioni, integrando le previsioni nei flussi di lavoro esistenti dell'hotel.



Monitoraggio Continuo

Stabilire un sistema di monitoraggio delle performance per rilevare eventuali derive del modello e garantire l'accuratezza nel tempo.



Feedback Operativo

Raccogliere feedback dagli operatori dell'hotel per identificare ulteriori opportunità di miglioramento e affinare il modello.



Integrazione Strategica

Esplorare l'integrazione del modello con i sistemi di pricing dinamico e gestione delle camere per massimizzare i ricavi e l'efficienza operativa.

In questo progetto ho trasformato circa 120.000 prenotazioni storiche in un modello predittivo validato,
capace di identificare oltre il 94% delle prenotazioni confermate.

Questo dimostra come il Machine Learning possa essere applicato concretamente alla gestione alberghiera
per supportare decisioni strategiche basate sui dati.